Sinais precoces de corretude

João Felipe Vilas Boas · FGV EMAP

Prever a trajetória, acrescentar informação e economizar inferência.

Qwen2.5-Coder-1.5B-Instruct · HumanEval+ · MBPP+

Um resultado negativo aprofundado por diagnóstico e análise econômica.

Tarefa, trajetória e ação

- AUC agregada pode reconhecer dificuldade do prompt.
- WT-AUC compara corretos e incorretos da mesma tarefa.
- Probabilidades precisam sustentar decisões de aborto.
- Resolução e custo avaliam o sistema sequencial.

Um estado determinístico do prompt empata as tentativas da mesma tarefa.

Desenho e história

- Piloto: 960 trajetórias, 32 tarefas.
- HumanEval+: 2.640 tentativas, 132 tarefas.
- MBPP+ congelado: 640 tentativas, 32 tarefas.
- Em 32 tokens: 2.158 candidatos ativos e 92 tarefas mistas.

26 tarefas principais constam de artefatos anteriores. Aprovação do orientador permanece pendente; não se reivindica pré-registro independente.

Validação por tarefas

- Cinco folds externos; tarefa inteira permanece no mesmo fold.
- Seleção interna de C e camada com perda ponderada por tarefa.
- Cross-fitting de toda a seleção antes de Platt.
- Bootstrap pareado de tarefas, condicional aos escores ajustados.

No residual, a seleção e calibração do primeiro estágio também excluem o rótulo pontuado.

Resultado original em 32 tokens

Preditor	AUC	WT-AUC	Log loss
B	0,701	0,628	0,630
H	0,592	0,568	0,687
H+B	0,646	0,581	0,668

ΔWT-AUC = −0,0470 [−0,0994; 0,0056].

Δlog loss = +0,0379 [0,0067; 0,0706].

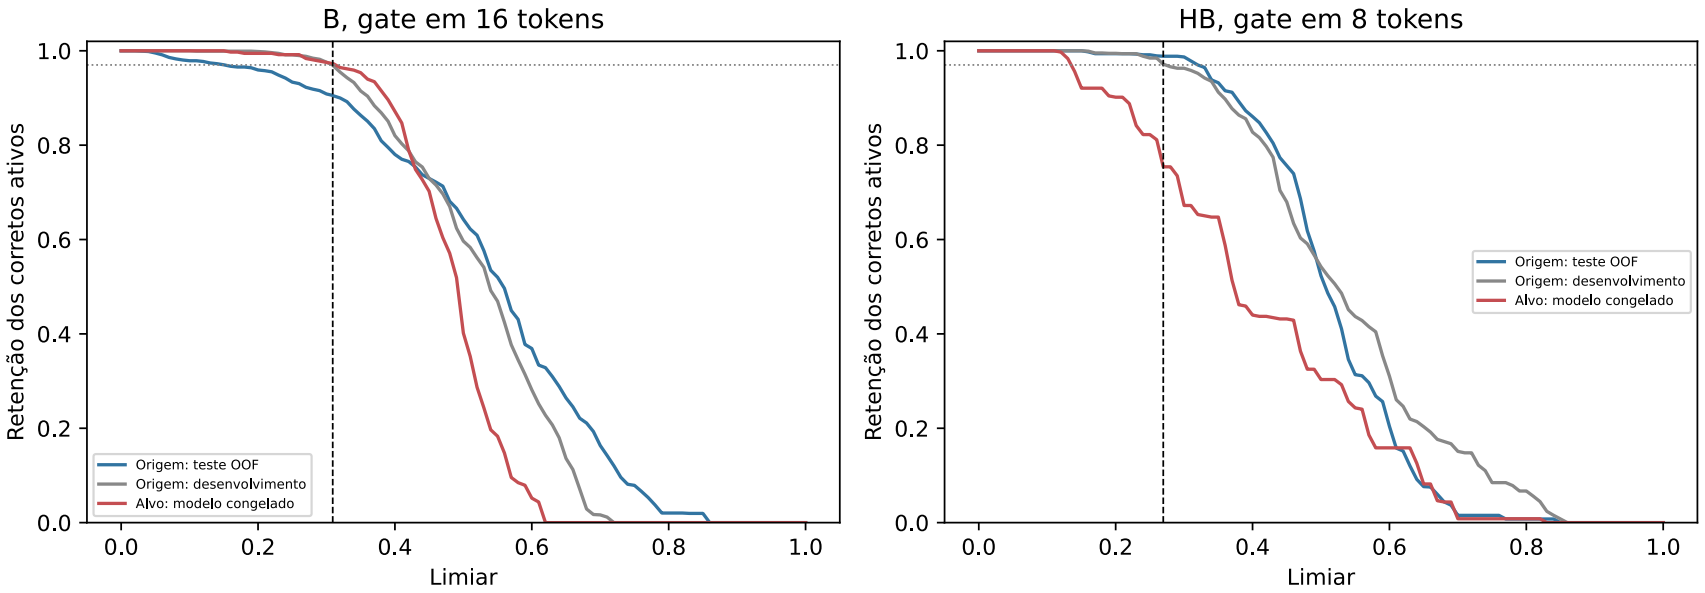
Os critérios originais de ganho incremental e benefício conjunto não foram satisfeitos.

Leituras alternativas: o que aprendemos?

- NLL média e margem preservam parte importante do ranking.
- PCA64: WT-AUC 0,630; log loss 0,632.
- Residual ancorado em B: WT-AUC 0,635; log loss 0,629.
- Intervalos contra B incluem zero; penalização conjunta mais forte não resolveu.

Sensibilidade à parametrização é sustentada; causa única e superioridade geral não são identificadas.

Retenção não é garantia externa



Origem OOF, desenvolvimento e alvo congelado são avaliações distintas. Limiares definidos apenas na origem.

Candidatos descartados e cobertura

- H+B no alvo: 276/366 corretos ativos mantidos, 75,41%.
- 90 descartes distribuídos por 12 tarefas; cinco concentram 60.
- Mbpp/166 perde oito sucessos; Mbpp/259 perde seu único sucesso.
- Entre corretos ativos iniciados: 23/48 abortados.

O denominador muda com o caminho de execução. Duas tarefas perdem resolução.

Custo até sucesso

Condicionado à tarefa, com tentativas iid:

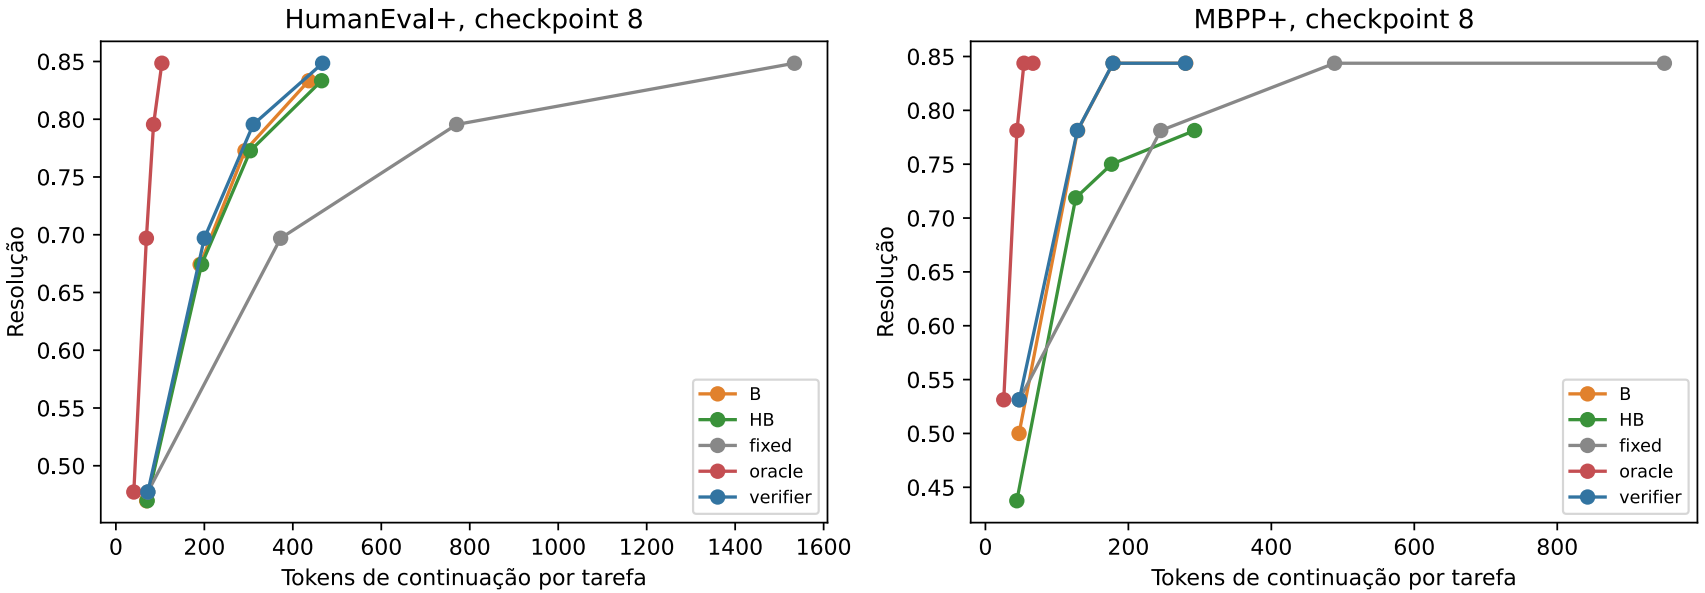
$$E[C(N)] = E[D] \sum_{j=0}^{N-1} (1 - pr)^j.$$

Para orçamento ilimitado, p>0 e r>0:

$$\frac{E[D]}{E[T]} < r.$$

Retenção global, heterogeneidade, cobertura finita e overhead precisam entrar. Tokens, latência, energia e FLOPs são medidas distintas.

Oracle retrospectivo



Em t=8, N=20: economia idealizada 77,75% em HumanEval+ e 76,25% em MBPP+. Conhece os rótulos; preserva todos os corretos.

Integridade e limites

- Métricas e os três scorers principais reconstituídos.
- 70 unidades de leitura exploratória repetidas com probabilidades idênticas.
- 50 pares / 100 gerações: tokens e estados idênticos entre capturas.
- RTX3050 Laptop 6 GB detectada; tempos técnicos são descritivos.

Um modelo, dois benchmarks, exposição histórica e intervalos condicionais. Nenhuma causa semântica, garantia externa ou aceleração da política é presumida.

Próximo teste e contribuição

Proposta: B e H+B congelados em t=8, 120 novas tarefas MBPP+, 20 tentativas por tarefa e piloto técnico disjunto de 20 tarefas.

Endpoint único: diferença pareada de retenção na mesma população ativa. Coleta aguarda aprovação do estudante e revisão do orientador.

Contribuição: separar sinais, leituras, decisões e oportunidade econômica em uma avaliação delimitada, explicativa e auditável.