**FUNDAÇÃO GETULIO VARGAS**

ESCOLA DE MATEMÁTICA APLICADA

João Felipe Vilas Boas

# SINAIS LATENTES PRECOCES DE CORRETUDE EM GERAÇÃO DE CÓDIGO

Avaliação intratarefa, custo de inferência e transferência de sinais precoces

Rio de Janeiro
2026

João Felipe Vilas Boas

# SINAIS LATENTES PRECOCES DE CORRETUDE EM GERAÇÃO DE CÓDIGO

Avaliação intratarefa, custo de inferência e transferência de sinais precoces

Trabalho de Conclusão de Curso apresentado à Escola de Matemática Aplicada da Fundação Getulio Vargas como requisito para obtenção do grau de bacharel em Matemática Aplicada.

Orientador: Prof. Dário Oliveira.

Rio de Janeiro
2026

## RESUMO

Este estudo avalia sinais latentes de corretude e interrupção precoce na geração de código pelo Qwen2.5-Coder-1.5B-Instruct. Um piloto de 960 trajetórias escolhe o regime de amostragem por regra fixa. O banco principal contém 2.640 tentativas em 132 tarefas HumanEval+, avaliadas pelo EvalPlus. A validação aninhada por tarefa separa treinamento, seleção e teste. No endpoint primário de 32 tokens, 2158 trajetórias permanecem ativas e 92 tarefas contêm ambos os resultados. A diferença de WT-AUC entre H+B e B foi −0,047, IC 95% [−0,099; 0,006]; a diferença de log loss foi 0,038, IC 95% [0,007; 0,071]. O resultado não satisfaz o critério de ganho incremental definido no protocolo. Políticas são comparadas com as mesmas sementes e orçamentos contra parada por verificador e por observáveis. Os critérios conjuntos para afirmar benefício operacional não foram satisfeitos. A transferência aplica um sistema congelado a 640 tentativas MBPP+, sem ajuste nos dados alvo. A execução respeita uma GPU de 6 GB. Os intervalos são condicionais aos modelos OOF ajustados. O histórico de exposição a tarefas é divulgado e não se reivindica pré-registro independente nem aprovação do orientador por inferência a partir da execução. Análises exploratórias com PCA e correção residual reduzem a desvantagem da combinação, sem estabelecer superioridade sobre B. Um oracle retrospectivo preserva os corretos e quantifica o espaço econômico idealizado. Uma extensão aprovada e congelada antes de novas trajetórias avaliou 120 tarefas MBPP+ sem resultados locais anteriores. Em oito tokens, a diferença de retenção H+B−B é −0,1636, IC95% [−0,240; −0,094]; o resultado satisfaz o critério direcional próprio, sem alterar as decisões originais.



**Palavras-chave:** geração de código; probing; corretude funcional; validação agrupada; inferência adaptativa.

## ABSTRACT

We evaluate hidden correctness signals and early termination with Qwen2.5-Coder-1.5B--Instruct. A 960-trajectory pilot selects sampling by a fixed rule. The main bank comprises 2,640 attempts across 132 HumanEval+ tasks with official EvalPlus labels and task-grouped nested validation. At the primary 32-token endpoint, 2158 trajectories remain active and 92 tasks contain both outcomes. The H+B versus B within-task AUC difference is −0.047 with a 95% interval [−0.099, 0.006]. The log-loss difference is 0.038 [0.007, 0.071]. The predeclared incremental-gain criterion is not met. Paired policies are compared against verifier stopping and observable-feature aborts. Frozen transfer uses 640 MBPP+ attempts without target fitting. Intervals are conditional on fitted out-of-fold scorers; prior task exposure is disclosed. The original execution record lacks advisor approval; review of the new extension was reported by the student. No independent preregistration is claimed. Exploratory PCA and anchored residual readouts reduce the original deficit without establishing improvement over B. A retrospective label-aware oracle quantifies economic headroom while preserving every correct candidate. A prospectively approved extension evaluated 120 locally unexposed MBPP+ tasks. At eight tokens, H+B minus B correct-candidate retention is −0.1636, 95% CI [−0.2402, −0.0943]; the result meets its sole directional criterion and does not revise the original decisions.



**Keywords:** code generation; probing; functional correctness; grouped validation; adaptive inference.

## SUMÁRIO


1 Introdução . . . . . 6
1.1 Contexto e motivação . . . . . 6
1.2 Problema científico . . . . . 6
1.3 Objetivos e sequência de evidências . . . . . 7
1.4 Delimitação e estado da entrega . . . . . 7
2 Trabalhos relacionados e posicionamento . . . . . 9
2.1 Amostragem repetida e verificação funcional . . . . . 9
2.2 Representações internas e estimação de corretude . . . . . 9
2.3 Dificuldade e interrupção adaptativa . . . . . 10
2.4 Complexidade do probe e transporte de probabilidades . . . . . 10
2.5 Contribuição delimitada e limites da reivindicação . . . . . 10
2.6 Matriz de posicionamento . . . . . 11
3 Fundamentação matemática e computacional . . . . . 12
3.1 Formulação probabilística e notação . . . . . 12
3.2 Transformers, espaço latente e extração causal . . . . . 13
3.3 Dificuldade da tarefa e sinal específico da trajetória . . . . . 15
3.4 Amostragem repetida, seleção e custo . . . . . 17
4 Metodologia . . . . . 21
4.1 Desenho experimental e construção dos dados . . . . . 21
4.2 Preditores precoces e modelos estatísticos . . . . . 23
4.3 Validação, inferência estatística e controles . . . . . 26
4.4 Política de interrupção precoce e replay . . . . . 30
4.5 Ambiente efetivamente validado . . . . . 32
4.6 Transferência externa implementada . . . . . 33
5 Resultados do desenho fixo . . . . . 34
5.1 Amostragem, elegibilidade e proveniência . . . . . 34
5.2 Predição e ganho incremental no endpoint primário . . . . . 34
5.3 Replay pareado e validação em execução real . . . . . 38
5.4 Transferência congelada para MBPP+ . . . . . 41
5.5 Diagnósticos exploratórios posteriores ao resultado principal . . . . . 42
6 Diagnósticos, limite econômico e validação independente . . . . . 47
6.1 Perguntas explicativas e desenho das ablações . . . . . 47
6.2 Componentes do baseline e leituras latentes alternativas . . . . . 48
6.3 Geometria e sensibilidade ao número de tarefas . . . . . 49
6.4 Anatomia da deterioração do gate em MBPP+ . . . . . 50
6.5 Potencial econômico e distância ao oracle . . . . . 52
6.6 Medições técnicas e avaliação independente . . . . . 54
6.7 Validação independente aprovada . . . . . 54

7 Discussão e limitações ..... 59
7.1 Interpretação dos resultados do desenho fixo ..... 59
7.2 Síntese dos diagnósticos exploratórios ..... 59
7.3 O que explica e o que permanece indeterminado ..... 59
7.4 Alcance da avaliação independente ..... 60
7.5 Validade interna ..... 60
7.6 Validade de mensuração e do verificador ..... 60
7.7 Validade externa e contaminação ..... 60
7.8 Precisão estatística e escopo computacional ..... 61
7.9 Trabalhos futuros ..... 61
8 Considerações finais ..... 62
Referências ..... 63
9 Reprodutibilidade e histórico metodológico ..... 65
9.1 Artefatos e comandos ..... 65
9.2 Correções da versão 0.2 ..... 65
9.3 Integridade e assistência computacional ..... 66
9.4 Diagnósticos posteriores à análise principal ..... 66

# 1 INTRODUÇÃO

## 1.1 Contexto e motivação

Modelos de linguagem especializados em código permitem formular a síntese de programas como geração de sequências condicionada a uma especificação. Uma única execução pode produzir uma solução incorreta mesmo quando o modelo atribui probabilidade positiva a soluções corretas. Por isso, amostrar diversos candidatos amplia a oportunidade de encontrar uma solução que passe em um verificador. A avaliação de Codex introduziu o HumanEval e consolidou o uso de corretude funcional e de pass@k na análise de geração de código (Chen et al., 2021). Estudos de amostragem repetida também demonstram que o orçamento de inferência é uma dimensão relevante para ampliar a cobertura de tarefas solucionadas (Brown et al., 2024).

O benefício da repetição tem um custo. Cada candidato utiliza computação para processar o prompt, gerar tokens e executar testes. Parte desse esforço é gasta em candidatos que, quando completados, falham no verificador. Surge então uma possibilidade: identificar durante a geração trajetórias com baixa probabilidade de sucesso e interrompê-las antes de consumir todo o orçamento previsto. Essa possibilidade só é útil se a identificação ocorrer cedo, se não eliminar sucessos em excesso e se seu custo adicional não anular a economia.

O projeto estuda essa questão em um Small Language Model (SLM), usando o termo para descrever o porte do modelo escolhido, sem pressupor uma fronteira universal entre modelos pequenos e grandes. A infraestrutura validada é uma máquina pessoal com GPU NVIDIA RTX 3050 Laptop de 6 GB. A limitação de recursos motiva um desenho compacto, centrado em um modelo, um benchmark principal e uma verificação externa de robustez.

## 1.2 Problema científico

Um classificador pode prever corretude porque reconhece que certos problemas são fáceis. Isso não implica que consiga distinguir duas respostas diferentes ao mesmo problema. Essa distinção é decisiva para a interrupção de um candidato: uma avaliação que permanece constante entre todas as tentativas do prompt orienta alocação de orçamento por tarefa, mas não identifica qual tentativa merece continuar.

A pergunta central é:

> **Pergunta de pesquisa**
> As representações internas precoces de um SLM contêm informação que distingue trajetórias corretas e incorretas geradas para a mesma tarefa, além da dificuldade do problema e das estatísticas observáveis escolhidas, e essa informação permite reduzir o custo de inferência com múltiplas tentativas?

A expressão “além dos observáveis” refere-se a uma comparação operacional entre classes de preditores especificadas. Não significa informação adicional em relação ao texto completo do prefixo e ao conhecimento integral do modelo, pois o estado interno é calculado a partir desses

elementos. O trabalho tampouco interpreta previsibilidade como consciência, introspecção humana ou conhecimento infalível do futuro.

### 1.3 Objetivos e sequência de evidências

O objetivo geral é caracterizar o valor preditivo e operacional de estados internos de prefixos em geração verificável de código. As três perguntas do protocolo original organizam o núcleo experimental; duas perguntas complementares delimitam o transporte e a oportunidade econômica:

Quadro 1: Perguntas de pesquisa e evidência necessária em cada nível da avaliação.

| Pergunta | Evidência necessária |
|---|---|
| Q1 — Previsibilidade | Medir em que posições os estados internos predizem o resultado final em tarefas não utilizadas no treinamento. |
| Q2 — Especificidade | Comparar trajetórias corretas e incorretas do mesmo problema e avaliar o ganho sobre estatísticas observáveis do prefixo. |
| Q3 — Utilidade | Avaliar se uma política de interrupção reduz custo mantendo a resolução dentro de uma margem previamente declarada. |
| Q4 — Transporte | Examinar a retenção dos gates congelados em outras tarefas, sem recalibração no alvo. |
| Q5 — Oportunidade | Medir a distância entre os gates disponíveis e um oracle contrafactual que preserva todos os corretos. |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

A contribuição está no encadeamento entre essas evidências. Uma AUC agregada elevada responde apenas a parte de Q1. Uma classificação melhor dentro da tarefa responde a parte de Q2. A existência de informação estatística útil não implica, por si só, que interromper gerações produza ganho operacional. Q4 e Q5 não alteram os critérios originais de Q2 e Q3. O resultado negativo principal é aprofundado por ablações de complexidade, diagnóstico de transferência e uma análise contrafactual do espaço econômico disponível. A extensão independente tem um único estimando de retenção e autorização próprios.

### 1.4 Delimitação e estado da entrega

O núcleo experimental utiliza Qwen2.5-Coder-1.5B-Instruct, HumanEval+ e múltiplas gerações sob uma configuração de amostragem congelada. MBPP+ foi a extensão externa executada. A avaliação adicional reserva outras tarefas do mesmo MBPP+, sem resultados locais anteriores; não constitui um terceiro benchmark. Foi aprovada pelo estudante, que informou revisão do orientador, e congelada antes das novas trajetórias. Seu estado e seus resultados são apresentados separadamente no capítulo empírico. Activation Steering, efeitos causais de intervenções, transferência entre modelos e extração de características por autoencoders esparsos ficam como trabalhos futuros. Não são condições para completar o TCC.

A avaliação principal usa o desenho fixo v0.2, com piloto separado, banco completo e validação por tarefa. A reanálise histórica permanece exploratória e é apresentada separadamente. As decisões empíricas seguem os critérios definidos antes do banco principal; os capítulos divulgam a exposição histórica e a autorização de execução.

O arquivo `RESEARCH_PROTOCOL.md` registra as decisões experimentais. A versão 0.2 foi executada sob desenho fixo, autorização prospectiva do estudante e snapshot de fontes e configuração anterior ao banco principal. Seu registro histórico mantém a aprovação do orientador como pendente; não se reivindica pré-registro independente. A aprovação posterior da extensão não cria aprovação retroativa do v0.2. A exposição anterior a 26 tarefas principais é divulgada. Protocolos, emenda administrativa, hashes e registros de autorização preservam essa cronologia, sem apresentar escolhas posteriores aos resultados como antecipadas.

# 2 TRABALHOS RELACIONADOS E POSICIONAMENTO

## 2.1 Amostragem repetida e verificação funcional

Chen et al. (2021) formulam a avaliação de programas gerados por meio de testes e apresentam um estimador de pass@k baseado em múltiplos candidatos. Brown et al. (2024) estudam o aumento de cobertura obtido com mais amostras e destacam a relevância da seleção e verificação. Esses trabalhos motivam a separação entre a capacidade de gerar ao menos uma solução correta e a capacidade de identificá-la.

A qualidade do verificador também importa. Liu et al. (2023) apresentam EvalPlus e a ampliação dos testes de HumanEval para HumanEval+, mostrando que testes mais completos revelam falhas que os testes originais não identificam. Neste projeto, a variável resposta é passar em uma versão fixada dessa suíte. Isso fornece um critério reproduzível, mas não uma prova de correção para todas as entradas possíveis.

## 2.2 Representações internas e estimação de corretude

Kadavath et al. (2022) diferenciam a avaliação de uma resposta específica da estimativa de que o modelo saberá responder uma pergunta. Essa distinção é próxima da separação entre nível da tarefa e nível da trajetória adotada aqui. Azaria; Mitchell (2023) estudam classificadores sobre ativações internas para identificar veracidade de afirmações, comparando-os também a medidas baseadas na probabilidade da sequência. A abordagem de Representation Engineering organiza a investigação de fenômenos de alto nível em padrões distribuídos das ativações (Zou et al., 2023).

Em geração de código, Di Cicco (2026) reporta decodificação linear de corretude a partir do estado do último token do prompt em Qwen3-4B-Instruct-2507 sobre tarefas de LiveCodeBench. O resultado demonstra a relevância de estados anteriores à geração para discriminação entre tarefas. Por construção, porém, um estado determinístico do mesmo prompt é compartilhado pelas suas diferentes tentativas. Essa observação motiva uma avaliação adicional entre trajetórias do mesmo problema.

Klassert (2026) investiga estimação de incerteza introspectiva em geração de código, com características estáticas e dinâmicas e avaliações no nível da resposta e da linha. O resumo do trabalho reporta sinal de corretude no nível da resposta, sem ganhos consistentes das estratégias dinâmicas mais elaboradas. Isso reforça a opção por um probe simples como experimento principal; não justifica assumir que uma dinâmica temporal mais complexa será superior.

Rathnasuriya; Yang (2026) examinam sobreconfiança em quatro modelos de código e três benchmarks de execução. Confiança e entropia oferecem discriminação parcial e dependente do modelo; seleção por incerteza não melhora consistentemente a acurácia do conjunto aceito. A análise latente é exploratória. Esse antecedente recente aproxima a literatura da comparação entre observáveis e estados internos, mas não estabelece o estimando intratarefa

nem o custo sequencial dos gates específicos avaliados neste TCC. Resultados de modelos de 7–8 bilhões de parâmetros não são transferidos numericamente ao modelo de 1,5 bilhão.

### 2.3 Dificuldade e interrupção adaptativa

Zhu et al. (2025) estimam dificuldade percebida pelo modelo a partir de representações iniciais e aplicam essa informação a estratégias de inferência adaptativa. Ruan et al. (2026) estudam interrupção de episódios de agentes a partir de probes em estados internos, com controle de retenção e certificação em dados independentes. Seu cenário, unidade temporal e procedimento de garantia diferem de uma regra empírica ajustada em prefixos de código.

O método ST-BoN (Wang et al., 2025) utiliza estados internos em uma estratégia de truncamento e seleção de candidatos. Esse antecedente impede apresentar o uso de hidden states para reduzir o custo de Best-of-N como novidade isolada. A comparação do presente estudo concentra-se na corretude funcional supervisionada, na discriminação dentro da tarefa e na comparação controlada com observáveis.

### 2.4 Complexidade do probe e transporte de probabilidades

Hewitt; Liang (2019) mostram que o desempenho de um probe pode refletir sua capacidade de aprender a tarefa, motivando controles e restrições de complexidade. Seus controles linguísticos diferem da permutação de rótulos intratarefa utilizada aqui. As ablações com PCA, penalização e offset residual avaliam a sensibilidade à parametrização; não identificam, sozinhas, um mecanismo semântico ou a ausência de informação acessível a outros decodificadores.

Ovadia et al. (2019) avaliam incerteza sob mudanças de distribuição e documentam limitações do transporte da calibração. Isso motiva avaliar o gate congelado por suas decisões, além do ranking. O presente estudo distingue escores OOF da origem, escores de desenvolvimento usados na seleção do gate e aplicação de um modelo ajustado em toda a origem ao novo benchmark. Essa distinção impede atribuir toda diferença a um único efeito de domínio.

### 2.5 Contribuição delimitada e limites da reivindicação

O trabalho não reivindica ter sido o primeiro a prever corretude com hidden states, o primeiro a estimar dificuldade nem o primeiro a interromper inferência com sinais internos. A contribuição é uma avaliação integrada e reproduzível, em um regime delimitado de geração de código, de três aspectos: separação entre tarefa e trajetória; poder incremental sobre baselines observáveis especificados; e utilidade em uma política sequencial de interrupção. A extensão exploratória aprofunda o resultado negativo com controles de parametrização, diagnóstico dos sucessos descartados e um limite econômico contrafactual. A derivação do custo por série geométrica e os métodos de PCA e validação não são apresentados como novidades teóricas.

As referências são identificadas por fontes primárias, com versão explícita quando fixada na bibliografia. Resultados resumidos não substituem a leitura integral dos métodos antes da comparação final. Em especial, alegações de ausência de trabalhos idênticos exigem revisão bibliográfica mais ampla; não são inferidas de uma busca limitada.

## 2.6 Matriz de posicionamento

Quadro 2: Posicionamento sintético em relação aos antecedentes discutidos na revisão bibliográfica.

| Antecedente | Objeto principal | Relação com este estudo |
|---|---|---|
| Di Cicco | Corretude da primeira tentativa a partir do prompt | Motiva separar dificuldade e trajetória |
| Klassert | Incerteza introspectiva em respostas e linhas de código | Motiva o probe simples e limites da generalização |
| Rathnasuriya e Yang | Sobreconfiança, seleção e sinais latentes exploratórios | Exige separar ranking, calibração, retenção e custo sequencial |
| Zhu et al. | Dificuldade percebida e alocação de inferência | Comparação no nível da tarefa |
| Ruan et al. | Abortos em episódios de agentes | Retenção certificada difere de meta empírica |
| Wang et al. / ST-BoN | Consistência interna entre amostras e truncamento | Uso de estados internos para economia já possui antecedentes |
| Este estudo | Trajetórias da mesma tarefa, observáveis e replay pareado | Evidência precoce medida; diagnósticos de parametrização, transporte e limite econômico |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

# 3 FUNDAMENTAÇÃO MATEMÁTICA E COMPUTACIONAL

## 3.1 Formulação probabilística e notação

### *3.1.1 Tarefas, candidatos e configuração*

Seja $\mathcal{X}$ o espaço de tarefas e seja $x_i \in \mathcal{X}$ o prompt da tarefa $i$, incluindo especificação, assinatura e template fixado. O modelo tem parâmetros $\theta$ congelados. Uma configuração $c$ reúne temperatura, top-p, limite de tokens, regras de parada, precisão e versão do tokenizer. A tentativa $j$ produz a sequência aleatória $Y_{ij} = \left(Y_{ij1}, ..., Y_{ijT_{ij}}\right)$, de comprimento $T_{ij}$.

Distinguem-se a distribuição original do modelo, $p_\theta$, e a distribuição efetivamente usada pelo decodificador, $q_{\theta,c}$. A lei da sequência amostrada é

$$q_{\theta,c}(y \mid x_i) = \prod_{u=1}^{T} q_{\theta,c}(y_u \mid x_i, y_{<u}). \tag{1}$$

O comprimento é determinado por término natural ou limite computacional. A distribuição da sequência incorpora as regras de parada. Tratar todos os candidatos como tendo comprimento fixo esconderia uma dimensão essencial do custo e da elegibilidade para interrupção.

Quadro 3: Notação do modelo de geração, corretude e custo sequencial.

| Símbolo | Significado |
|---|---|
| $i, j$ | Tarefa e tentativa. |
| $x_i, c, \theta$ | Prompt, configuração de inferência e parâmetros do modelo. |
| $T_{ij}$ | Número de tokens gerados, incluindo os tokens de término conforme convenção registrada. |
| $S_{ij}$ | Indicador de aprovação na suíte funcional. |
| $\ell, t$ | Camada do Transformer e posição relativa à completion. |
| $h_{ij\ell t}$ | Estado interno após processar o token de completion $t$. |
| $B_{ijt}, z_{ijt}$ | Vetor de observáveis e score do probe. |
| $\pi_i$ | Probabilidade de sucesso de uma tentativa da tarefa $i$ no regime fixado. |
| $N, q$ | Número máximo de tentativas e limiar de interrupção. |
| $A_i, C_i$ | Resolução da tarefa e custo acumulado de uma política. |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### *3.1.2 Corretude operacional*

Um verificador $V$ recebe a tarefa e o programa extraído da completion. Sua saída define

$$S_{ij} = V\big(x_i, Y_{ij}\big) \in \{0, 1\}, \quad \pi_i = P\big(S_{ij} = 1 \mid x_i, c\big). \tag{2}$$

O verificador é mantido fixo em versão, testes, ambiente e limites de execução. Falhas de sintaxe, execução, asserção e extração são classificadas como insucesso. Um timeout do programa é uma falha sob o orçamento especificado. Uma interrupção da infraestrutura de avaliação é um erro de medição e deve ser reexecutada ou marcada como dado indisponível, sem virar automaticamente um rótulo negativo.

Truncamento no limite de geração é registrado como atributo do candidato. O programa extraído é avaliado pela mesma regra funcional: um candidato que terminou por limite pode, excepcionalmente, já conter uma solução válida. Caso o protocolo deseje definir sucesso como "passa e não truncou", deve nomear essa variável separadamente e não confundi-la com corretude funcional. Esta versão adota a aprovação no verificador como rótulo principal.

#### *3.1.3 Informação disponível durante a geração*

Seja $\mathcal{F}_{ijt}$ a informação observável até o prefixo de comprimento $t$: prompt, tokens amostrados, distribuições de decodificação calculadas e estados acessíveis até esse instante. O resultado final é observado apenas depois de completar e testar o programa. O alvo ideal de um preditor precoce é

$$p^{*}_{ijt} = P\big(S_{ij} = 1 \mid \mathcal{F}_{ijt}\big). \tag{3}$$

Antes do término, o mesmo prefixo pode admitir continuações corretas e incorretas. Portanto, "trajetória com baixa chance de sucesso" não significa "trajetória inevitavelmente errada". Dois candidatos que compartilham exatamente o mesmo prefixo podem receber a mesma previsão e posteriormente obter rótulos diferentes.

Pela propriedade da esperança condicional, a sequência ideal $p^{*}_{ijt}$ satisfaz, antes ou após absorção no término,

$$E\big[p^{*}_{ij,t+1} \mid \mathcal{F}_{ijt}\big] = p^{*}_{ijt}. \tag{4}$$

Essa identidade é uma propriedade do preditor probabilístico ideal. Não implica que o probe ajustado seja uma martingala, que a confiança cresça monotonamente em cada trajetória ou que a AUC estimada aumente a cada checkpoint.

### 3.2 Transformers, espaço latente e extração causal

#### *3.2.1 Representações e atenção causal*

Um Transformer representa tokens por vetores e aplica sucessivos blocos de atenção e transformações não lineares (Vaswani et al., 2017). Em notação esquemática, para uma matriz de estados $H$, uma cabeça de atenção calcula

$$Q = HW_Q, \quad K = HW_K, \quad U = HW_U, \tag{5}$$

$$\mathrm{Attn}(H) = \mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}} + M\right)U. \tag{6}$$

A máscara causal $M$ impede que uma posição consulte tokens posteriores. Conexões residuais, normalizações e transformações feed-forward produzem estados contextualizados. O espaço latente é o espaço vetorial dessas representações, com dimensão determinada pela arquitetura. Não é um espaço de significados com coordenadas semanticamente nomeadas por definição.

O estado $h_{ij\ell t} \in \mathbb{R}^d$ é uma função do prompt e do prefixo processado. Para um modelo determinístico em modo de avaliação,

$$h_{ij\ell t} = f_{\theta,\ell}\big(x_i, Y_{ij,1:t}\big). \tag{7}$$

A aleatoriedade da representação decorre principalmente da amostragem de tokens; pesos e procedimento de extração permanecem constantes. A investigação de padrões lineares nesses vetores testa acessibilidade do sinal a uma classe de decodificadores simples.

### *3.2.2 Convenção temporal e alinhamento*

O checkpoint $t = 0$ corresponde ao último token do prompt. Para $t > 0$, o estado é extraído após processar o token $t$ da completion, e não o estado que foi usado para amostrar esse token. Em um decodificador autoregressivo, os logits usados para amostrar $Y_t$ dependem do prefixo que termina em $Y_{t-1}$; o estado de $Y_t$ participa da predição seguinte. Confundir essas posições produz um deslocamento de um token e invalida a interpretação temporal.

Um pipeline que para imediatamente depois de amostrar $Y_t$ pode ainda não ter calculado o seu estado. É necessário processá-lo, sem amostrar $Y_{t+1}$, para decidir a interrupção. Esse forward adicional ou antecipado deve ser incluído na latência e no custo de operação. Contar $t$ tokens gerados continua correto, mas não contabiliza sozinho todo o trabalho do Transformer.

### *3.2.3 Propriedade do estado anterior à amostragem*

> **Proposição 1 — Ausência de discriminação antes da divergência**
> Com prompt, template, pesos e execução determinística fixados, o estado do último token do prompt é igual entre tentativas da mesma tarefa. Qualquer score determinístico calculado apenas desse estado também é constante dentro da tarefa.

**Demonstração.** Para todo $j$, $h_{ij\ell 0} = f_{\theta,\ell}(x_i)$. Logo, $z_{ij0} = g\big(f_{\theta,\ell}(x_i)\big)$ independe de $j$. Cada comparação entre uma tentativa correta e uma incorreta da tarefa resulta em empate. Uma AUC que atribui peso $\frac{1}{2}$ aos empates vale $\frac{1}{2}$ dentro dessa tarefa.

Esse resultado não impede que `prompt_last` apresente boa AUC entre tarefas. Ele o torna um baseline de dificuldade e um controle de integridade: diferenças relevantes entre repetições do mesmo prompt precisam ser explicadas por mudanças de entrada, dropout, extração incorreta ou não determinismo numérico. Não devem ser interpretadas como previsão da seed futura.

### *3.2.4 Teste de ausência de informação futura*

Para cada camada e posição selecionadas, compare a extração usando apenas o prefixo e a extração na mesma posição de uma passagem sobre a sequência completa:

$$h_{\ell,t}(x, y_{1:t}) \approx h_{\ell,t}(x, y_{1:T}). \tag{8}$$

A igualdade é esperada matematicamente sob atenção causal. Diferenças numéricas podem decorrer de precisão e kernels. O teste deve fixar tolerância absoluta e relativa, modo de

avaliação, backend e convenção de normalização. Uma falha exige diagnóstico antes de usar as ativações. Este é um teste de integridade da causalidade temporal da arquitetura, não uma demonstração de que uma direção latente causa corretude.

#### *3.2.5 Alcance informacional do estado interno*

Se $H = f_\theta(X, P)$, em que $P$ é o prefixo completo e o modelo é fixado, então $H$ não acrescenta informação aleatória quando $(X, P)$ já é integralmente conhecido. Em notação de informação mútua,

$$I(S; H \mid X, P) = 0. \tag{9}$$

A utilidade do estado está em representar o prefixo de modo que certas propriedades se tornem acessíveis a um preditor limitado. Assim, um ganho sobre NLL e entropia sustenta a afirmação de ganho sobre essas estatísticas, e não sobre todo método possível baseado no texto. Essa restrição impede transformar um resultado de probing em uma alegação excessiva sobre introspecção.

### 3.3 Dificuldade da tarefa e sinal específico da trajetória

#### *3.3.1 Heterogeneidade entre problemas*

A probabilidade $\pi_i$ varia com a tarefa e a configuração. Em um banco com $n_i$ tentativas, a proporção $\hat{\pi}_i = \sum_j \frac{S_{ij}}{n_i}$ é uma estimativa descritiva dessa probabilidade. Uma tarefa sem sucessos observados não possui necessariamente probabilidade verdadeira zero; a amostra pode simplesmente não ter encontrado sua região de soluções corretas.

Para descrição do banco, definem-se três categorias mutuamente exclusivas: todas as tentativas corretas, resultados mistos e todas as tentativas incorretas. Esses nomes se referem aos resultados observados. Não autorizam afirmar que o modelo sempre acertará ou nunca resolverá o problema.

O número de tentativas influencia a classificação. Sob amostragem independente e $n$ tentativas, a probabilidade de observar resultados mistos é

$$P(\text{mista} \mid \pi_i, n) = 1 - \pi_i^n - (1 - \pi_i)^n. \tag{10}$$

Assim, a análise entre tarefas mistas representa principalmente problemas com variabilidade detectável nesse orçamento. Não é uma amostra aleatória de todos os problemas de programação.

#### *3.3.2 Decomposição da associação*

Para um score $Z$ e o indicador $S$, a lei da covariância total fornece

$$\mathrm{Cov}(Z, S) = \mathrm{Cov}(E[Z|X], E[S|X]) + E[\mathrm{Cov}(Z, S|X)]. \tag{11}$$

O primeiro termo captura a associação entre tarefas; o segundo, a associação dentro da tarefa. A decomposição é conceitual e não uma decomposição da AUC. Ela mostra por que uma associação agregada pode ser explicada inteiramente pela dificuldade do prompt.

Como exemplo estritamente ilustrativo, considere duas tarefas: uma com 90% de acertos e outra com 10%. Um score constante igual a 0,9 para a primeira e 0,1 para a segunda pode ordenar bem exemplos agregados. Entretanto, não distingue qual tentativa acertará dentro de nenhuma das tarefas. Nenhum desempenho numérico desse exemplo é um resultado do modelo estudado.

### *3.3.3 Discriminação dentro da tarefa*

Sejam $\mathcal{P}_i$ e $\mathcal{N}_i$ os conjuntos de tentativas corretas e incorretas elegíveis da tarefa $i$. Define-se a AUC intratarefa por

$$\mathrm{AUC}_i = \frac{1}{|\mathcal{P}_i|\ |\mathcal{N}_i|} \sum_{j \in \mathcal{P}_i} \sum_{k \in \mathcal{N}_i} \psi\big(z_{ij} - z_{ik}\big), \tag{12}$$

em que $\psi(a)$ vale 1 se $a > 0$, $\frac{1}{2}$ se $a = 0$ e 0 se $a < 0$. A média por tarefas mistas é

$$\text{WT-AUC} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \mathrm{AUC}_i. \tag{13}$$

Cada tarefa informativa recebe o mesmo peso. Uma média por todos os pares de candidatos daria maior peso a tarefas com mais pares positivo-negativo; seria outro estimando. A unidade principal de inferência é a tarefa, mesmo que milhares de pares sejam construídos a partir dela.

Tarefas com apenas uma classe não têm AUC intratarefa definida. Elas continuam nas métricas probabilísticas e operacionais. A exclusão da WT-AUC deve ser acompanhada dos respectivos denominadores, para que um resultado elevado em poucas tarefas não pareça representar todo o benchmark.

### *3.3.4 Informação incremental e hipótese operacional*

Seja $B_{ijt}$ um vetor fixado de características observáveis do prefixo. Compare um modelo que usa apenas $B$ com outro que combina $B$ e a ativação. Os estimandos centrais são

$$\Delta_W = \text{WT-AUC}_{H+B} - \text{WT-AUC}_B, \tag{14}$$

$$\Delta_L = \mathrm{LogLoss}_{H+B} - \mathrm{LogLoss}_B. \tag{15}$$

Valores positivos de $\Delta_W$ e negativos de $\Delta_L$ indicam ganho, mas os dois critérios avaliam propriedades diferentes: ordenação dentro da tarefa e qualidade de previsão probabilística. Um ganho robusto sustenta a utilidade incremental da representação para a classe de modelos comparada. Não demonstra independência condicional universal nem que todos os fatores semânticos ou estilísticos foram controlados.

A hipótese nula de ausência de qualquer sinal dentro da tarefa, $S$ independente de $Z$ dado $X$, difere da hipótese de ausência de informação adicional sobre $B$, isto é, $S$ independente de $Z$ dado $(X, B)$. Essa distinção orienta a interpretação dos testes estatísticos posteriores.

## 3.4 Amostragem repetida, seleção e custo

### *3.4.1 Cobertura e pass@k*

Para $N$ candidatos, a cobertura da tarefa é

$$A_i(N) = \mathbf{1}\{\exists j \leq N : S_{ij} = 1\}. \tag{16}$$

Sob tentativas independentes e identicamente distribuídas condicionalmente à tarefa,

$$P(A_i(N) = 1 | x_i) = 1 - (1 - \pi_i)^N. \tag{17}$$

O ganho de passar de $N-1$ para $N$ tentativas é $\pi_i(1-\pi_i)^{N-1}$, que decresce quando $0 < \pi_i < 1$. Essa expressão não deve ser aplicada após substituir $\pi_i$ por uma taxa global sem considerar heterogeneidade: em geral, a média das coberturas por tarefa difere da cobertura calculada com a média das probabilidades.

Com $n$ candidatos e $c_i$ aprovados, o estimador usual de pass@k é (Chen et al., 2021)

$$\widehat{\text{pass@k}}_i = 1 - \frac{\binom{n-c_i}{k}}{\binom{n}{k}}, \quad k \leq n. \tag{18}$$

Esse estimador descreve a probabilidade de incluir um sucesso em um subconjunto de tamanho $k$. Já a resolução observada dos primeiros $k$ candidatos é $\mathbf{1}\left\{\sum_{j=1}^{k} S_{ij} > 0\right\}$. Ambos são úteis, mas não são números intercambiáveis. O replay operacional preserva uma ordem de tentativas e utiliza o segundo objeto.

### *3.4.2 Terminologia: Best-of-N e verificador*

"Best-of-N" frequentemente descreve gerar candidatos e escolher o melhor segundo um score. Neste documento, o baseline operacional é mais precisamente **amostragem repetida com verificador e parada no primeiro sucesso**. Ele é denominado BoN com verificador por continuidade com o projeto, com essa definição explícita.

A suíte completa de testes é acessada pela política apenas quando um candidato termina. Esse acesso representa um cenário de verificação forte: o programa não recebe os testes ocultos no prompt, mas o controlador pode utilizá-los para decidir a parada. Isso difere da seleção em produção, na qual os testes disponíveis podem ser incompletos. As conclusões operacionais devem ser limitadas a esse cenário, ou acompanhadas futuramente de uma separação entre testes de seleção e de avaliação final.

### *3.4.3 Custo até sucesso ou esgotamento*

Defina $K_i = \min\{j : S_{ij} = 1\}$, adotando $K_i = \infty$ quando não há sucesso no banco. O custo do baseline até o primeiro sucesso ou limite $N$ é

$$C_i^V(N) = \sum_{j=1}^{N} T_{ij} \mathbf{1}\{K_i \geq j\}. \tag{19}$$

Tarefas não resolvidas contribuem com o custo de todas as tentativas iniciadas. Excluir essas tarefas do custo médio favoreceria políticas que simplesmente desistem de problemas difíceis.

A métrica primária de custo é tokens de completion por tarefa, $\overline{C} = \sum_i \frac{C_i}{m}$. Uma métrica secundária é o custo agregado por tarefa resolvida,

$$C_{\text{por solução}} = \frac{\sum_i C_i}{\sum_i A_i}, \tag{20}$$

que fica indefinido se nenhuma tarefa for resolvida. Ela inclui no numerador o custo das tarefas sem sucesso. Não é a média do custo apenas entre tarefas que tiveram sucesso.

### *3.4.4 Retenção de candidatos e efeito sobre resolução*

Considere uma política que mantém um candidato com indicador $R_{ij}$, com $R = 1$ para candidatos que terminaram naturalmente antes da decisão. O sucesso útil é $S_{ij}R_{ij}$. Para $\pi_i > 0$, defina $r_i = P(R = 1|S = 1, x_i)$, e defina $a_i = P(R = 1|x_i)$. Se $\pi_i = 0$, a retenção condicionada ao sucesso não é identificável, mas a probabilidade de sucesso útil é zero sem precisar defini-la.

Sob tentativas independentes e a mesma regra por tentativa,

$$P(SR = 1|x_i) = \pi_i r_i, \tag{21}$$

$$P(A_i^{\pi}(N) = 1|x_i) = 1 - (1 - \pi_i r_i)^N. \tag{22}$$

A precisão entre candidatos mantidos é $P(S = 1|R = 1, x_i) = \pi_i \frac{r_i}{a_i}$, quando $a_i > 0$. Essa precisão pode crescer mesmo quando a cobertura com orçamento fixo diminui. Portanto, "maior fração de acertos entre os mantidos" não basta como evidência de melhoria do sistema.

> **Proposição 2 — Limite da interrupção no mesmo banco**
> Quando a política usa exatamente os mesmos $N$ candidatos potenciais e só pode descartá-los, seu conjunto de sucessos é subconjunto do conjunto de sucessos do baseline. Logo, $A_i^{\pi}(N) \leq A_i^{V}(N)$ para cada tarefa.

**Demonstração.** Se um sucesso é encontrado pela política, o candidato correspondente está no banco original e também passa no verificador do baseline. A política não cria novos candidatos além do limite e não altera o conteúdo dos mantidos. Assim, não pode resolver uma tarefa que nenhum dos $N$ candidatos originais resolvia.

O ganho esperado nesse regime é reduzir custo com perda pequena ou nula de resolução. Para superar cobertura em um mesmo orçamento de tokens, seria necessário reinvestir a economia em novas tentativas, com um banco maior e uma comparação própria. Essa extensão não integra o experimento principal.

### *3.4.5 Condição econômica para interromper*

Uma política pode economizar tokens em um candidato e aumentar o custo total da tarefa ao eliminar um sucesso precoce, forçando outras tentativas. Por isso, o custo do replay não é necessariamente monotônico no limiar de interrupção.

Sob tentativas iid por tarefa, seja $D$ o custo de uma tentativa sob a política e $s = \pi_i r_i$ sua probabilidade de sucesso útil. Como iniciar uma tentativa depende dos resultados anteriores, independentes da tentativa atual,

$$E[C_i^{\pi}(N)|x_i] = E[D|x_i] \sum_{j=0}^{N-1} (1-s)^j. \tag{23}$$

Para $s > 0$, a soma vale $\frac{1-(1-s)^N}{s}$; para $s = 0$, vale $N$. Essa expressão mostra que a redução do custo por tentativa deve compensar a possível redução na probabilidade de sucesso por tentativa. A análise empírica usa os caminhos efetivos do banco e não depende de estimar $\pi_i$ para substituir nessa fórmula.

### *3.4.6 Derivação, limite ilimitado e retenção ativa*

Para explicitar as hipóteses, condicione em $x_i$ e suponha que os pares $\big(D_j, S_j R_j\big)$ sejam identicamente distribuídos e independentes entre tentativas. Permite-se dependência entre custo e sucesso da **mesma** tentativa. Se $I_j$ indica que as tentativas anteriores não produziram sucesso mantido, então $I_j$ é independente de $D_j$, e

$$E\big[D_j I_j \mid x_i\big] = E[D|x_i] P\big(I_j = 1 | x_i\big) = d_i (1 - \pi_i r_i)^{j-1}. \tag{24}$$

Somar essas identidades demonstra a expressão anterior sem impor que candidatos corretos e incorretos tenham o mesmo comprimento. A hipótese falha se o controlador adapta prompts, seeds, amostragem ou sua regra com base nas tentativas anteriores. O replay preserva ordem e configuração, mas o banco finito não prova que as tentativas de uma aplicação futura sejam iid.

Se $\pi_i > 0$, $r_i > 0$ e os custos médios são finitos, o limite com tentativas ilimitadas é

$$E\Big[C_i^{\pi(\infty)} | x_i\Big] = \frac{d_i}{\pi_i r_i}, \quad E\Big[C_i^{V(\infty)} | x_i\Big] = \frac{\tau_i}{\pi_i}, \quad \tau_i = E[T|x_i]. \tag{25}$$

Logo, a interrupção reduz o custo esperado nesse limite precisamente quando

$$\frac{d_i}{\tau_i} < r_i. \tag{26}$$

Trata-se de uma consequência algébrica conhecida de uma soma geométrica, não de um teorema inédito. Se $\pi_i r_i = 0$, o tempo até sucesso não é finito e não se aplica essa comparação de razões. Nenhum sucesso em vinte tentativas tampouco demonstra que a probabilidade verdadeira seja zero.

Para orçamento finito, escreva $G_{N(s)} = \sum_{j=0}^{N-1} (1-s)^j$. A condição de menor custo é $\frac{d_i}{\tau_i} < \frac{G_{N(\pi_i)}}{G_{N(\pi_i r_i)}}$, enquanto a cobertura é $1 - (1 - \pi_i r_i)^N$. Quando $N = 1$, economizar em candidatos é suficiente para reduzir custo; ao aumentar $N$, os sucessos perdidos pesam mais. Menor custo finito pode refletir abandono de soluções e precisa ser examinado junto à resolução, sem interpretação automática de eficiência.

A retenção $r_i$ dessas equações é **global**, incluindo sucessos terminados antes do gate. Se $a_i^+ = P(T > t|S = 1, x_i)$ e $r_i^{\text{ativo}}$ é a retenção entre corretos ativos, então

$$r_i = 1 - a_i^+(1 - r_i^{\text{ativo}}). \tag{27}$$

Portanto, substituir indiscriminadamente recall ativo por $r_i$ altera o modelo econômico. A análise empírica explicita os dois denominadores. Se $a_i^+ = 0$, o recall ativo não é identificável e os corretos terminam antes do gate, de modo que $r_i = 1$; a identidade anterior se aplica diretamente quando $a_i^+ > 0$.

Finalmente, sob heterogeneidade entre tarefas, o custo populacional é $E_X[d_X G_{N(\pi_X r_X)}]$. Em geral ele não coincide com $E_{X[d_X]} G_{N\left(E_{X[\pi_X]} E_{X[r_X]}\right)}$. A média agregada de acertos não pode substituir as probabilidades condicionais nessa expressão não linear. Overheads de prefill, gate e verificação devem ser acrescidos ao custo por tentativa na mesma unidade, preservando sua dependência com o caminho. Um tempo de probe não é uma quantidade de tokens sem hipótese de conversão explicitada e validada; as medições deste estudo mantêm essas unidades separadas.

### *3.4.7 Oracle retrospectivo e alcance do limite econômico*

O oracle idealizado conhece $S_{ij}$, interrompe todos os incorretos ativos em um checkpoint fixo $t$ e mantém todos os corretos. Usa a mesma ordem e para no primeiro sucesso. Em cada tarefa, seu custo é no máximo o do verificador e sua resolução é idêntica. Entre políticas no mesmo checkpoint que preservam **todos** os candidatos corretos, ele minimiza o custo nesse caminho: nenhuma delas pode cobrar menos que $t$ por um incorreto ainda ativo ou menos que o comprimento completo do primeiro sucesso mantido.

Esse limite é condicional às restrições descritas. Uma política que descarta sucessos pode, em certos caminhos, custar menos que esse oracle e perder cobertura, ou alcançar depois um sucesso mais curto. O oracle não é limite inferior universal para toda política de inferência nem é implementável online. Sua utilidade é separar o espaço econômico disponível da capacidade real de identificar candidatos descartáveis sem conhecer seus rótulos finais.

### *3.4.8 Tokens, latência e fronteira custo–resolução*

Tokens gerados são uma medida auditável de trabalho de decodificação, mas não equivalem a FLOPs, energia ou tempo. Prefill, comprimento do contexto, cache, extração de estados, cálculo de entropia, transferência GPU–CPU, inferência do probe e verificação têm custos próprios. Os resultados devem distinguir economia de tokens e aceleração medida em execução.

Uma política domina outra no plano descritivo se tem resolução ao menos igual e custo não maior, com uma desigualdade estrita. Na presença de incerteza amostral, a comparação deve reportar diferenças pareadas e intervalos. A fronteira apresentada corresponde às políticas e limiares previamente definidos; não representa a fronteira ótima global de todos os algoritmos possíveis.

# 4 METODOLOGIA

A implementação revisada segue o protocolo v0.2, de 12 de outubro de 2026. As regras a seguir definem o experimento principal executado. Resultados e auditorias aparecem no capítulo empírico. O registro histórico mantém a aprovação do orientador pendente para v0.2; a revisão da extensão foi depois informada pelo estudante. Execução autorizada e validação técnica não equivalem a pré-registro independente. A reanálise histórica e as extensões posteriores são identificadas separadamente e não alteram os endpoints definidos antes do banco principal.

## 4.1 Desenho experimental e construção dos dados

### *4.1.1 Modelo e ambiente*

O modelo principal utilizado é Qwen2.5-Coder-1.5B-Instruct, integrante de uma família especializada em código (Hui et al., 2024). Os manifestos registram identificador completo, revisão imutável dos pesos, tokenizer, template de chat, precisão e backend. A escolha da variante Instruct é específica; não deve ser substituída silenciosamente pela variante base.

A viabilidade na RTX 3050 foi medida no piloto e nas sessões de coleta, com batch 1, BF16 nos pesos e projeções FP32. Não foi usada quantização. Geração e extração preservam a mesma condição numérica. Alterar precisão, quantização ou backend exigiria outra condição experimental, com validação e proveniência próprias.

### *4.1.2 Benchmark principal e unidade de generalização*

HumanEval+ é o benchmark principal, avaliado pelo EvalPlus. O snapshot utilizado contém 164 tarefas, com identificadores e hash nos manifestos. A avaliação de generalização separa tarefas, não apenas tentativas. Problemas semelhantes identificados antes dos resultados precisariam compartilhar um grupo; o desenho efetivamente usado agrupa por task_id e não certifica ausência de similaridade semântica entre tarefas.

O acesso prévio a algumas tarefas para desenvolvimento não desaparece com a geração de novas seeds. Tarefas usadas para decisões de método devem ser registradas como desenvolvimento. O particionamento verifica a generalização a prompts retidos dentro do benchmark, não certifica ausência de contaminação do benchmark no pré-treinamento do modelo.

### *4.1.3 Piloto e congelamento*

O planejamento reserva 32 tarefas, selecionadas deterministicamente pelo hash de `protocol-v0.1-pilot:` concatenado a `task_id`, para desenvolvimento. As demais 132 tarefas constituem o conjunto da avaliação principal. As 32 tarefas não entram nos folds de teste. O histórico de geração prévia em 26 das outras tarefas é declarado; o estudo não presume que essas tarefas fossem desconhecidas do pesquisador. Nenhuma exclusão é feita com base no desfecho observado.

O piloto testa temperaturas 0,6, 0,8 e 1,0, com top-p igual a 0,95, dez tentativas por tarefa e limite inicial de 512 tokens. A finalidade é verificar execução, quantidade de tarefas mistas, taxas de truncamento e custo. AUC de probes não deve ser usada para escolher a temperatura.

A regra proposta privilegia o número de tarefas mistas, com taxa agregada de aprovação entre 10% e 90%; empates são resolvidos por taxa mais próxima de 50%, menor comprimento médio e menor temperatura.

O aumento material foi fixado em cinco pontos percentuais acima da menor taxa combinada de sintaxe inválida, extração vazia ou truncamento entre temperaturas. A regra previa revisão anterior à análise principal caso nenhuma configuração fosse elegível. A seleção efetiva usou o piloto completo e escolheu temperatura 1,0, sem usar AUC dos probes.

### *4.1.4 Banco de candidatos*

A configuração definitiva utilizou 20 tentativas para cada tarefa principal. Com 132 tarefas, o banco completo contém 2.640 trajetórias. As ativações e estatísticas foram extraídas desse mesmo banco. Gerar bancos distintos para cada método acrescentaria variação de candidatos à comparação dos métodos.

Cada tentativa tem seed própria, derivada de uma função hash documentada do protocolo, versão do benchmark, tarefa e índice da tentativa, convertida para o intervalo aceito pelo gerador. Deve-se verificar colisões na conversão. A seed é reinicializada antes de cada tentativa, de modo que interromper uma amostra anterior não altere o fluxo aleatório da seguinte.

A independência estatística entre amostras é uma aproximação do desenho de seeds e do decodificador. A reprodutibilidade bit a bit depende também do hardware e das bibliotecas. O banco arquivado, com hashes, é a referência empírica; uma seed isolada não substitui a preservação dos candidatos.

### *4.1.5 Contrato dos registros*

Cada registro contém identificação de tarefa e tentativa, seed, prompt exato, IDs de tokens, completion bruta, código extraído, critério de término, rótulo funcional, classe de erro, custos e referências para as features. O manifesto global contém modelo, tokenizer, benchmark, verificador, versões, configuração, commit e hashes.

Quadro 4: Grupos de dados preservados por tentativa para reprodução e auditoria.

| Grupo de dados | Campos essenciais |
|---|---|
| Identidade | `run_id`, `task_id`, `attempt_id`, `seed`, versões do protocolo e do banco. |
| Geração | Prompt e template, tokens, texto bruto, parâmetros, motivo de parada, comprimento e tempo. |
| Verificação | Código extraído, aprovação, tipo de falha, versão da suíte e tempo de execução. |
| Preditores | Camada, checkpoint, ponto de hook, risco ativo, NLL, entropia e caminho/hash das ativações. |
| Proveniência | Commit, revisões imutáveis, hardware, precisão, dependências e integridade dos arquivos. |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Tentativas duplicadas em conteúdo são preservadas se resultam da amostragem prevista. Não se elimina uma solução porque ela parece repetitiva, trivial ou longa. Remoção por corrupção

deve conservar o registro da causa e os totais antes e depois. Falhas do programa gerado e falhas da infraestrutura são categorias distintas.

#### *4.1.6 Verificação funcional e limites de execução*

O código gerado é avaliado pelo checker oficial em subprocessos POSIX/WSL, com seus limites de tempo e memória e o mecanismo reliability_guard. Esse mecanismo desabilita algumas operações, mas o próprio EvalPlus esclarece que não constitui um sandbox de segurança. A implementação utilizada não comprova isolamento de rede ou ausência de credenciais do ambiente; essas propriedades não são reivindicadas. Reexecuções preservam os mesmos limites do checker, e diferenças de ambiente ou flutuações precisam ser diagnosticadas como possíveis alterações de mensuração.

O parser de completion para código é determinístico e definido antes da avaliação. Regras para remover cercas Markdown, tratar prefixos e extrair funções não podem variar após a inspeção de exemplos que falharam. Alterar o parser muda o experimento e exige versionar os rótulos.

### 4.2 Preditores precoces e modelos estatísticos

#### *4.2.1 Checkpoints e conjunto sob risco*

Foram avaliados os checkpoints 0, 8, 16, 32 e 64 tokens; a representação final é uma referência tardia. O endpoint principal predefinido é 32 tokens. As outras posições descrevem a evolução temporal e participam da escolha interna da política operacional.

A ordem da decisão é: primeiro verificar se a geração terminou; se terminou, encaminhar ao verificador; caso contrário, avaliar a regra de interrupção. Assim, para uma decisão depois de $t$ tokens, o conjunto sob risco é

$$\mathcal{R}_t = \{(i, j) : T_{ij} > t\}. \tag{28}$$

O uso da desigualdade estrita evita classificar como abortada uma completion que terminou exatamente no checkpoint. Um estado existente em $T = t$ pode ser usado em uma análise descritiva separada, mas já não corresponde à mesma decisão de continuação. Gerações curtas não são preenchidas com zeros nem recebem uma ativação futura fictícia.

As curvas em diferentes checkpoints condicionam em conjuntos diferentes. Deve-se reportar, em cada ponto, candidatos ativos, tarefas representadas, tarefas mistas e prevalência. Uma análise descritiva adicional sobre o conjunto comum que permanece ativo até 64 tokens ajuda a distinguir mudança de população e mudança de informação; ela representa essa população restrita, e não todo o benchmark.

#### *4.2.2 Camadas e convenção do estado*

As quatro profundidades candidatas correspondem aos blocos mais próximos de 25%, 50%, 75% e 100% da profundidade. Os índices são calculados uma vez, registrados e deduplicados

se necessário. O manifesto especifica se o vetor corresponde à saída residual do bloco antes ou depois de normalização. O embedding inicial não conta como bloco Transformer.

A captura reproduz o estado disponível na inferência incremental. Salvar todas as ativações de todos os tokens não é requisito: foram preservados os vetores selecionados, tokens e metadados, reduzindo o armazenamento. O banco completo permite avaliar os desfechos potenciais; na validação online, a política obteve seus estados no checkpoint e abortou sem executar a continuação descartada.

### *4.2.3 Estatísticas observáveis*

Sejam $a_{u,v}$ os logits do token $v$ no passo $u$. A distribuição bruta é $p_u(v) = \mathrm{softmax}(a_u)_v$. O decodificador aplica temperatura, seleção do núcleo e renormalização para produzir $q_u$. A probabilidade bruta e a efetivamente amostrada são objetos diferentes.

Para a distribuição de amostragem, definem-se

$$\mathrm{NLL}_u = -\log q_u(Y_u), \quad \mathrm{Ent}_u = -\sum_{v:q_u(v)>0} q_u(v) \log q_u(v). \tag{29}$$

Até $t$, as características principais incluem média de NLL, NLL do último token, média de entropia, entropia máxima e média da diferença entre os dois maiores logits. Para esta última, usam-se os logits finitos antes do top-p, após a escala de temperatura, evitando uma margem infinita quando o filtro deixa apenas um token. A base do logaritmo é natural e a unidade é nat.

A logprobabilidade do prefixo é $\sum_{u=1}^{t} \log q_u(Y_u)$. Em um checkpoint fixo, ela é uma transformação linear da NLL média; incluir ambas não cria uma fonte independente de informação. O comprimento final, o tempo total futuro e o resultado dos testes nunca entram em features precoces. O número de tokens $t$ também é constante em uma análise de checkpoint fixo.

Comprimento do prompt e da assinatura são controles de tarefa. Se a assinatura não puder ser extraída com regra confiável, seu indicador de ausência é registrado. Estatísticas equivalentes da distribuição bruta podem ser uma análise de sensibilidade previamente definida, porque entropia após top-p depende do filtro de amostragem.

### *4.2.4 Baselines e modelo principal*

Quadro 5: Famílias de preditores e variáveis disponíveis em cada comparação.

| Modelo | Informação utilizada |
|---|---|
| B0 — Prior | Prevalência do treino, sem rótulos de outras tentativas da tarefa de teste. |
| B1 — Prompt | Comprimento e atributos observáveis do prompt. |
| P — Estado inicial | Representação `prompt_last`; baseline de variação entre tarefas. |
| B — Observáveis | Atributos do prompt e estatísticas de confiança do prefixo. |
| H — Latente | Estado interno de uma camada e posição escolhidas no treino. |
| H+B — Combinado | Estado interno concatenado aos mesmos observáveis usados por B. |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

B, H e H+B utilizam o mesmo tipo de classificador principal: regressão logística com regularização L2. O número de hiperparâmetros e o critério de seleção são controlados. B deve receber seu próprio ajuste de regularização no treino, para que H+B não vença um baseline deliberadamente subajustado.

### *4.2.5 Probe linear e função objetivo*

Para um vetor de features $a$, o probe define

$$z = b + w^{\top} a, \quad \hat{p} = \sigma(z) = \frac{1}{1 + \exp(-z)}. \tag{30}$$

Se a tarefa $i$ contribui com $n_i$ tentativas elegíveis, cada tentativa recebe peso proporcional a $\frac{1}{n_i}$. Uma forma da função objetivo é

$$J(b, w) = \frac{1}{m_{\mathrm{tr}}} \sum_{i \in \mathcal{I}_{\mathrm{tr}}} \frac{1}{n_i} \sum_{j} \ell\big(S_{ij}, \sigma\big(b + w^{\top} a_{ij}\big)\big) + \frac{\lambda}{2} \lVert w \rVert_2^2, \tag{31}$$

com $\ell(s, p) = -s \log p - (1 - s) \log(1 - p)$. O intercepto não é penalizado. A relação exata entre $\lambda$ e o parâmetro `C` depende da normalização usada pela implementação; a configuração preserva a definição da biblioteca, sem assumir que qualquer convenção equivale numericamente a $\lambda = \frac{1}{C}$.

Padronização é ajustada apenas no conjunto de treinamento de cada split. Uma direção por diferença de médias,

$$v = \hat{\mu}_1^{\mathrm{tr}} - \hat{\mu}_0^{\mathrm{tr}}, \tag{32}$$

pode ser um diagnóstico geométrico secundário. A direção e sua orientação são construídas exclusivamente com rótulos de treino. Separação visual em projeções escolhidas depois de olhar todo o banco não constitui evidência confirmatória.

### *4.2.6 Calibração e interpretação dos scores*

Uma transformação logística de calibração, $\hat{p}_{\mathrm{cal}} = \sigma(az + b)$, pode ser ajustada com previsões de desenvolvimento produzidas fora da amostra. Calibração trata a relação entre score e frequência observada de sucesso; é distinta de discriminação (Guo et al., 2017). Uma transformação estritamente crescente preserva a ordenação e a AUC.

A interrupção por limiar necessita principalmente de uma boa ordenação e de um limiar validado. Probabilidades bem calibradas facilitam interpretação e comparações, mas não são condição matemática para obter economia. O desempenho probabilístico foi reportado sem apresentar calibração como garantia de retenção de corretos em tarefas novas.

## 4.3 Validação, inferência estatística e controles

### *4.3.1 Separação por tarefa e avaliação aninhada*

As tentativas de um problema compartilham especificação e estrutura de solução. Dividi-las aleatoriamente entre treino e teste permite que o treinamento se beneficie de características do próprio problema avaliado. A separação exigida é

$$\mathcal{I}_{\mathrm{tr}} \cap \mathcal{I}_{\mathrm{te}} = \varnothing, \tag{33}$$

em que os conjuntos contêm identificadores de tarefas. As mesmas tarefas pertencem ao mesmo fold em todos os checkpoints e métodos. Não se refaz o particionamento para obter uma distribuição mais favorável de rótulos depois dos resultados.

Utiliza-se avaliação externa com cinco folds agrupados e validação interna com três folds agrupados dentro de cada treino externo. A camada e `C` são selecionados internamente. O risco de sobreajuste ao critério de seleção motiva a separação entre seleção e avaliação (Cawley; Talbot, 2010). Todos os passos dependentes dos dados, inclusive padronização e construção de direções, são repetidos no treino correto.

O conjunto candidato de regularização é $C \in \{0.001, 0.01, 0.1, 1, 10\}$. No endpoint científico de 32 tokens, a posição não é selecionada. Para cada modelo, o critério interno principal é log loss médio por tarefa. Dentro de uma faixa de um erro-padrão do melhor valor interno, usa-se maior regularização e depois camada mais rasa. O erro-padrão para essa regra é uma heurística de seleção, não um intervalo de confiança do resultado final.

O objeto avaliado pela validação externa é o procedimento que escolhe, treina e aplica um modelo usando apenas tarefas de treino. As camadas selecionadas podem variar entre folds. Não se deve apresentar a melhor camada encontrada posteriormente em todo o banco como se tivesse sido definida antecipadamente.

### *4.3.2 Predições fora da amostra e calibração interna*

Cada candidato principal recebe uma previsão de um modelo que não treinou em sua tarefa. A concatenação dessas previsões permite calcular métricas sobre o conjunto externo completo. As escolhas continuam restritas ao interior de cada treino externo.

Para calibrar e selecionar a política, obtêm-se scores internos fora da amostra. Quando a seleção de hiperparâmetros participa desse processo, ela também precisa ocorrer sem o fold interno cujos scores estão sendo produzidos, ou os scores devem ser tratados apenas como dados de desenvolvimento com viés de seleção. A implementação v0.2 produz scores por cross-fitting da seleção inteira: cada partição pontuada é excluída também da escolha de camada e regularização. O calibrador é ajustado nesses scores; calibrador e limiar continuam sendo ajustes de desenvolvimento avaliados integralmente em tarefas externas.

Calibrador e limiar podem ser ajustados nos dados de desenvolvimento desde que todo o sistema seja avaliado depois em tarefas externas intocadas. O recall obtido nesse conjunto de ajuste é uma meta empírica, sujeita a otimismo por seleção. Para reivindicar uma certificação de

recall, seria necessário um conjunto independente de certificação e um procedimento de inferência adequado à dependência entre tentativas; o presente desenho não faz essa reivindicação.

### *4.3.3 Métricas probabilísticas e de ranking*

As métricas principais de probabilidade são log loss e Brier, com peso igual por tarefa:

$$\text{LogLoss} = \frac{1}{m}\sum_{i}\frac{1}{n_i}\sum_{j}\ell\big(S_{ij},\hat{p}_{ij}\big), \tag{34}$$

$$\text{Brier} = \frac{1}{m}\sum_{i}\frac{1}{n_i}\sum_{j}\big(\hat{p}_{ij}-S_{ij}\big)^2. \tag{35}$$

Para estabilidade numérica, probabilidades usadas em logaritmos são limitadas a $[\varepsilon, 1-\varepsilon]$, com $\varepsilon$ documentado e idêntico entre métodos. A AUC agregada é reportada como diagnóstico entre candidatos, acompanhada da WT-AUC. O resumo de precisão-revocação utiliza average precision (AP), com implementação declarada; a denominação genérica PR-AUC não deve esconder a diferença entre AP e integração trapezoidal.

Curvas de calibração descrevem a relação entre probabilidade prevista e frequência observada. O número de bins e a regra de particionamento são fixados. ECE é secundário porque depende desses bins e pode ser instável na amostra pequena. A análise não se limita a acurácia com limiar 0,5, que pode ser pouco informativa para a política de alta retenção.

### *4.3.4 Bootstrap por tarefa e alcance dos intervalos*

Para estimar incerteza, reamostram-se tarefas inteiras com reposição, preservando todas as suas tentativas, scores e resultados de políticas. Usam-se os mesmos índices reamostrados para comparar os métodos. Em cada réplica, recomputam-se as métricas e as diferenças. O número utilizado é 2.000 réplicas com seed fixada, produzindo intervalos percentílicos de 95%.

Na WT-AUC, reamostrar apenas as tarefas mistas estima a incerteza condicional a esse subconjunto; nas métricas de resolução e custo, reamostra-se todo o conjunto principal. A opção e seu denominador são explicitados. Réplicas sem classes necessárias não recebem valor zero artificialmente; são contadas como indefinidas.

O bootstrap dos scores externos já calculados trata os ajustes como fixos. Como os modelos dos folds compartilham dados de treino, esses intervalos são aproximações para a variabilidade entre tarefas e não capturam integralmente a instabilidade de retreinar todo o procedimento. A incerteza reportada é condicional aos modelos ajustados. Uma análise de repetição agrupada de todo o ajuste exigiria dimensionamento próprio e não foi realizada.

### *4.3.5 Permutações: hipótese nula e validade*

Permutações avaliam se o alinhamento entre features e rótulos é compatível com uma hipótese nula de intercambialidade (Ojala; Garriga, 2010). Embaralhar rótulos dentro da tarefa mantém seu número de acertos e destrói o alinhamento entre prefixos e desfechos. Esse é um controle relevante para sinal intratarefa.

Entretanto, tal embaralhamento também destrói a relação entre os observáveis $B$ e o resultado. Por isso, ele não é um teste específico da hipótese "hidden states não acrescentam nada a B". Aplicar esse procedimento ao delta H+B menos B e chamá-lo de teste de poder incremental seria uma interpretação incorreta. A análise incremental principal usa deltas pareados fora da amostra, intervalos por tarefa e perdas probabilísticas.

Há também um cuidado com os folds. Permutar todos os rótulos depois de concatenar scores OOF e tratar todos esses scores como externos a todos os rótulos ignora que o rótulo de uma tarefa pode ter sido usado para treinar scores de outros folds. Uma alternativa computacionalmente simples é o teste por fold externo:

1. Fixar o modelo e as previsões do fold $k$, sem ajustes usando seus rótulos.
2. Permutar os rótulos apenas dentro de cada tarefa ativa desse fold.
3. Calcular a WT-AUC de H+B em cada permutação, usando 10.000 repetições.
4. Obter $p_k = \frac{1+\sum_b \mathbf{1}\{M_b \geq M_{\text{obs}}\}}{10001}$, com $M$ igual à WT-AUC.
5. Combinar conservadoramente por $p_{\text{global}} = \min(1, 5 \min_k p_k)$.

A correção de Bonferroni permanece válida sem independência entre os cinco p-valores, desde que cada teste individual seja válido. Folds sem tarefas mistas recebem $p_k = 1$. Esse teste verifica ausência global de associação intratarefa no sentido definido; a combinação pode ter potência baixa. Uma alternativa é permutar rótulos dentro das tarefas e repetir integralmente treinamento e seleção a cada permutação, com custo computacional maior. A escolha deve ser congelada, sem selecionar a estratégia que produza menor p-valor.

A validade ainda pressupõe que, sob a hipótese nula, os rótulos sejam intercambiáveis entre tentativas elegíveis do mesmo problema. Amostragem com configurações distintas ou tentativas dependentes de feedback do verificador exigiria restringir os blocos de permutação ou redesenhar o teste. Este projeto usa tentativas sem realimentação entre gerações.

### *4.3.6 Efeitos fixos como análise complementar*

A regressão abaixo é uma formulação conceitual complementar; não foi ajustada como novo estimador neste estudo. A análise intratarefa efetivamente executada usa WT-AUC e os contrastes pareados definidos no protocolo.

Uma regressão com intercepto por tarefa formaliza o controle da informação constante no prompt:

$$\text{logit } P\big(S_{ij} = 1\big) = \alpha_i + \beta_B^\top B_{ijt} + \beta_z z_{ijt}. \tag{36}$$

A estimação logística condicional pode eliminar os interceptos ao condicionar no número de sucessos de cada tarefa. Tarefas sem variação de rótulo não identificam $\beta_z$. Colunas constantes dentro da tarefa, como comprimento do prompt, são absorvidas pelo efeito fixo e não precisam ser estimadas separadamente.

Essa regressão é associativa e complementar. Interceptos estimados com os rótulos das tarefas externas não constituem um preditor válido para tarefas novas. Portanto, não se usa sua log loss ajustada como melhoria fora da amostra. A comparação preditiva vem dos modelos B e H+B avaliados externamente. A incerteza de um coeficiente calculado sobre scores aprendidos deve reconhecer que esses scores também foram estimados; um erro-padrão convencional não representa automaticamente toda a cadeia de aprendizado.

#### *4.3.7 Controles negativos e diagnósticos*

O controle determinístico de `prompt_last` deve ter WT-AUC igual a 0,5 quando há empates exatos. Uma direção aleatória normalizada avalia a facilidade de obter associação aparente em alta dimensão. Um probe treinado com rótulos permutados dentro das tarefas do treino verifica se a separação depende do alinhamento real entre representação e resultado.

A direção invertida não é um controle independente contra associação: para um score sem outras mudanças, $\mathrm{AUC}(-z) = 1 - \mathrm{AUC}(z)$ com a convenção de empates. Ela serve para verificar sinal e implementação. Também não se permite usar o comprimento final como controle de uma política precoce. Indicadores de formatação já presentes no prefixo podem ser diagnósticos de artefatos; seu ajuste deve respeitar os splits.

Um desempenho não significativo de um controle não demonstra automaticamente a validade do modelo principal. Os controles se somam a uma avaliação explícita de vazamento, amostra, hipótese nula e tamanho de efeito.

#### *4.3.8 Multiplicidade e critérios de evidência*

A posição de 32 tokens e a comparação H+B contra B definem o endpoint principal. O resultado positivo de especificidade incremental requer $\Delta_W > 0$, intervalo pareado de 95% inteiramente acima de zero e $\Delta_L < 0$ fora da amostra. O intervalo de $\Delta_L$ também é reportado; se ele incluir zero, a evidência probabilística é qualificada como incerta. O teste de permutação apoia a análise de existência de sinal intratarefa, sem funcionar como teste do ganho condicional.

Curvas por posição, comparações de camadas, tipos de erro, direções geométricas e subgrupos permaneceram secundários. Seus intervalos pontuais não têm cobertura simultânea e não foram usados para selecionar uma confirmação posterior. A correção Bonferroni descrita na permutação combina os folds daquele teste; não cobre toda a extensão exploratória. Não se escolheu outro checkpoint para substituir o resultado em 32 tokens.

Não rejeitar uma hipótese nula não demonstra equivalência. Um intervalo amplo pode conter tanto ausência de efeito quanto um efeito relevante. Com poucas tarefas mistas, a conclusão apropriada pode ser “inconclusivo neste orçamento”, e não “o modelo não contém o sinal”.

## 4.4 Política de interrupção precoce e replay

### *4.4.1 Regra de decisão e casos de término*

A política utiliza um único checkpoint $t^*$ por ajuste, evitando a multiplicação de decisões dentro da mesma tentativa. Se o candidato permanece ativo nesse ponto e seu score é inferior ao limiar $q$, a geração é interrompida. Caso contrário, continua normalmente até terminar. Não há steering nem alteração da distribuição dos tokens nos candidatos mantidos.

O algoritmo por tarefa é:

1. Iniciar a tentativa seguinte com sua seed pré-atribuída.
2. Gerar até o término natural, o checkpoint ou o limite, conforme o que ocorrer primeiro.
3. Se houve término, extrair o programa, verificar e parar a tarefa se houver sucesso.
4. Se a geração segue ativa no checkpoint, calcular os preditores e o score.
5. Interromper se o score for menor que $q$; caso contrário, completar e verificar.
6. Repetir até um sucesso verificado ou até atingir $N$ tentativas iniciadas.

Uma tentativa abortada consome orçamento de tentativa. Um candidato que termina exatamente em $t^*$ vai ao verificador antes da decisão de aborto. A regra com $q$ abaixo de todos os scores representa "não interromper" e deve sempre estar incluída na seleção.

### *4.4.2 Seleção do checkpoint e do limiar*

Dentro do treino externo, avaliam-se $t \in \{8, 16, 32, 64\}$ e limiares derivados exclusivamente dos scores de desenvolvimento. O modelo de cada posição é ajustado sem usar o teste externo. A métrica de retenção relevante para o gate é

$$\hat{r}_{\text{ativo}}(t, q) = \frac{\sum_{i,j} S_{ij} \mathbf{1}\{T_{ij} > t\} \mathbf{1}\{\hat{p}_{ijt} \geq q\}}{\sum_{i,j} S_{ij} \mathbf{1}\{T_{ij} > t\}}. \tag{37}$$

Essa taxa evita que muitos sucessos curtos, nunca expostos ao gate, escondam perdas entre candidatos efetivamente avaliados. Reporta-se também a retenção global, contando sucessos que terminaram antes do checkpoint como mantidos. Se não há sucessos ativos suficientes para avaliar uma configuração, ela não é calibrável e a opção conservadora é não interromper.

A meta de desenvolvimento é $\hat{r}_{\text{ativo}} \geq 0.97$. Todos os pares checkpoint-limiar que atendem à meta são avaliados por replay de custo médio por tarefa. Escolhe-se o menor custo; empates numéricos são resolvidos por maior resolução no desenvolvimento, checkpoint mais cedo e menor limiar. Não se escolhe automaticamente o maior limiar admissível, pois abortar sucessos pode aumentar o custo até solução.

Para evitar impor um limiar pior que o baseline, a opção sem aborto participa da mesma seleção. O protocolo registra uma tolerância numérica para empates e uma grade finita de limiares, incluindo os valores nos quais a decisão muda. A política e seu calibrador ficam congelados antes da avaliação externa.

### *4.4.3 Meta empírica de recall e generalização*

A taxa de 97% é uma meta de ajuste. O recall no teste deve ser medido, e pode ser menor. Dependência dentro da tarefa, seleção do melhor limiar e mudança de distribuição impedem atribuir automaticamente uma garantia binomial simples à taxa agregada.

Ruan et al. (2026) distinguem ajuste e certificação independente em seu contexto de agentes. Esta proposta adota apenas uma restrição empírica de seleção e uma avaliação externa; não reproduz a garantia formal daquele método. Além disso, retenção de trajetórias corretas não é igual a preservação da resolução das tarefas. Perder a única solução de um problema tem efeito diferente de perder uma entre várias soluções corretas.

### *4.4.4 Replay com candidatos pareados*

O banco guarda a completion completa de cada tentativa. Para simular aborto, o replay consulta apenas features disponíveis no checkpoint e usa o resultado completo exclusivamente para avaliar o contrafactual de retenção: saber se o candidato descartado passaria. A política não acessa esse rótulo para decidir.

Defina $b_{ij} = \mathbf{1}\{T_{ij} > t^*, \hat{p}_{ijt^*} < q\}$. O custo de uma tentativa iniciada no replay é

$$d_{ij}^{\pi} = b_{ij} t^* + (1 - b_{ij}) T_{ij}. \tag{38}$$

Se $K_i^{\pi}$ é a primeira tentativa não abortada que passa, então

$$C_i^{\pi}(N) = \sum_{j=1}^{N} d_{ij}^{\pi} \mathbf{1}\{K_i^{\pi} \geq j\}, \tag{39}$$

$$A_i^{\pi}(N) = \mathbf{1}\{K_i^{\pi} \leq N\}. \tag{40}$$

É essencial somar apenas tentativas efetivamente iniciadas. O rótulo de um candidato abortado pode ser usado para calcular false-abort na análise, mas não para parar o replay como se a tarefa tivesse sido resolvida.

A equivalência com a execução online exige que abortar uma tentativa não modifique a identidade das seguintes. Seeds independentes, ordem fixa e configuração determinística fornecem essa propriedade no desenho. Batching e diferenças numéricas podem impedir igualdade bit a bit; por isso, uma execução online pequena deve conferir decisões, contagem de tokens e comportamento de término.

### *4.4.5 Comparadores operacionais*

O experimento utiliza o mesmo banco e a mesma ordem para quatro famílias: geração fixa de N candidatos completos; geração sequencial com verificador; interrupção com observáveis B; e interrupção com H+B. Os orçamentos reportados são 1, 5, 10 e 20, com $N = 20$ como comparação principal.

Cada política adaptativa recebe o mesmo espaço de checkpoints, método de calibração e regra de seleção. Uma ablação secundária pode fixar o mesmo checkpoint para B e H+B,

isolando a contribuição do score. A comparação principal entre procedimentos permite que cada um selecione sua configuração dentro do mesmo orçamento de desenvolvimento.

O baseline fixo e o baseline com verificador têm a mesma cobertura potencial no mesmo conjunto de candidatos, mas custos distintos quando há sucessos precoces. O comparador decisivo da economia é o baseline com verificador, porque ele já evita gerar tentativas depois de resolver a tarefa.

#### *4.4.6 Não inferioridade e economia*

Definam-se as diferenças médias pareadas

$$\Delta_A = \frac{1}{m}\sum_i (A_i^{\pi} - A_i^{V}), \quad \Delta_C = \frac{1}{m}\sum_i (C_i^{\pi} - C_i^{V}). \tag{41}$$

A margem planejada de não inferioridade é 0,03 em proporção, isto é, 3 pontos percentuais. Exige-se que o limite inferior do intervalo de 95% de $\Delta_A$ seja maior que $-0.03$, e que o limite superior do intervalo de $\Delta_C$ seja menor que zero. Usar um intervalo bilateral de 95% para essas condições é uma escolha conservadora em relação a um teste unilateral de 5%.

A economia relativa é $1 - \frac{\overline{C}^{\pi}}{\overline{C}^{V}}$, com intervalo pareado. A margem de resolução não deriva automaticamente do recall de 97%; são critérios distintos. Com aproximadamente 132 tarefas, a perda de uma tarefa equivale a cerca de 0,76 ponto percentual, o que limita a resolução estatística de uma margem estreita. A discussão de potência deve considerar tarefas e discordâncias pareadas, não apenas o número total de trajetórias.

A comparação contra a política observável usa as mesmas métricas. Economizar em relação ao verificador, mas não superar B, sustenta o valor da interrupção naquele regime, sem demonstrar que os estados internos foram necessários para o ganho.

#### *4.4.7 Medição online e amortização*

A execução online mede tempo após aquecimento, sincronização apropriada da GPU e condições comparáveis de carga e batch. Reporta geração, extração/score, verificação e total. A política não deve ser creditada por economia de FLOPs ou energia sem medição correspondente.

O custo de pesquisa inclui gerar o banco completo, extrair ativações, treinar e calibrar. Esses custos não pertencem ao custo marginal por tarefa da política já treinada, mas precisam ser informados. Se o custo de preparação for $F$ e a economia média por uso for $s > 0$ na mesma unidade, o ponto de amortização idealizado é $\frac{F}{s}$ utilizações. Sem estimativas compatíveis, não se afirma retorno econômico total.

### 4.5 Ambiente efetivamente validado

O dispositivo é uma NVIDIA GeForce RTX 3050 6GB Laptop GPU. A geração usa pesos em bfloat16, projeções lineares calculadas em float32, atenção eager e uma tentativa por vez, com TF32 desativado. O armazenamento dos vetores selecionados usa float16. Essa combinação separa precisão dos pesos, computação e armazenamento; descrevê-la apenas como “inferência

FP16” seria inexato. As tentativas técnicas rejeitadas não forneceram rótulos ao banco. Versões e hashes estão nos manifestos.

### 4.6 Transferência externa implementada

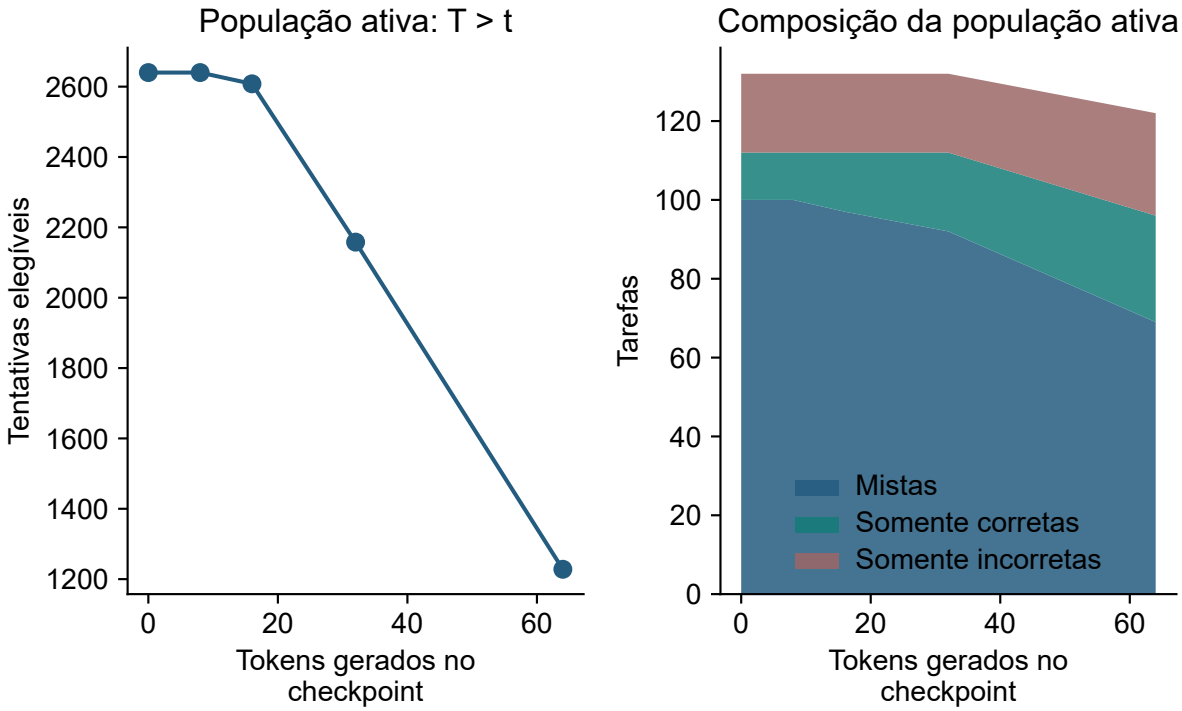
O fluxo secundário prepara modelos, calibradores e políticas exclusivamente com HumanEval+, congela o bundle e então permite coletar MBPP+. Foram avaliadas 32 tarefas selecionadas por hash, com 20 tentativas cada. A aplicação não ajusta parâmetros com rótulos do benchmark alvo. Recalibração ou retreino em MBPP+ constituiriam outro experimento. Os resultados da transferência congelada são reportados no capítulo empírico, sem retreino, recalibração ou seleção nos rótulos alvo.

# 5 RESULTADOS DO DESENHO FIXO

## 5.1 Amostragem, elegibilidade e proveniência

O piloto e o banco principal são separados por tarefa. A coleta mantém todas as 20 tentativas de cada tarefa principal, inclusive após um sucesso, para permitir replay pareado. No endpoint primário há 2158 tentativas elegíveis, 132 tarefas e 92 tarefas mistas. Tarefas homogêneas contribuem para perdas e resolução, mas não identificam AUC intratarefa. A população ativa muda entre checkpoints: as curvas temporais não acompanham uma amostra invariável.

Figura 1: HumanEval+: elegibilidade T > t e composição das 132 tarefas do banco principal. Checkpoint zero usa todos os prompts; os checkpoints posteriores têm populações ativas diferentes.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

## 5.2 Predição e ganho incremental no endpoint primário

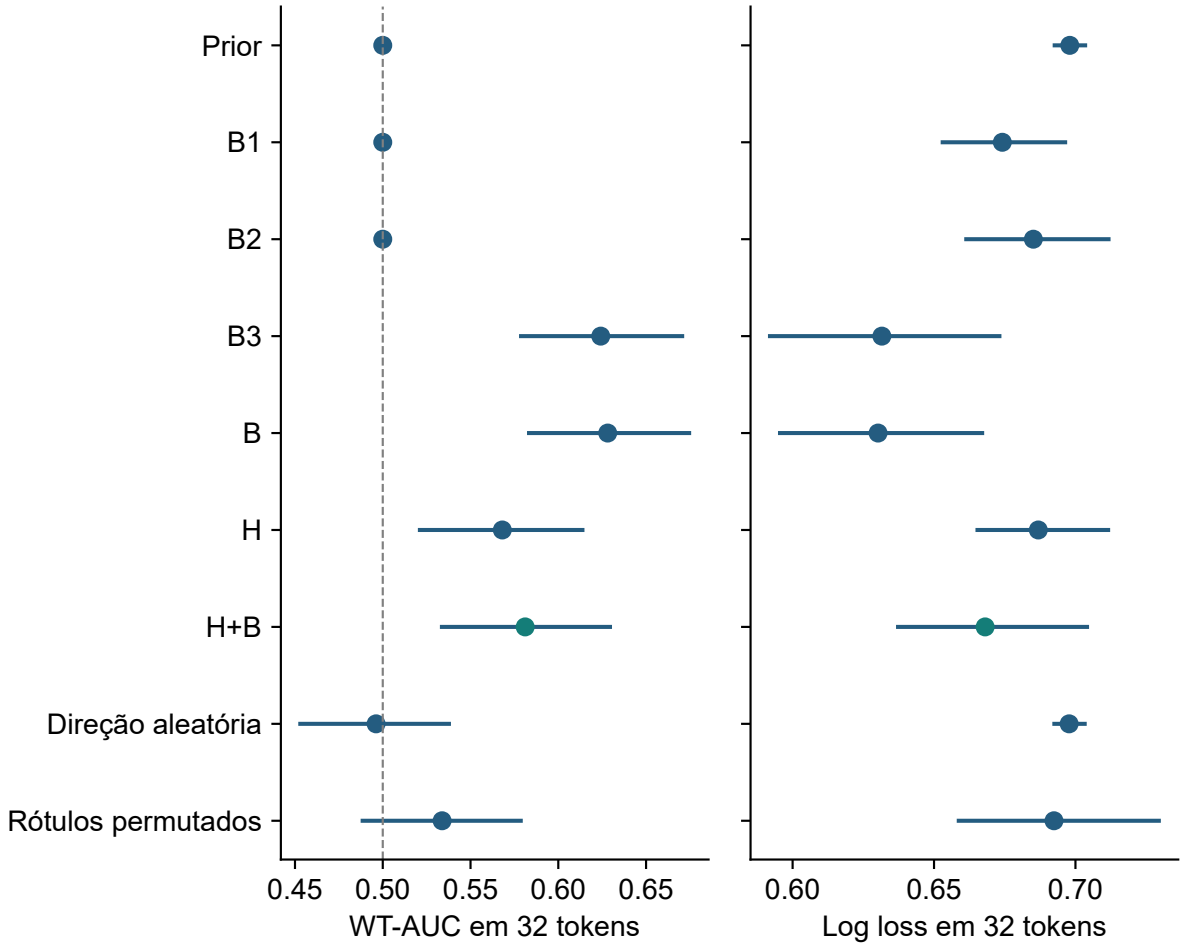
Tabela 1: Predições externas em 32 tokens; cada tarefa recebe o mesmo peso total.

| Preditor | AUC | WT-AUC | IC 95% WT-AUC | Log loss |
|---|---|---|---|---|
| B | 0,701 | 0,628 | [0,583; 0,675] | 0,630 |
| H | 0,592 | 0,568 | [0,521; 0,614] | 0,687 |
| H+B | 0,646 | 0,581 | [0,534; 0,629] | 0,668 |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

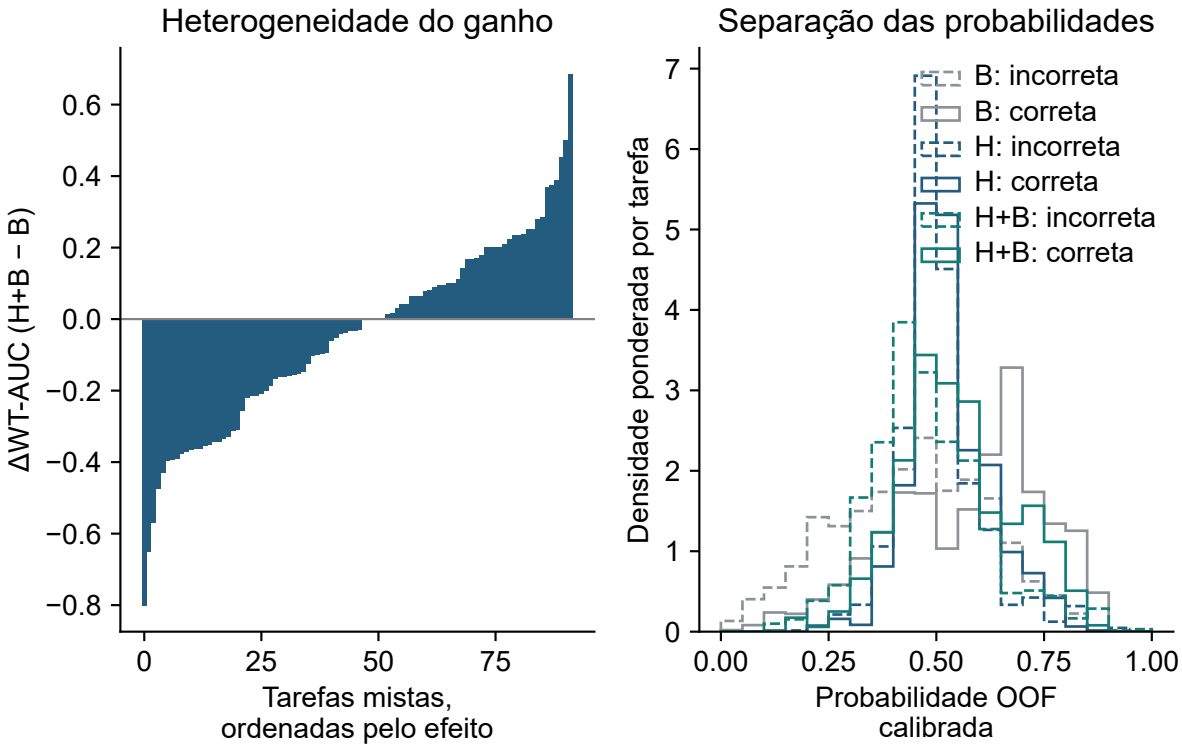
A diferença H+B menos B em WT-AUC é −0,047, IC 95% [−0,099; 0,006], e em log loss é 0,038, IC 95% [0,007; 0,071]. Esse resultado não satisfaz o critério conjunto de Q2. O intervalo de perda permanece acima de zero: H+B apresenta maior perda que B neste contraste. O teste de permutação por fold avalia associação intratarefa; ele não constitui um teste isolado de informação adicional sobre B. Os controles e as métricas secundárias estão apresentados para diagnóstico, sem substituir o endpoint.

Figura 2: HumanEval+ OOF, t=32: desempenho primário e controles, 2158 tentativas ativas e 92 tarefas mistas. IC95% por bootstrap de tarefas, condicional aos scorers ajustados; WT-AUC usa somente tarefas mistas.



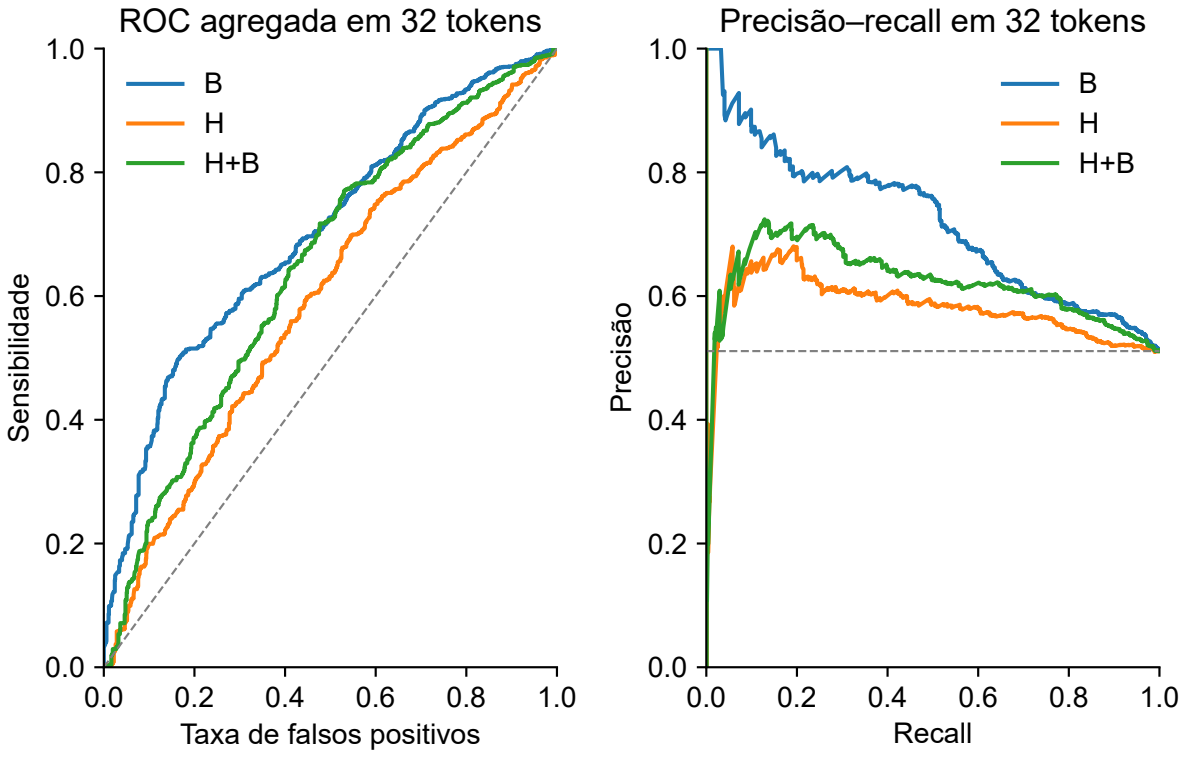

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 3: HumanEval+ OOF, t=32: diferença H+B−B nas 92 tarefas mistas e distribuições de probabilidades por resultado. As densidades usam pesos inversos ao número de tentativas ativas da tarefa, com normalização em cada resultado.



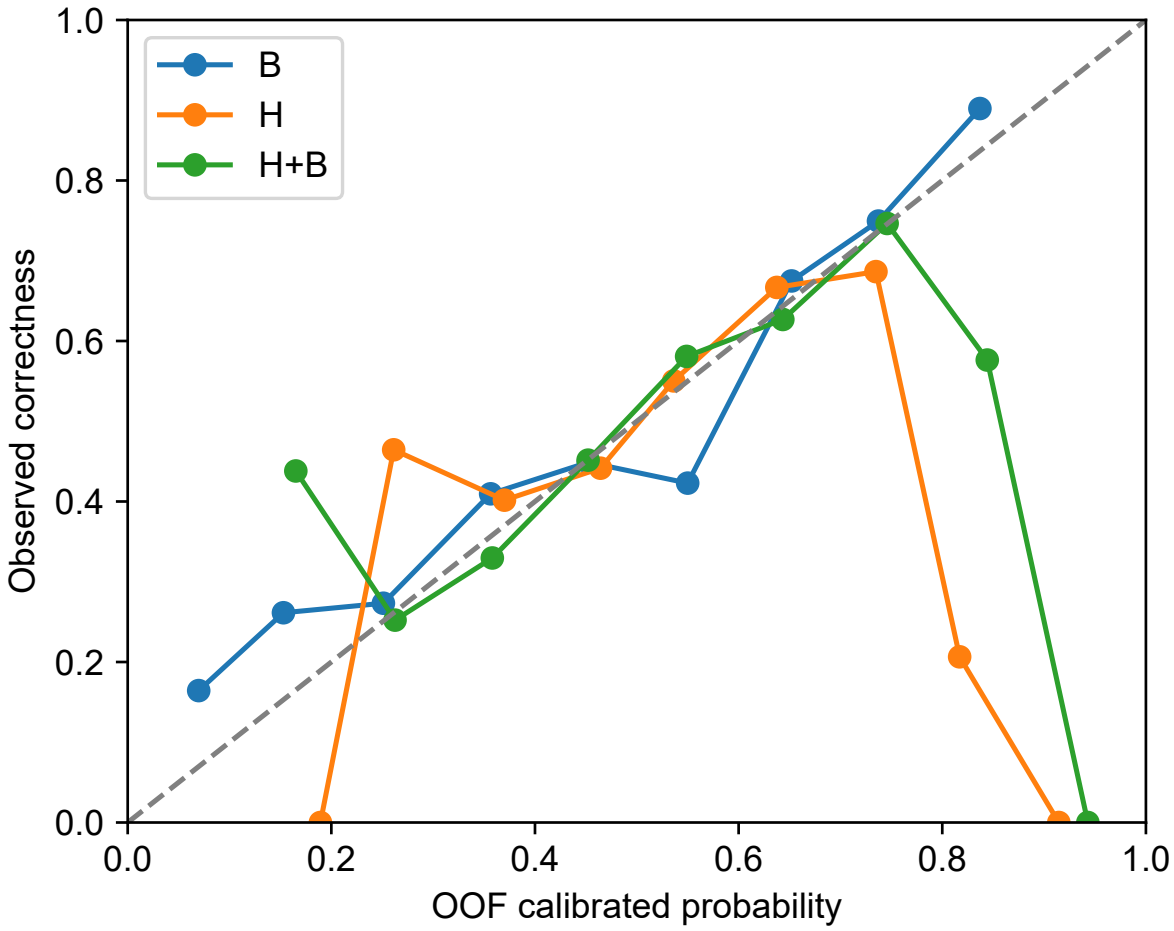

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 4: HumanEval+ OOF, t=32: curvas agregadas ROC e precisão–recall de B, H e H+B, ponderadas por tarefa. Não são curvas de discriminação intratarefa.



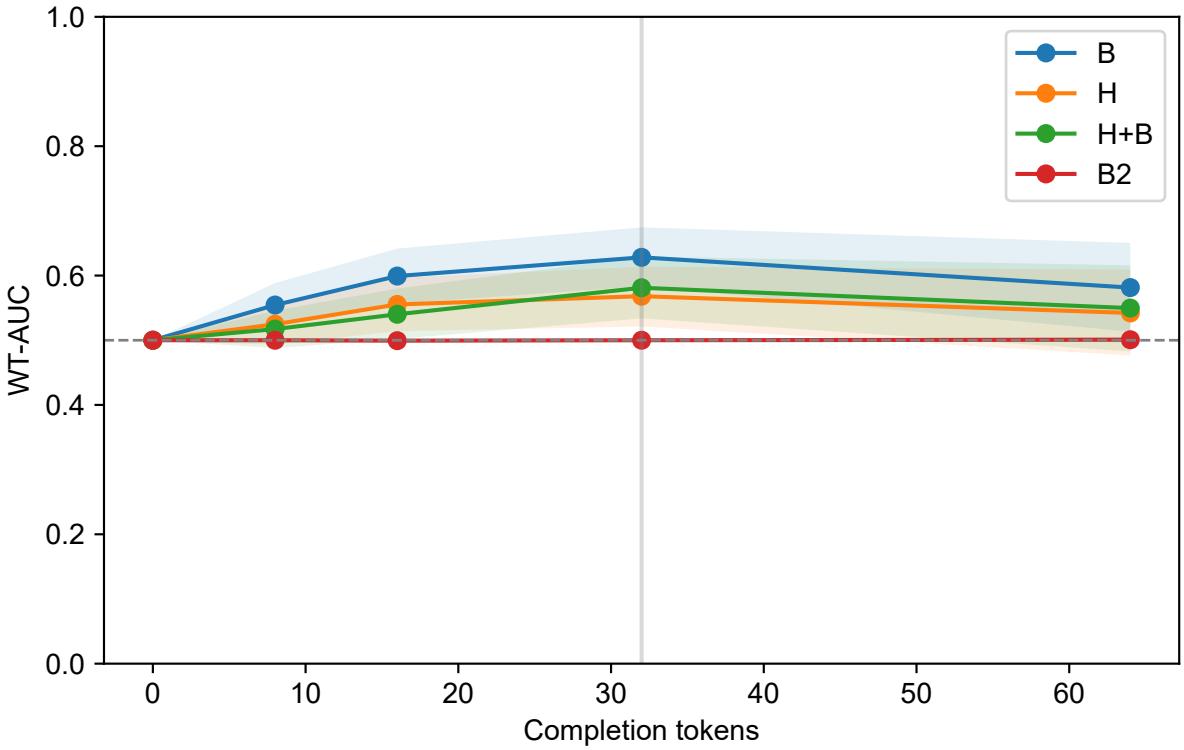

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 5: HumanEval+ OOF, t=32: probabilidade calibrada e frequência observada, dez bins de largura 0,1 e igual peso total por tarefa. A tarefa pontuada é excluída do ajuste do probe e do calibrador.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 6: HumanEval+ OOF: WT-AUC por checkpoint, com IC95% por tarefa e conjunto ativo T > t. O endpoint de 32 tokens é primário; as populações mudam entre os demais pontos, que são secundários.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### 5.3 Replay pareado e validação em execução real

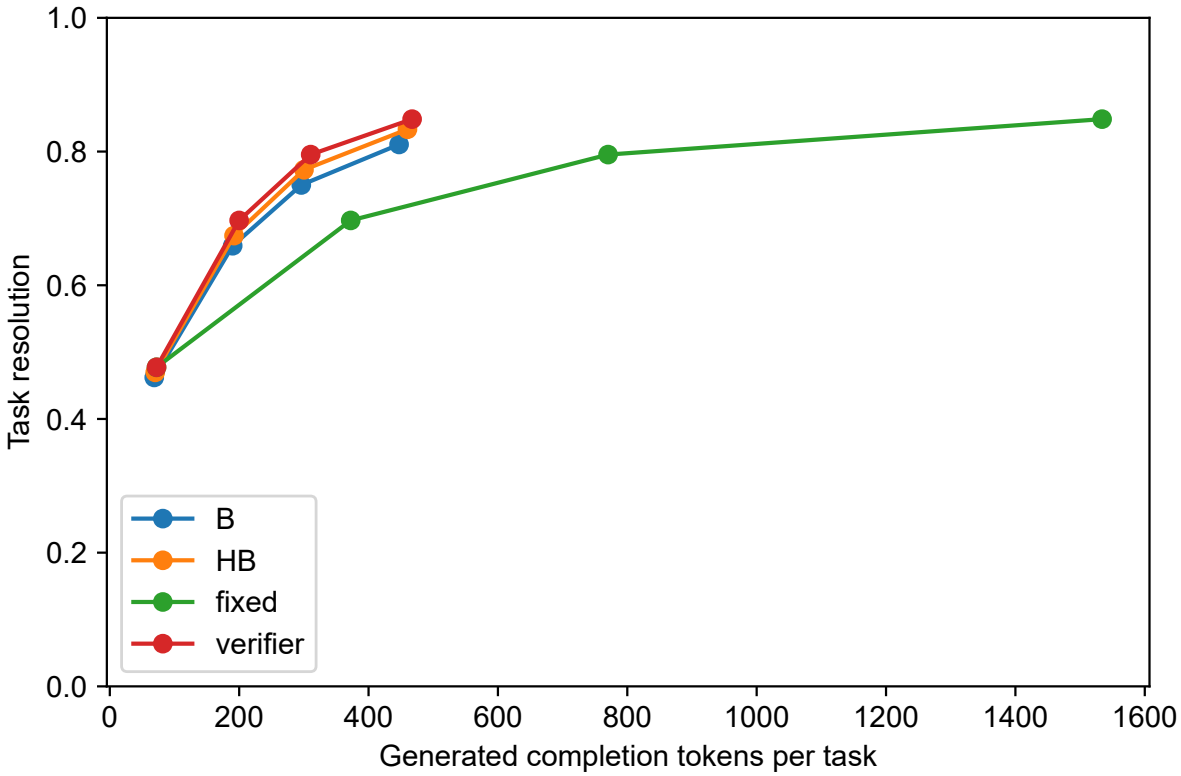
Os critérios conjuntos para afirmar benefício operacional não foram satisfeitos. O critério exige não inferioridade de resolução com margem de três pontos percentuais e economia de tokens, ambos contra verificador e B, além de suporte a Q2 e validação online com aborto efetivo. Uma falha em qualquer condição impede afirmar benefício do sistema.

Tabela 2: Contabilidade de continuação: tentativas abortadas consomem orçamento; parada no primeiro sucesso verificado.

| N | Política | Resolução | Tokens/tarefa | Aborto falso ativo |
|---|---|---|---|---|
| 1 | B | 0,462 | 68,7 | 0,033 |
| 1 | H+B | 0,470 | 70,2 | 0,019 |
| 1 | verifier | 0,477 | 72,2 | 0,000 |
| 5 | B | 0,659 | 190,0 | 0,146 |
| 5 | H+B | 0,674 | 192,0 | 0,096 |
| 5 | verifier | 0,697 | 199,9 | 0,000 |
| 10 | B | 0,750 | 296,0 | 0,197 |
| 10 | H+B | 0,773 | 300,2 | 0,103 |
| 10 | verifier | 0,795 | 310,5 | 0,000 |
| 20 | B | 0,811 | 447,2 | 0,297 |
| 20 | H+B | 0,833 | 460,2 | 0,120 |
| 20 | verifier | 0,848 | 467,3 | 0,000 |

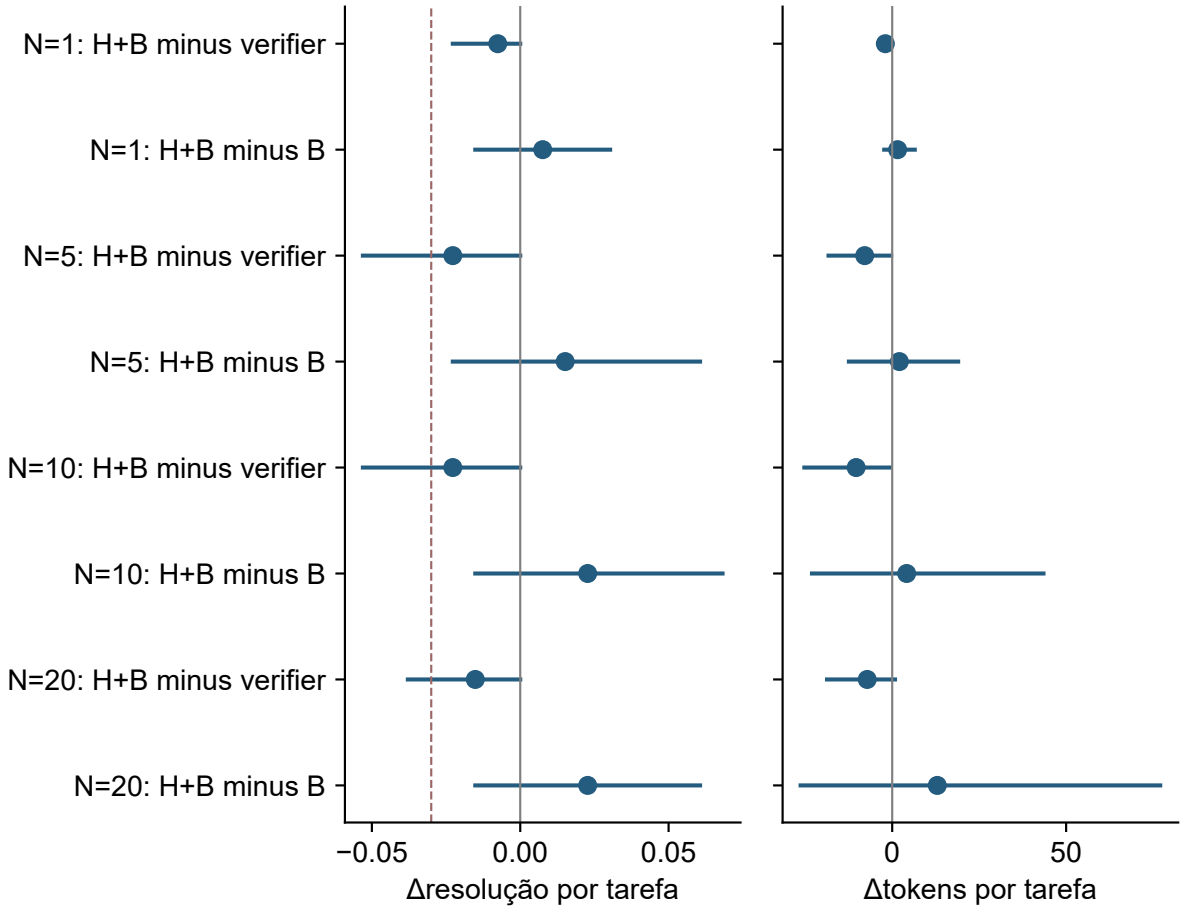
Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 7: HumanEval+, N=1,5,10,20: custo e resolução nos mesmos fluxos ordenados de candidatos. Gates escolhidos somente no treino de cada fold; tokens não equivalem a latência.



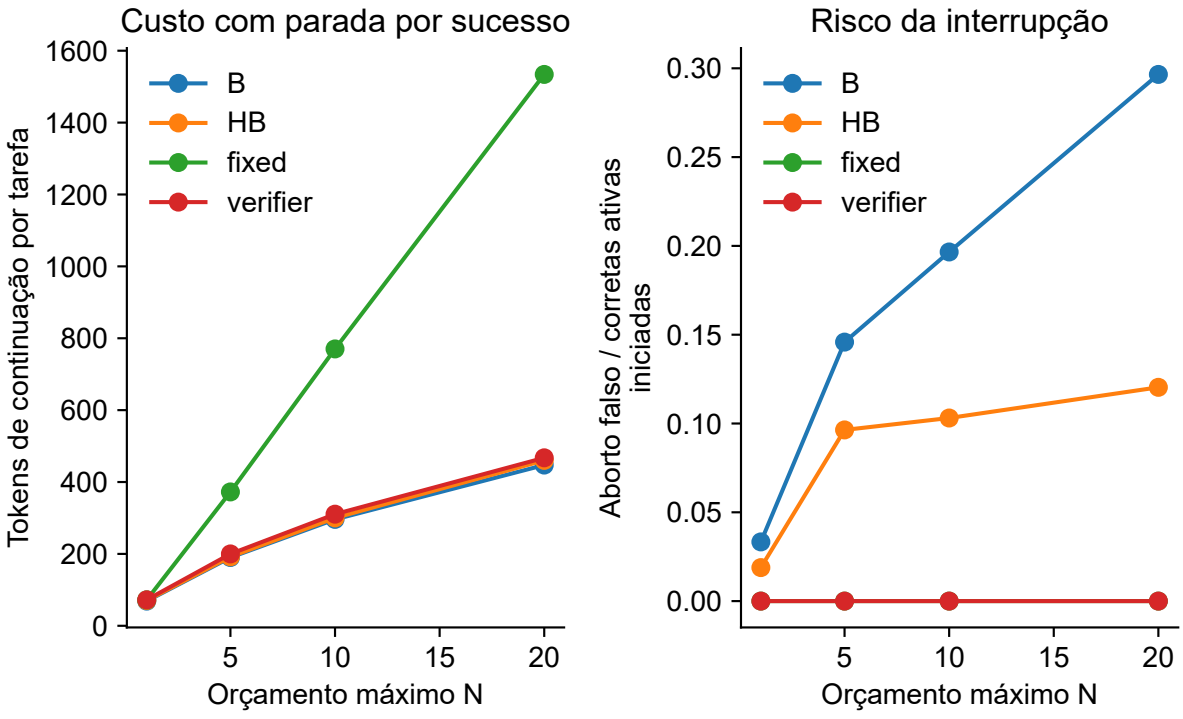

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 8: HumanEval+: diferenças pareadas H+B menos verificador ou B, por orçamento, com IC95% por tarefa. Linha tracejada: margem de resolução −0,03; a regra original exige também economia de tokens.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 9: Replay HumanEval+: custo e proporção de corretos abortados entre os corretos ativos iniciados. O denominador exclui tentativas nunca iniciadas e difere do total de corretos potenciais no banco.



Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

A validação online incluiu 12 tarefas escolhidas por ordem lexicográfica, sem seleção por resultado. A reprodução de tokens, identidades e decisões passou. Houve aborto efetivo. Os tempos são descritivos, sem repetições suficientes para inferir economia de latência.

### 5.4 Transferência congelada para MBPP+

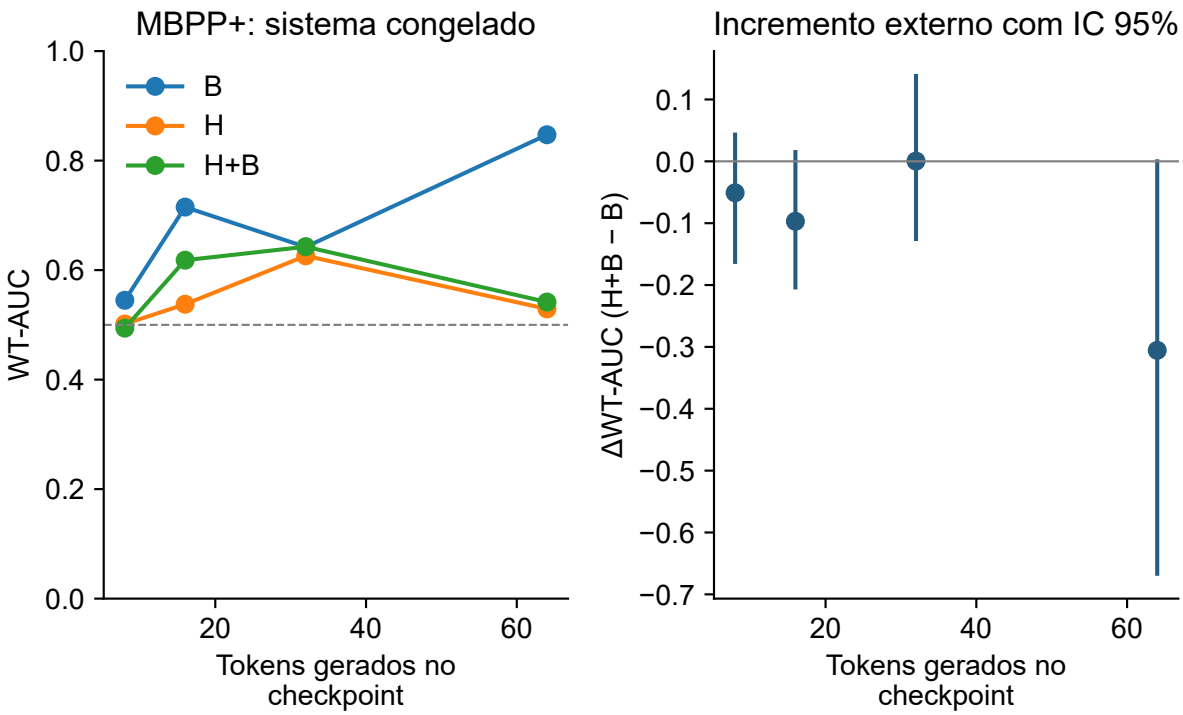
O sistema foi ajustado exclusivamente no banco principal HumanEval+ e aplicado sem reajuste, recalibração ou escolha de limiar nos rótulos alvo. O resultado é secundário e offline.

Tabela 3: Desempenho externo de transferência. Uma população homogênea não identifica WT-AUC.

| Checkpoint | Preditor | AUC | WT-AUC | Log loss |
|---|---|---|---|---|
| 8 | B | 0,470 | 0,545 | 0,718 |
| 8 | H | 0,372 | 0,502 | 0,880 |
| 8 | H+B | 0,364 | 0,494 | 0,883 |
| 16 | B | 0,725 | 0,715 | 0,659 |
| 16 | H | 0,610 | 0,538 | 0,673 |
| 16 | H+B | 0,644 | 0,618 | 0,663 |
| 32 | B | 0,756 | 0,642 | 0,648 |
| 32 | H | 0,706 | 0,626 | 0,658 |
| 32 | H+B | 0,733 | 0,643 | 0,640 |
| 64 | B | 0,915 | 0,847 | 0,590 |
| 64 | H | 0,614 | 0,529 | 0,689 |
| 64 | H+B | 0,741 | 0,542 | 0,644 |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 10: Transferência externa sem ajuste nos rótulos alvo. WT-AUC e contraste pareado; checkpoints são secundários.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Tabela 4: Replay offline em 32 tarefas alvo. Não há validação online MBPP+ nem ajuste com rótulos alvo.

| Política N=20 | Resolução MBPP+ | Tokens/tarefa |
|---|---|---|
| B | 0,844 | 257,0 |
| H+B | 0,781 | 292,6 |
| verifier | 0,844 | 279,9 |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Tabela 5: Diferenças pareadas por tarefa em transferência. Tokens positivos indicam maior custo de H+B.

| Contraste N=20 | Δresolução e IC 95% | Δtokens e IC 95% |
|---|---|---|
| H+B menos verifier | −0,062 [−0,156; 0,000] | 12,72 [−0,595; 34,531] |
| H+B menos B | −0,062 [−0,156; 0,000] | 35,66 [13,092; 64,438] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

## 5.5 Diagnósticos exploratórios posteriores ao resultado principal

As análises desta seção foram acrescentadas após a conclusão e inspeção dos resultados do desenho fixo. Mantêm probabilidades, calibradores e políticas congelados, sem retreino, ajuste no alvo ou mudança do critério de decisão. Usam 2.000 reamostragens de tarefas com seed 20260921. Os intervalos adicionais são pontuais: não têm cobertura simultânea nem status confirmatório.

### *5.5.1 Precisão, estabilidade e composição da população*

Os contrastes e intervalos principais foram reproduzidos numericamente a partir das previsões OOF. O intervalo quantifica os tamanhos de efeito compatíveis sob as suposições utilizadas; incluir zero não demonstra equivalência ou ausência universal de sinal (Greenland et al., 2016).

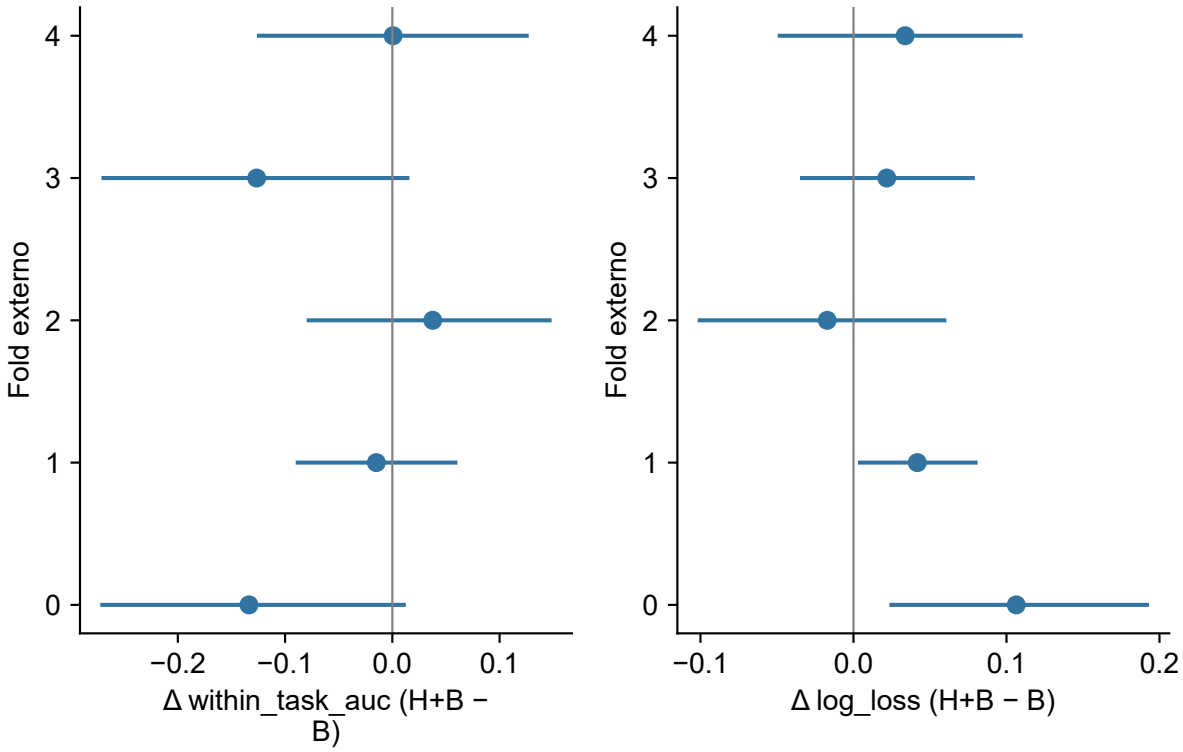
Tabela 6: Influência da exclusão de uma tarefa por vez; os modelos permanecem fixos. A faixa não é um intervalo de confiança.

| Métrica H+B menos B | Estimativa principal | Faixa ao excluir uma tarefa |
|---|---|---|
| brier | 0,0163 | [0,014; 0,018] |
| log_loss | 0,0379 | [0,032; 0,042] |
| WT-AUC | −0,0470 | [−0,055; −0,039] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

A estabilidade do sinal da estimativa sob exclusão não estabelece significância em cada exclusão. Os cinco folds têm conjuntos de treinamento sobrepostos e não são replicações independentes.

Figura 11: Variação do contraste H+B menos B entre folds externos, em 32 tokens. Intervalos exploratórios por tarefa.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

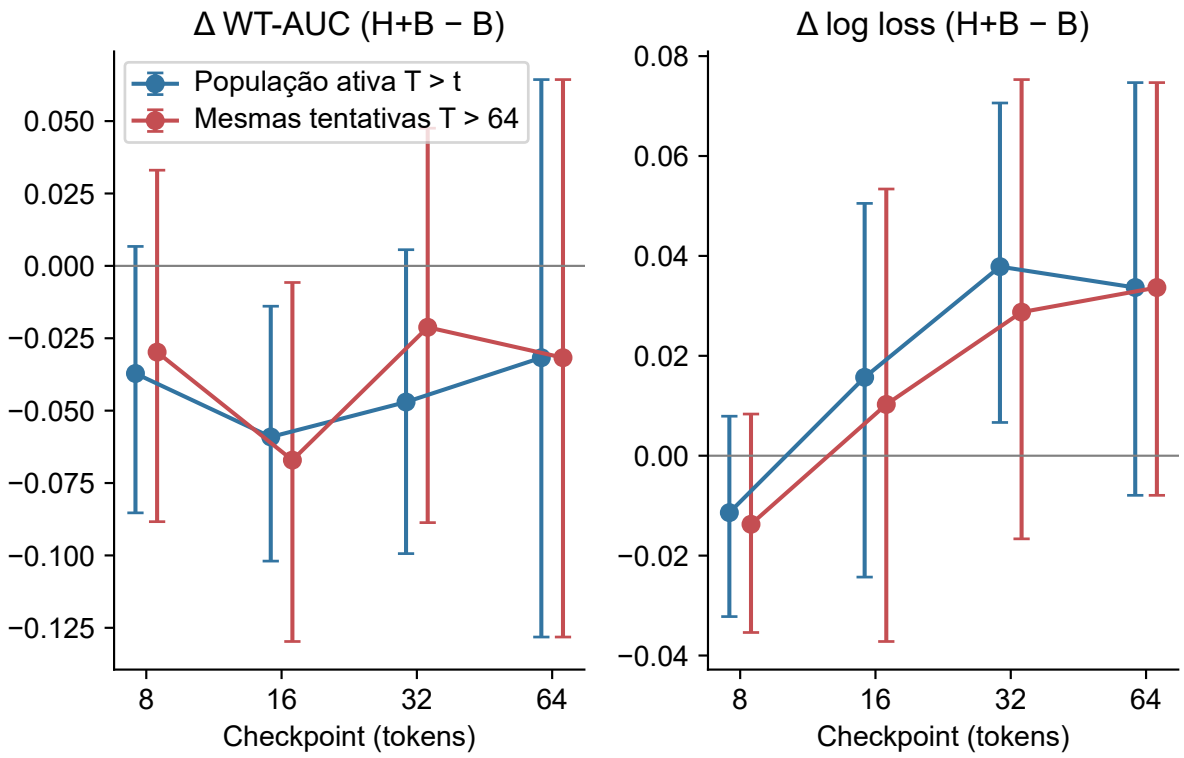
Uma coorte comum retém as mesmas identidades de tentativa nos checkpoints 8, 16, 32 e 64. Ela condiciona em T > 64: separa descritivamente a mudança de população, mas não identifica efeito causal do tempo. A sensibilidade ao histórico exclui da avaliação as tarefas geradas em artefatos anteriores. Essa exclusão não refaz o treinamento nem remove a exposição histórica da pesquisa; não constitui nova amostra confirmatória.

Tabela 7: Análises de sensibilidade com escores fixos. WT-AUC utiliza somente tarefas mistas em cada coorte.

| População em 32 tokens | Tarefas | ΔWT-AUC e IC 95% | Δlog loss e IC 95% |
|---|---|---|---|
| HumanEval+ OOF, T > 64 | 122 | −0,0212 [−0,089; 0,048] | 0,0287 [−0,017; 0,075] |
| MBPP+ frozen, T > 64 | 17 | −0,0208 [−0,312; 0,251] | 0,0025 [−0,065; 0,067] |
| HumanEval+, sem histórico | 106 | −0,0341 [−0,093; 0,025] | 0,0192 [−0,016; 0,054] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 12: Contrastes na população ativa original e na coorte comum T > 64. Os demais checkpoints são exploratórios.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### *5.5.2 Calibração e transporte do limiar*

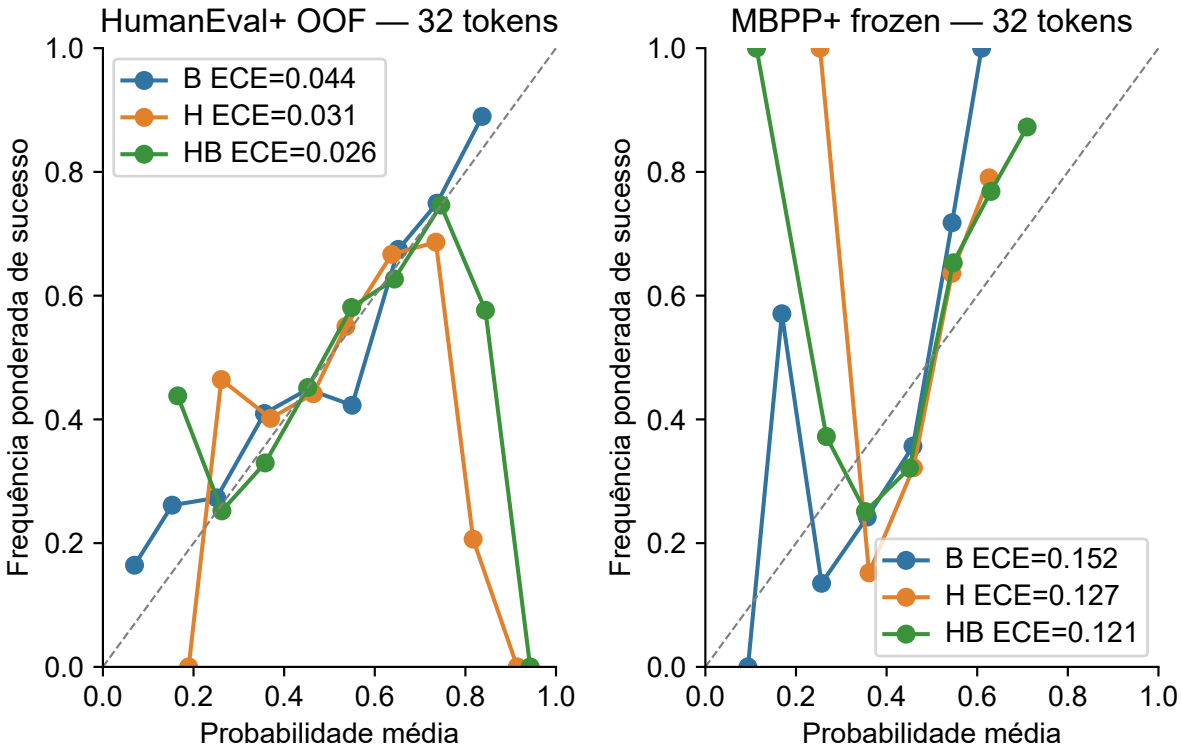
A calibração é descrita em dez bins fixos de largura 0,1 da probabilidade de sucesso, com peso total igual por tarefa. O ECE agrega os desvios absolutos entre probabilidade e frequência observada; a curva de confiabilidade complementa a discriminação (Guo et al., 2017). ECE depende da discretização e do tamanho amostral e não substitui log loss ou Brier. Seu bootstrap percentil pode ter viés positivo e não conter o ECE empírico. Bins pouco ocupados são instáveis; contagens e massas ponderadas são exportadas junto às figuras.

Tabela 8: Calibração da probabilidade da classe positiva em 32 tokens; os intervalos exploratórios estão nos artefatos complementares.

| **Avaliação** | **Preditor** | **ECE** | **RMSCE** |
|---|---|---|---|
| HumanEval+ OOF | B | 0,0445 | 0,0620 |
| HumanEval+ OOF | H | 0,0313 | 0,0754 |
| HumanEval+ OOF | H+B | 0,0261 | 0,0642 |
| MBPP+ frozen | B | 0,1521 | 0,1685 |
| MBPP+ frozen | H | 0,1266 | 0,1387 |
| MBPP+ frozen | H+B | 0,1208 | 0,1341 |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 13: Confiabilidade em origem e alvo. Os escores são OOF em HumanEval+ e de um modelo ajustado em toda a origem para MBPP+; a diferença entre painéis não isola mudança de domínio.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

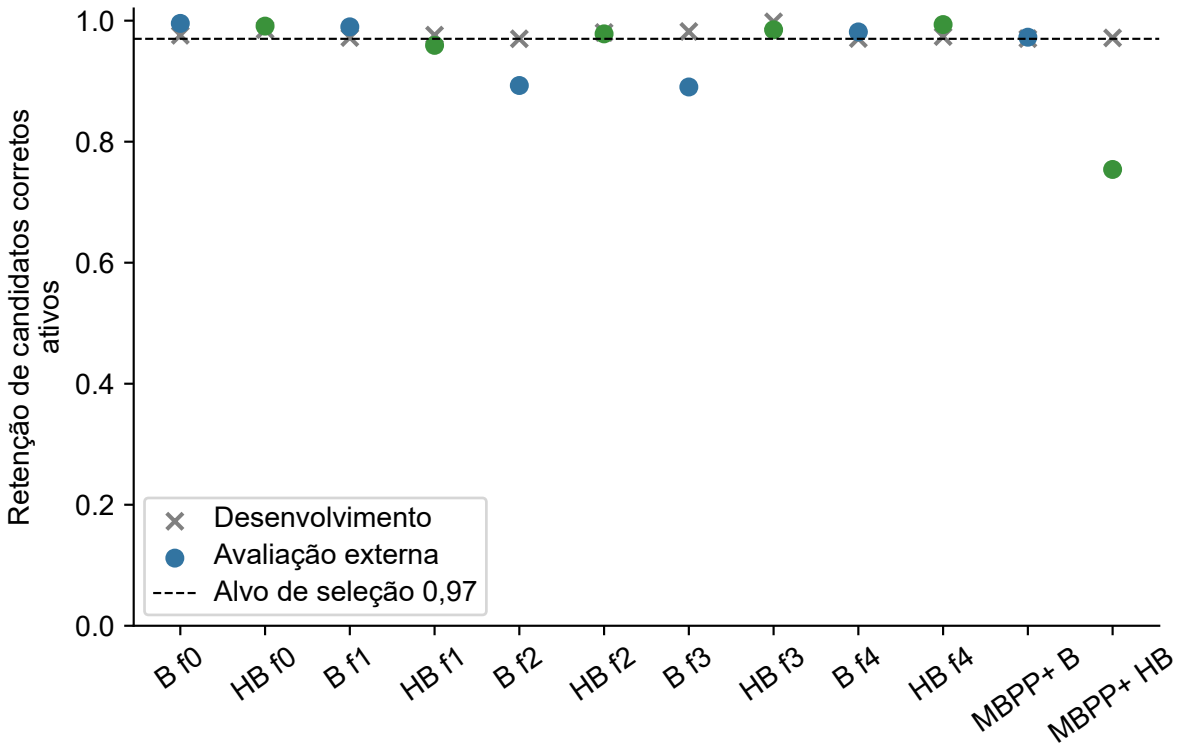
A retenção abaixo considera todos os candidatos corretos ativos no checkpoint selecionado, inclusive candidatos nunca iniciados no replay. Ela tem o mesmo denominador conceitual da restrição de desenvolvimento. Difere da taxa de aborto falso operacional, que considera apenas tentativas iniciadas. Cada política pode selecionar um checkpoint diferente; a comparação de retenções entre políticas não usa necessariamente a mesma população.

Tabela 9: Retenção de candidatos corretos sob gates congelados. Bootstrap por tarefa da razão de contagens somadas; alvo de desenvolvimento 0,97.

| **Avaliação** | **Política** | **Retidos/ativos corretos** | **Retenção e IC 95%** |
|---|---|---|---|
| HumanEval+ OOF | B | 1158/1219 | 0,9500 [0,907; 0,983] |
| HumanEval+ OOF | H+B | 1056/1079 | 0,9787 [0,961; 0,993] |
| MBPP+ frozen | B | 356/366 | 0,9727 [0,955; 0,989] |
| MBPP+ frozen | H+B | 276/366 | 0,7541 [0,619; 0,877] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 14: Alvo de seleção, retenção de desenvolvimento e retenção externa nos gates congelados. O alvo empírico não é garantia de generalização.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### *5.5.3 Condições necessárias para a conclusão operacional*

Tabela 10: Critérios originais em N = 20. Q2 exige redução pontual de log loss; seu IC qualifica a incerteza. LI e LS são limites do intervalo; nenhuma margem foi escolhida após observar os resultados.

| **Condição** | **Estimativa e IC 95%** | **Regra** | **Atendida** |
|---|---|---|---|
| Ganho primário de WT-AUC | −0,0470 [−0,099; 0,006] | LI > 0,000 | não |
| Redução primária de log loss | 0,0379 [0,007; 0,071] | Estimativa < 0,000 | não |
| N=20 HB menos verifier: Δresolução | −0,0152 [−0,038; 0,000] | LI > −0,030 | não |
| N=20 HB menos verifier: Δtokens | −7,1818 [−18,735; 0,804] | LS < 0,000 | não |
| N=20 HB menos B: Δresolução | 0,0227 [−0,015; 0,061] | LI > −0,030 | sim |
| N=20 HB menos B: Δtokens | 12,9621 [−26,335; 77,053] | LS < 0,000 | não |
| Critério conjunto Q2 | — | Regra conjunta | não |
| Replay online com aborto efetivo | — | Regra conjunta | sim |
| Benefício operacional conjunto | — | Regra conjunta | não |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

# 6 DIAGNÓSTICOS, LIMITE ECONÔMICO E VALIDAÇÃO INDEPENDENTE

## 6.1 Perguntas explicativas e desenho das ablações

Esta extensão foi definida em 17/10/2026, depois da conclusão e inspeção dos resultados anteriores. Os diagnósticos não substituem o endpoint original. A avaliação independente subsequente tem hipótese e congelamento próprios. Seu objetivo é distinguir explicações compatíveis com a desvantagem de H+B, examinar decisões do gate transferido e quantificar a oportunidade econômica de uma interrupção idealizada.

Mantiveram-se os cinco folds externos originais, com tarefas inteiras. Cada ablação de observáveis seleciona C nos três folds internos. A penalização conjunta forte usa C em 0,00001, 0,0001 e 0,001. PCA compara 16 e 64 componentes, com camada e C escolhidos no treino; imputation, padronização e PCA são refeitos dentro de cada split. A padronização e o classificador ponderam igualmente as tarefas; PCA utiliza as observações de treino, sem rótulos, e whitening.

A calibração Platt recebe scores produzidos por cross-fitting de toda a seleção. O residual usa uma probabilidade de B cujo ajuste, seleção e calibrador excluem o rótulo do candidato pontuado. Dentro da seleção residual, esse primeiro estágio é novamente refeito apenas no respectivo treino. Seu preditor é

$$\hat{p}_{\mathrm{res}} = \sigma\big(\mathrm{logit}(\hat{p}_B) + w_H^{\top}\tilde{H}\big). \tag{42}$$

O offset fica fixo durante o ajuste L2 de w; não há segundo Platt. Esse método ancora B e restringe a correção, mas a comparação não identifica separadamente todos os efeitos de parametrização e calibração. Todos os intervalos adicionais são bootstrap pontual de 2.000 tarefas com seed 20260921, condicionais aos modelos ajustados; não há cobertura simultânea nem promoção de vencedores à hipótese principal.

## 6.2 Componentes do baseline e leituras latentes alternativas

Tabela 11: Predições em tarefas externas no checkpoint de 32 tokens. Comparações exploratórias; sinais positivos de perda representam piora.

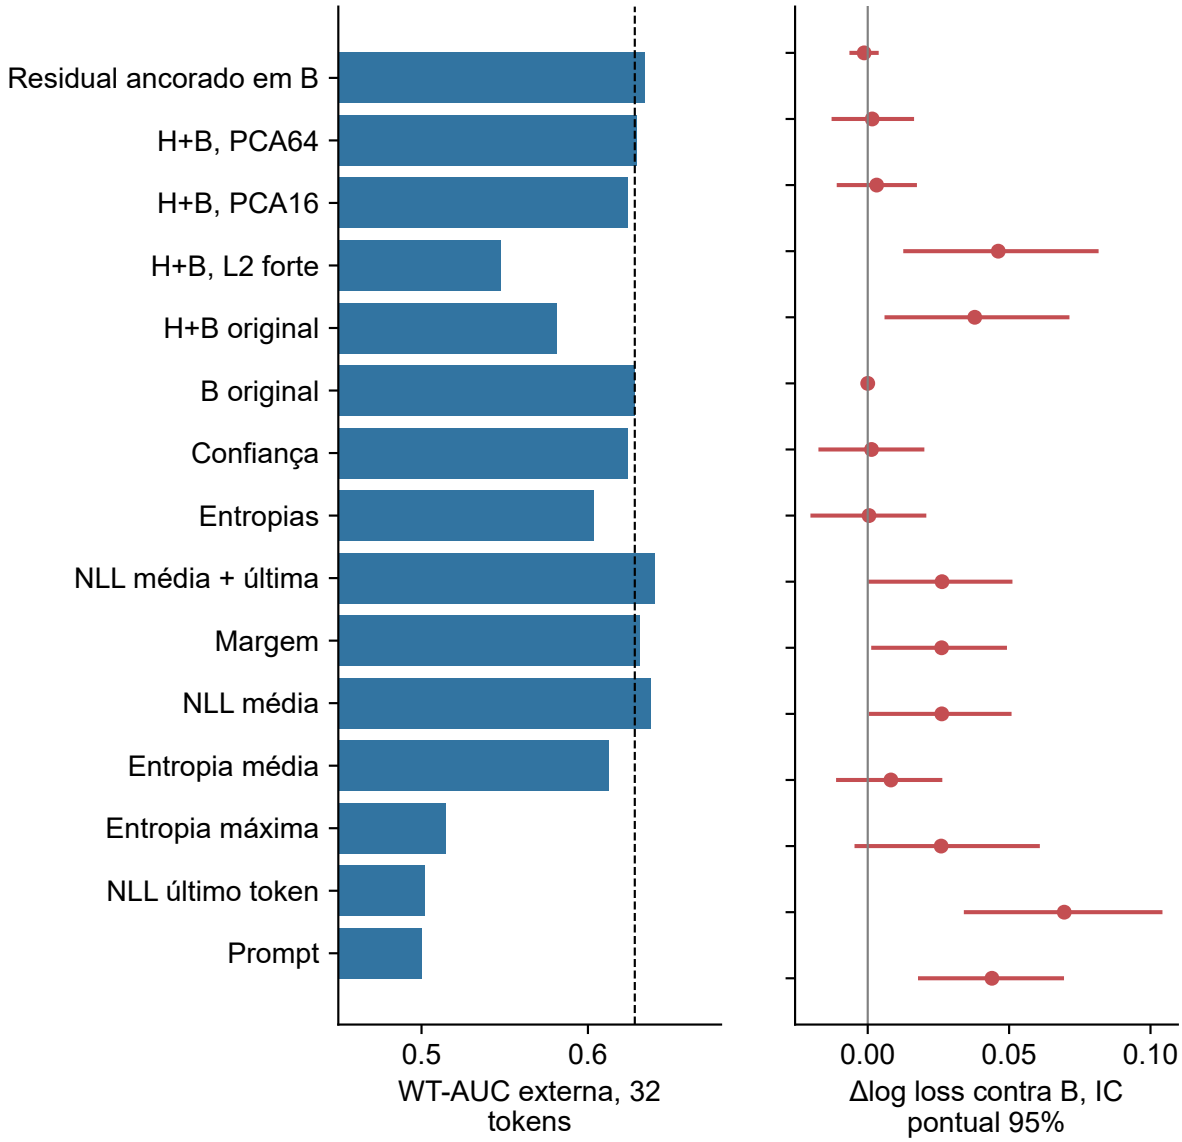
| Família | WT-AUC | Log loss | Δlog loss contra B e IC95% |
|---|---|---|---|
| B_original | 0,6282 | 0,6302 | 0,0000 [0,000; 0,000] |
| HB_original | 0,5811 | 0,6681 | 0,0379 [0,007; 0,071] |
| HB_pca16 | 0,6240 | 0,6334 | 0,0032 [−0,010; 0,017] |
| HB_pca64 | 0,6298 | 0,6318 | 0,0016 [−0,012; 0,016] |
| HB_stronger | 0,5476 | 0,6764 | 0,0462 [0,013; 0,081] |
| H_original | 0,5681 | 0,6869 | 0,0566 [0,024; 0,090] |
| H_residual_B | 0,6345 | 0,6289 | −0,0013 [−0,006; 0,003] |
| confidence_only | 0,6242 | 0,6316 | 0,0013 [−0,017; 0,019] |
| entropy_pair | 0,6036 | 0,6307 | 0,0005 [−0,020; 0,020] |
| last_nll | 0,5023 | 0,6997 | 0,0695 [0,035; 0,104] |
| logit_margin | 0,6311 | 0,6564 | 0,0261 [0,002; 0,049] |
| max_entropy | 0,5146 | 0,6562 | 0,0260 [−0,004; 0,060] |
| mean_entropy | 0,6128 | 0,6384 | 0,0082 [−0,010; 0,026] |
| mean_nll | 0,6378 | 0,6564 | 0,0262 [0,001; 0,050] |
| nll_pair | 0,6404 | 0,6565 | 0,0263 [0,001; 0,050] |
| prompt_only | 0,5000 | 0,6741 | 0,0439 [0,018; 0,069] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

O ranking obtido com NLL média ou margem isoladas é próximo ao de B na estimativa pontual, enquanto sua perda probabilística é maior. Portanto, identificar componentes com bom ranking não basta para justificar um limiar absoluto de interrupção. A combinação das estatísticas beneficia a qualidade probabilística neste regime. Prompt-only tem WT-AUC igual a 0,5 por construção.

PCA e o residual reduzem a desvantagem do H+B original; os intervalos contra B continuam incluindo zero. Penalização conjunta mais forte, sozinha, não resolve o problema na família testada. Esses resultados são compatíveis com sensibilidade à parametrização e ao custo de estimação, sem demonstrar uma causa única ou ausência universal de informação latente incremental.

Figura 15: Ablações e leituras alternativas com seleção agrupada. À direita, diferenças de perda e intervalos pontuais; todas as famílias são mostradas.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

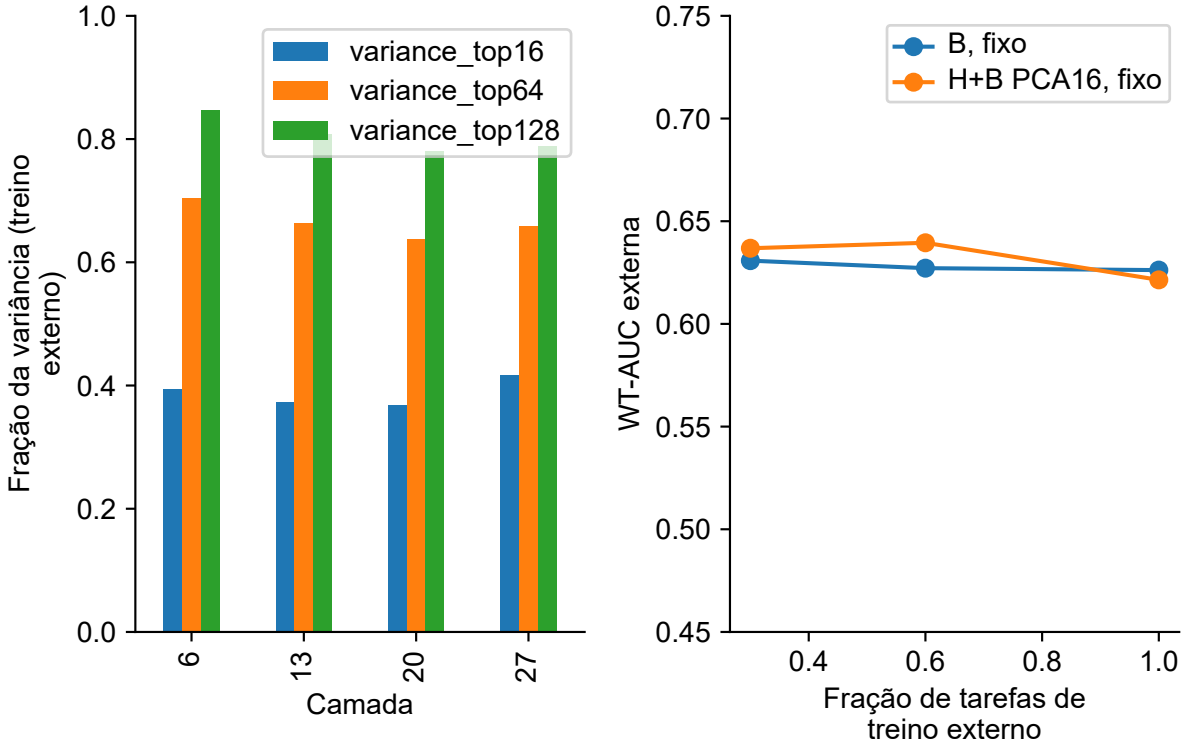
### 6.3 Geometria e sensibilidade ao número de tarefas

Os espectros descritivos usam vetores brutos, distintos dos padronizados na ablação preditiva, e são ajustados exclusivamente no treino externo. Fração de variância explicada não mede informação sobre corretude. Direções só são comparadas entre folds que escolheram a mesma camada, depois de desfazer a escala das coordenadas. Sobreposição dos treinos impede tratar seus ângulos como replicações independentes.

Na camada comum, os cossenos das direções variam de 0,716 a 0,745. A correlação entre escores H e B centrados por tarefa é 0,170. Correlação pequena não demonstra independência condicional, e direções distintas não garantem informação útil adicional para o rótulo. A predição linear do componente H+B latente a partir de B apresenta $R^2$ baixo ou negativo em alguns folds, sem estabelecer redundância completa.

A curva de tarefas usa algoritmos explicitamente fixos: C=0,01, camada 13 e PCA16 para a combinação. Subconjuntos de tarefas são definidos por hash dentro do treino externo, com aproximadamente 32, 63 e 105 tarefas. Ela não representa a curva do procedimento original completo nem estima um tamanho amostral ótimo. WT-AUC não cresce monotonamente neste diagnóstico; aumentar a amostra não é demonstrado como solução suficiente para a desvantagem original.

Figura 16: Variância de treino por camada e sensibilidade de algoritmos fixos à quantidade de tarefas. Não são efeitos causais da dimensão ou do tamanho amostral.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### *6.3.1 Prefixos compartilhados e divergência*

O teste de prefixos reagrupa as tentativas pelo prompt e IDs de tokens observados, e confirma constância dos scores em cada grupo idêntico. Em t=8, 15 das 100 tarefas mistas HumanEval+ e três das 24 mistas MBPP+ têm um único prefixo; nelas, leitores determinísticos não distinguem os resultados. Em t=32, nenhuma das 92 tarefas mistas principais está nessa condição. Portanto, o colapso integral de cada tarefa em um único prefixo não explica o contraste negativo principal. Colisões parciais limitam alguns pares, sem identificar sozinhas a causa da deterioração no alvo. As contagens por tarefa e checkpoint estão exportadas, sem escolher casos pelos resultados do probe.

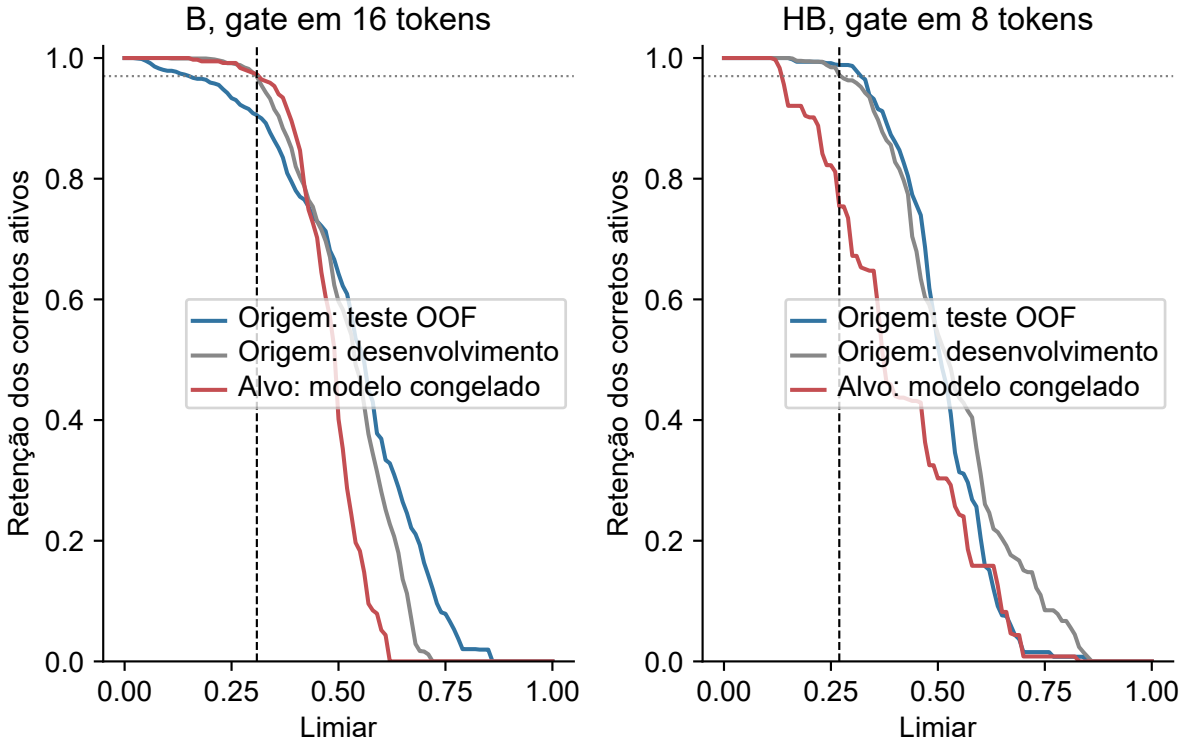
## 6.4 Anatomia da deterioração do gate em MBPP+

A análise distingue origem OOF, desenvolvimento de origem utilizado na escolha do gate e aplicação do bundle completo ao alvo. Reconstituir o desenvolvimento reproduz sua retenção aparente de 0,9715 para H+B em t=8; o calibrador e o limiar foram ajustados nesses rótulos, portanto esse valor não é validação externa.

No alvo, H+B em t=8 mantém 276 dos 366 corretos potenciais e descarta 90, distribuídos por 12 tarefas; cinco concentram 60 descartes. Os corretos têm mediana de score próxima de 0,373 e quartil inferior próximo de 0,286, com limiar 0,2695. O ranking intratarefa nesse ponto é 0,494, com intervalo amplo. Mudança da prevalência e dos comprimentos acompanha a diferença de scores, mas os procedimentos de ajuste também diferem entre origem e alvo: nenhuma comparação isola por si só uma causa de domínio.

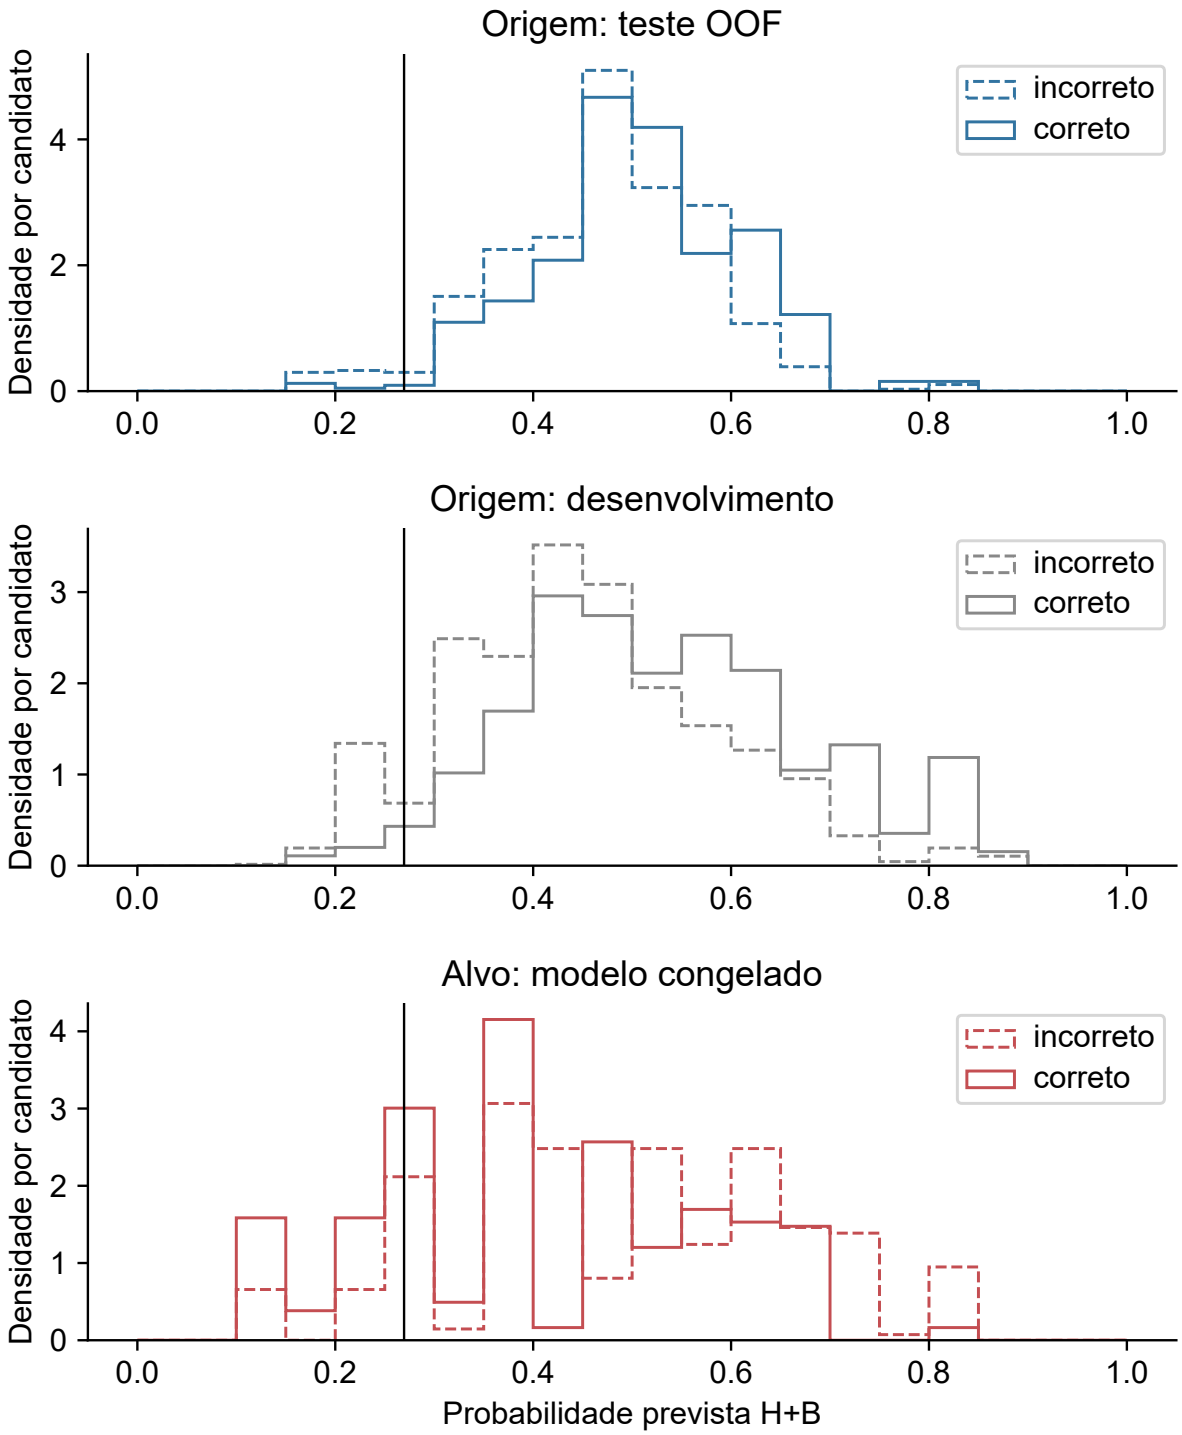
Mbpp/166 perde seus oito sucessos e Mbpp/259 perde seu único sucesso no banco, explicando duas tarefas a menos resolvidas. Entre corretos ativos iniciados, 23 de 48 são descartados; entre todos os corretos potenciais, são 90 de 366. Essa seleção pelo caminho de execução explica por que as duas taxas respondem perguntas diferentes. As curvas no alvo são diagnósticos retrospectivos; não fornecem um limiar reajustado ou uma nova política congelada.

Figura 17: Retenção versus limiar nas três avaliações distintas. Linhas verticais indicam gates escolhidos na origem, sem seleção sobre MBPP+.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 18: Distribuições por resultado funcional no gate H+B de 8 tokens. São densidades por candidato; o desenvolvimento não é avaliação externa.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### 6.5 Potencial econômico e distância ao oracle

O oracle conserva a mesma ordem, N e checkpoint e conhece os rótulos finais. Preserva todos os corretos, interrompe os incorretos ativos e para no primeiro sucesso. As condições matemáticas e a derivação estão na fundamentação. A implementação independente do replay também reproduziu os custos, resolução, tentativas iniciadas e descartes das políticas originais, tarefa por tarefa.

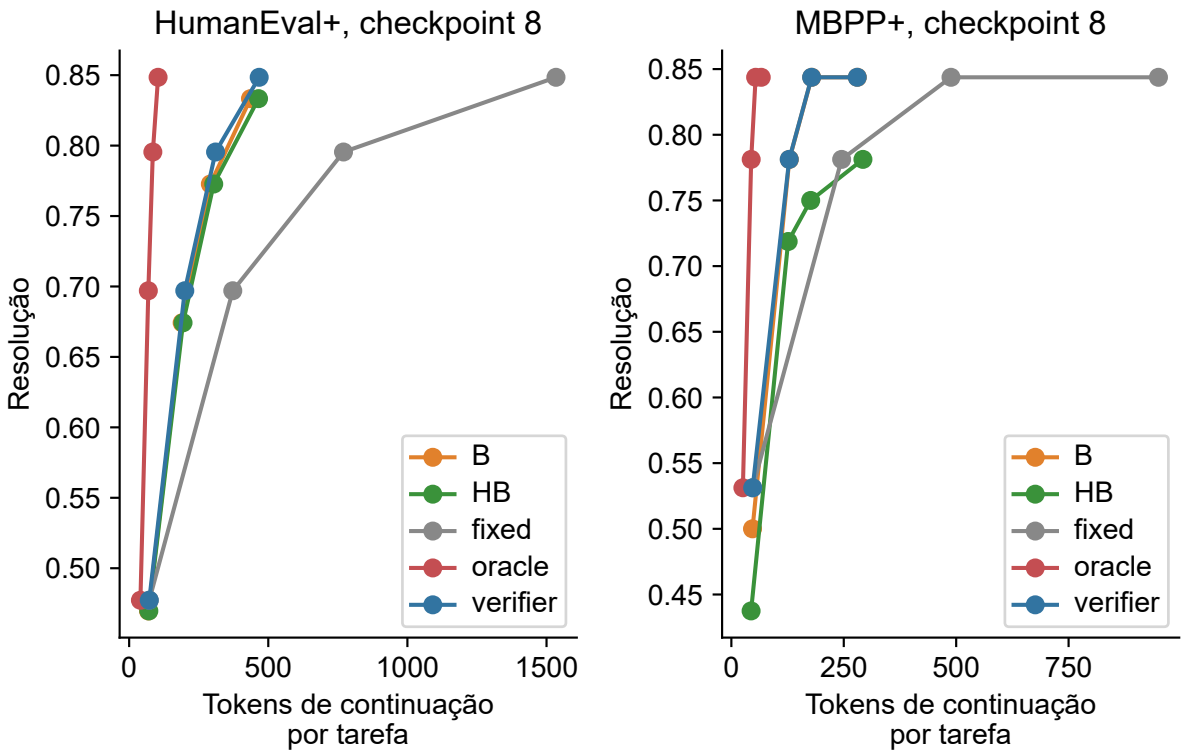
Tabela 12: Oracle retrospectivo, N=20. Sua resolução coincide exatamente com a do verificador; economia é razão de médias por tarefa.

| Banco | t | Tokens oracle/tarefa | Economia contra verificador e IC95% |
|---|---|---|---|
| HumanEval+ | 8 | 104,0 | 0,7775 [0,705; 0,823] |
| HumanEval+ | 16 | 141,6 | 0,6970 [0,617; 0,750] |
| HumanEval+ | 32 | 212,8 | 0,5448 [0,446; 0,617] |
| HumanEval+ | 64 | 307,9 | 0,3411 [0,234; 0,428] |
| MBPP+ | 8 | 66,5 | 0,7625 [0,574; 0,836] |
| MBPP+ | 16 | 98,0 | 0,6500 [0,460; 0,739] |
| MBPP+ | 32 | 156,0 | 0,4426 [0,239; 0,562] |
| MBPP+ | 64 | 227,4 | 0,1876 [0,057; 0,302] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Em HumanEval+, 71,4% da economia oracle em t=8 vem de tarefas não resolvidas no banco. Em MBPP+, 86,1% da economia oracle em t=8 vem de tarefas não resolvidas no banco. Isso delimita onde está grande parte da oportunidade: evitar prolongar tentativas que, retrospectivamente, não produzem solução. Acesso a esse rótulo não existe online. Uma política que descarta sucessos pode até custar menos que este oracle em um caminho, ao custo de perder cobertura; ele não é limite global de todas as políticas possíveis.

Figura 19: Custo e resolução para N=1,5,10,20 no checkpoint 8. B e H+B usam limiares específicos desse checkpoint escolhidos somente na origem; o oracle é idealizado.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

## 6.6 Medições técnicas e avaliação independente

O benchmark contém 50 pares, 100 gerações e 26 tarefas conhecidas. Tokens e estados coincidiram exatamente. A GPU conectada é NVIDIA GeForce RTX 3050 6GB Laptop GPU; pico reservado 4978 MiB. Os tempos médios de geração instrumentada foram 8,764 s na captura original e 8,475 s na seletiva. São tempos descritivos, parcialmente concorrentes com análises CPU; não constituem inferência de aceleração da política. Os microbenchmarks separados de gate, prefill e verificador estão nos artefatos. A RTX 4060 mencionada na solicitação não está disponível; seu desempenho não é extrapolado.

### *6.6.1 Latência completa em tarefas conhecidas*

Foram medidas 72 execuções em seis tarefas do piloto já examinado, três repetições e até três tentativas por tarefa, com a ordem dos quatro modos alternada. O plano precedeu as medições; não usa a nova reserva. Warmup dos caminhos e dos oracles do verificador e carregamento dos pesos foram excluídos. Tokens, estados capturados e rótulos funcionais foram comparados ao banco conhecido.

O somatório dos tempos completos de tarefa foi 33,6 minutos. O orçamento temporal de 30 minutos é verificado antes de cada bloco de quatro modos; o bloco final é concluído mesmo quando ultrapassa esse valor. Não se trata de um limite rígido por processo.

Tabela 13: Tempos de ponta a ponta na GPU efetivamente conectada, N=3. Variabilidade descritiva, sem teste confirmatório de aceleração.

| Modo | Tempo total médio (s) | Mín–máx (s) | Verificador RPC (s) | Resoluções/execuções |
|---|---|---|---|---|
| verifier plain | 32,570 | 2,714–112,960 | 0,281 | 9/18 |
| verifier selective | 32,595 | 2,733–112,842 | 0,281 | 9/18 |
| B | 14,441 | 2,721–29,622 | 0,100 | 9/18 |
| HB | 32,549 | 2,731–112,963 | 0,280 | 9/18 |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Os arquivos por tarefa decompõem geração, prefill, cópia seletiva, classificação, parsing e RPC do verificador. Prefill, cópia e classificação são partes da geração medida; não se somam novamente a ela. Mesmo o modo sem probe utiliza o sampler instrumentado da pesquisa. Orçamento, tarefas conhecidas e cache aquecido diferem do replay N=20: não se extrapola uma economia de latência, energia ou desempenho na RTX 4060.

## 6.7 Validação independente aprovada

Depois dos diagnósticos, o estudante aprovou explicitamente a proposta e informou que o orientador já a havia revisado. Esse relato, sem assinatura criada em nome do orientador, foi vinculado aos hashes do protocolo, desenho e implementação. Um snapshot prospectivo de 46 arquivos precede a primeira trajetória nova. O cabeçalho da proposta registra seu estado histórico de elaboração; o arquivo de aprovação e o manifesto de congelamento registram a autorização subsequente. Não se reivindica pré-registro externo nem se modifica a autorização histórica v0.2.

A hipótese única compara retenção de candidatos corretos por H+B e B no mesmo checkpoint de oito tokens. Os limiares de origem são 0,26953905544150975 e 0,3166734153299228, respectivamente, sem ajuste nos novos dados. A reserva por hash exclui tarefas com resultados locais anteriores e o controle Mbpp/2. Vinte tarefas técnicas disjuntas verificam a implementação; suas 400 tentativas não entram na inferência principal. A amostra principal contém 120 novas tarefas MBPP+ e 2.400 tentativas completas, mesmo após sucessos. A população é T>8; o denominador comum contém todos os candidatos corretos ativos, inclusive os que não seriam iniciados no replay. Não se usa a média das retenções por tarefa.

O estimando é a diferença das razões das contagens esperadas por tarefa:

$$\theta = r_{H+B} - r_{B}. \tag{43}$$

Reamostram-se tarefas inteiras, mantendo o pareamento, 10.000 vezes com seed 20261017. O único critério de suporte é limite superior do IC bilateral de 95% estritamente negativo. Mais de 1% de replicações sem denominador positivo tornaria o endpoint não identificável. Não houve troca de tarefa, seleção de limiar, expansão por resultado ou parada por significância.

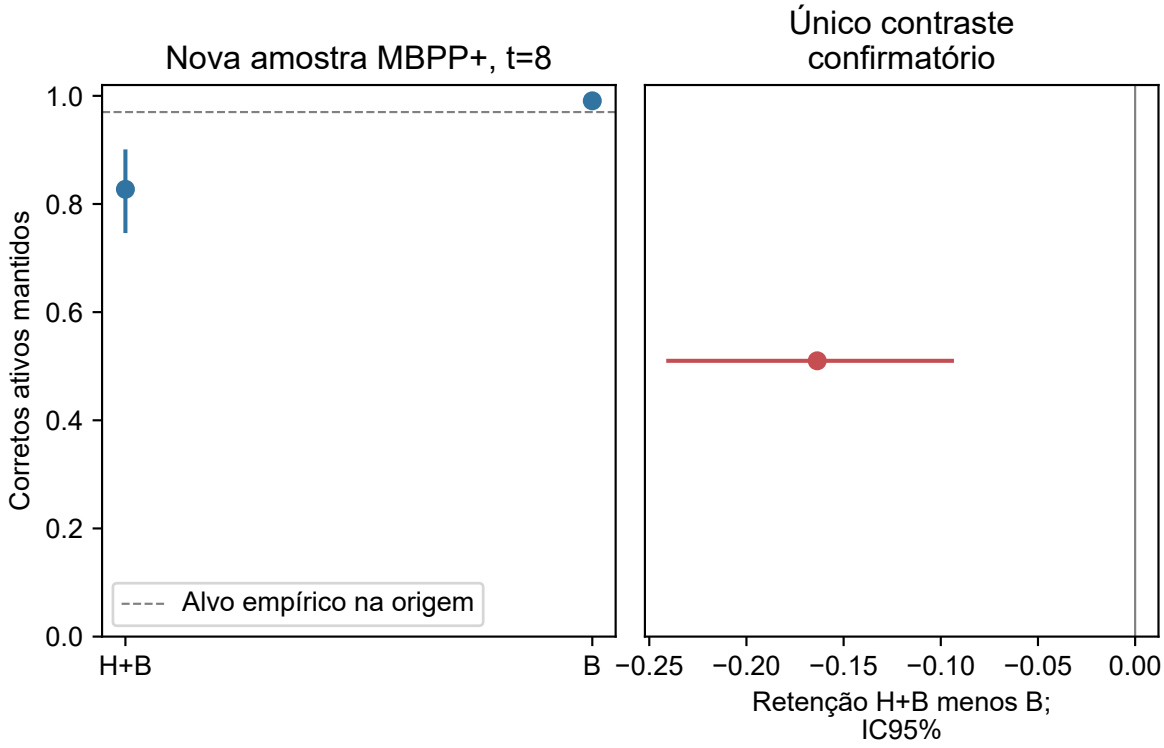
Em T>8 restam 2400 candidatos, 74 tarefas mistas e 1192 corretos ativos. A estimativa de θ é −0,1636, IC95% [−0,240; −0,094]. Houve 0 replicações indefinidas. O critério direcional foi satisfeito: o limite superior do intervalo é negativo.

Tabela 14: Retenções na nova amostra. Seus intervalos absolutos são descritivos; a confirmação usa somente o contraste pareado.

| Gate | Corretos retidos/ativos | Retenção | IC95% |
|---|---|---|---|
| H+B | 986/1192 | 0,8272 | [0,750; 0,897] |
| B | 1181/1192 | 0,9908 | [0,983; 0,997] |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 20: Nova reserva de 120 tarefas MBPP+, gates de origem em t=8: retenções de corretos ativos e contraste pareado H+B−B, IC95% por tarefa. A linha em 0,97 é meta empírica do desenvolvimento, sem garantia de transporte.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

### *6.7.1 Resultados secundários e limites da confirmação*

Tabela 15: Métricas secundárias na população ativa. Discriminação não equivale a calibração ou utilidade operacional.

| Preditor | AUC | WT-AUC | Log loss | Brier |
|---|---|---|---|---|
| B | 0,5087 | 0,5368 | 0,7002 | 0,2534 |
| H+B | 0,4577 | 0,4605 | 0,7883 | 0,2899 |

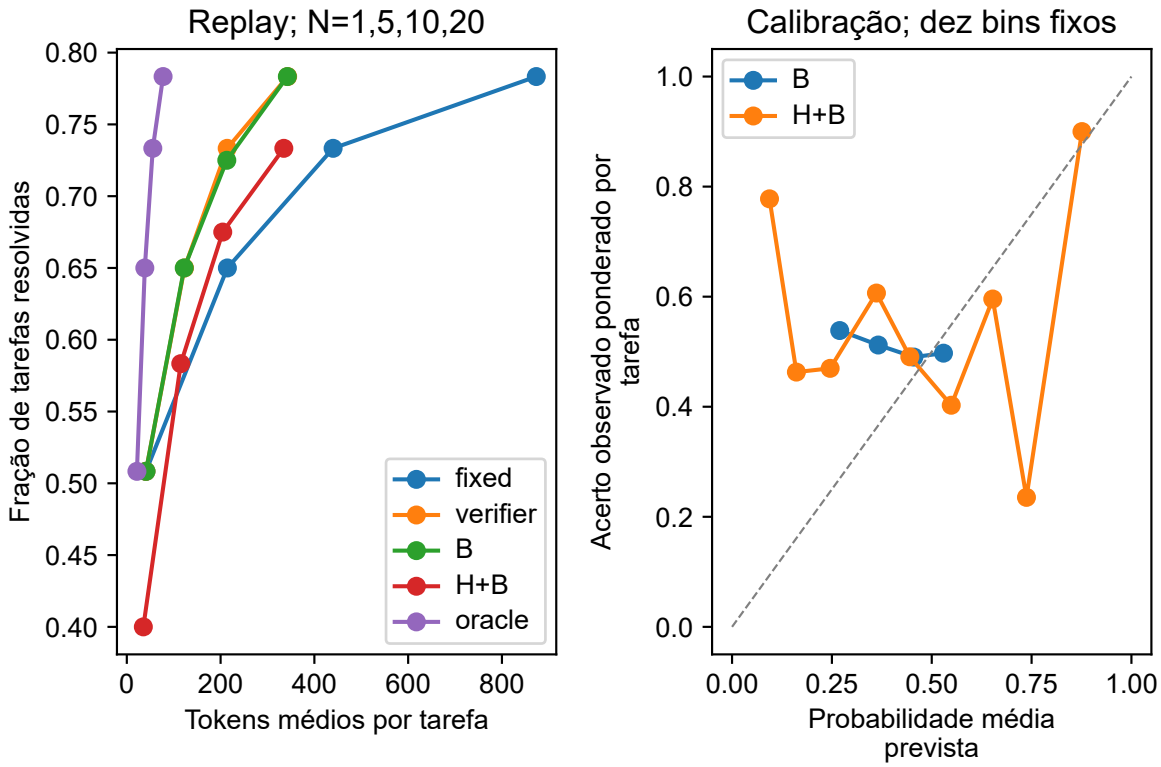
Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Tabela 16: Replay secundário N=20; apenas tentativas iniciadas geram custo. Oracle conhece os rótulos e preserva todos os corretos.

| Política | Tarefas resolvidas | Tokens médios | Falsos abortos iniciados |
|---|---|---|---|
| fixed | 94/120 | 873,26 | 0 |
| verifier | 94/120 | 342,99 | 0 |
| B | 94/120 | 342,38 | 1 |
| H+B | 88/120 | 334,85 | 64 |
| oracle | 94/120 | 77,36 | 0 |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 21: Nova reserva MBPP+, gates de origem em t=8: custo e resolução para N=1,5,10,20 e calibração com dez bins de largura 0,1, ponderada por tarefa. Resultados secundários descritivos, sem seleção de política no alvo.




Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Os CSVs publicam todos os orçamentos N=1,5,10,20, custos, perdas de cobertura, retenções, calibração e denominadores dos abortos iniciados. A auditoria reabriu as ativações de ambas as fases, conferiu todas as identidades e seeds e reaplicou os scorers congelados. A hipótese nova versa sobre transporte relativo de decisões; seu suporte não confirma ganho incremental de representações, os critérios Q2/H3 originais, uma causa de domain shift ou superioridade universal de um método.

São novas tarefas sem resultados locais anteriores, não tarefas certificadamente ausentes do pré-treinamento. O bootstrap pressupõe intercambiabilidade entre tarefas da população; a reserva determinística por hash não é um censo nem valida outros modelos ou benchmarks. Os intervalos secundários são pontuais. O replay mede tokens e resolução, sem demonstrar economia de latência, energia ou FLOPs. Nenhum resultado retrospectivo substituiu o critério aprovado. Há 94 tarefas com algum correto ativo e 26 sem correto ativo. 33 tarefas contêm decisões discordantes dos gates. A faixa das estimativas com uma tarefa retirada é [−0,168; −0,150]; são diagnósticos condicionais aos scorers, sem alterar a amostra ou testar significância de cada exclusão.

Uma sensibilidade posterior agrupa os pares de prompts sinalizados pela auditoria textual: 118 clusters, estimativa −0,1636 e IC95% [−0,240; −0,095]. Os pares são variantes de máximo/mínimo sobre tuplas ou listas heterogêneas, com exemplos compartilhados. Esse agru-

pamento heurístico não substitui o bootstrap por tarefa aprovado nem certifica independência semântica.

# 7 DISCUSSÃO E LIMITAÇÕES

## 7.1 Interpretação dos resultados do desenho fixo

O incremento primário não satisfaz os critérios estabelecidos antes do banco principal. A comparação por tarefa evita confundir facilidade entre problemas com ordenação de trajetórias de um mesmo problema. O valor observado é −0,047, IC 95% [−0,099; 0,006]. Mesmo um efeito positivo não demonstra mecanismo causal: o estado é uma representação do prefixo produzido pelo próprio modelo.

Os critérios conjuntos para afirmar benefício operacional não foram satisfeitos. A conclusão operacional depende das duas comparações pareadas, do risco de perder sucessos e da execução real. O custo em tokens não mede automaticamente tempo, energia ou custo de prefill. A transferência constitui um teste de transportabilidade limitado a outro benchmark de código.

Os intervalos de bootstrap mantêm os modelos OOF fixos; não incluem toda a variabilidade do procedimento de treino. As tarefas HumanEval não são inteiramente inéditas ao histórico da pesquisa: 26 tarefas principais estão presentes em artefatos anteriores. O protocolo é de desenho fixo com execução autorizada pelo estudante; o registro histórico v0.2 não contém aprovação do orientador arquivada e não se reivindica pré-registro independente. Resultados secundários e históricos preservam a regra principal e seus critérios de confirmação.

## 7.2 Síntese dos diagnósticos exploratórios

O intervalo principal de ΔWT-AUC vai de −0,0994 a 0,0056. O Δlog loss é 0,0379, IC 95% [0,007; 0,071]. Esses limites descrevem a precisão alcançada sob modelos fixos; não são uma prova de equivalência nem de ausência geral de sinal.

Em MBPP+, o gate H+B retém 276 dos 366 candidatos corretos ativos (0,7541, IC 95% [0,619; 0,877]). O alvo empírico de 0,97 no desenvolvimento não constitui garantia externa. A retenção observada descreve o transporte do gate congelado, sem identificar isoladamente as causas de diferenças entre origem e alvo.

## 7.3 O que explica e o que permanece indeterminado

As ablações distinguem o resultado de um procedimento da alegação de ausência de informação. PCA e o offset ancorado em B reduzem a desvantagem do H+B original, mas não demonstram superioridade sobre B nos intervalos adicionais. Penalização conjunta mais forte não oferece a mesma recuperação. Portanto, a parametrização merece atenção; dimensão, coordenadas, penalização e calibração não foram isoladas como causas independentes. A baixa correlação entre escores tampouco certifica utilidade incremental ou independência condicional.

O diagnóstico do gate revela uma falha de transporte de decisões de alta retenção empírica. Os descartes se concentram em parte das tarefas e podem eliminar toda sua cobertura. Diferenças entre origem OOF, desenvolvimento e aplicação de um modelo completo ao alvo impedem uma atribuição causal simples a domain shift. O desenho independente mantém os

scorers e compara ambos os gates na mesma população ativa, sem escolher o melhor classificador exploratório.

O oracle mostra que há oportunidade econômica no banco quando é possível identificar perfeitamente os descartes. Grande parte desse potencial está em tarefas não resolvidas. A lacuna entre esse contrafactual e os gates disponíveis separa um problema de oportunidade computacional de um problema de decisão estatística. Ela não demonstra que um método online consiga fechar a lacuna.

### 7.4 Alcance da avaliação independente

A nova comparação usa 120 tarefas e o mesmo checkpoint para os dois gates. O contraste de retenções é −0,1636, IC95% [−0,240; −0,094] e satisfaz seu critério próprio. A revisão da proposta pelo orientador foi informada pelo estudante antes do congelamento. Esse registro não cria aprovação retroativa do protocolo original. A confirmação nova, quando sustentada, refere-se ao contraste de decisões congeladas; não identifica uma causa do transporte nem valida ganho incremental, latência ou outros modelos.

### 7.5 Validade interna

As partições agrupadas, escolhas internas, reconstrução dos scores e testes de prefixo foram auditados. Esses controles sustentam contratos específicos de isolamento e temporalidade. Não demonstram ausência de adaptação humana ao teste, de toda similaridade entre tarefas ou de contaminação no pré-treinamento. As escolhas múltiplas posteriores permanecem exploratórias, e a retenção de desenvolvimento não foi certificada independentemente.

O sinal pode refletir estilo, formatação, prefixos degenerados ou sintomas de erro sintático. Isso ainda pode ter utilidade para prever corretude funcional, mas não comprova compreensão semântica profunda do programa. Análises por classe de erro ajudam a delimitar a interpretação, desde que permaneçam secundárias.

### 7.6 Validade de mensuração e do verificador

Passar em uma suíte finita não equivale a satisfazer a especificação em todo domínio de entradas. Aumento de cobertura de testes reduz algumas falhas de mensuração, sem eliminá-las. Timeouts dependem de hardware e orçamento, e o parser pode afetar o rótulo. A qualidade da variável resposta precisa ser discutida junto da qualidade do probe.

O acesso a testes completos para parar a busca favorece o cenário com verificador. A comparação mede eficiência condicional a esse acesso; não estabelece o mesmo ganho em cenários sem um oráculo funcional confiável.

### 7.7 Validade externa e contaminação

Um único modelo pequeno e dois benchmarks de funções curtas não representam a variedade de repositórios, dependências, linguagens e tarefas de engenharia de software. Repetição de HumanEval durante desenvolvimento pode comprometer a novidade das tarefas para o pesquisador;

presença de exemplos no pré-treinamento compromete inferências sobre problemas inéditos. Nenhum split de probes remove contaminação no pré-treinamento.

A mudança de benchmark pode alterar a prevalência, os prefixos e a confiabilidade do score. Isso afeta tanto AUC quanto calibração e retenção. Uma política de alta retenção precisa ser reavaliada quando o regime muda, sem atribuir garantias por analogia.

### 7.8 Precisão estatística e escopo computacional

A amostra relevante para generalização contém tarefas, não milhares de observações independentes. Poucas tarefas mistas e poucos sucessos em certas posições tornam intervalos largos e limiares instáveis. Mais tentativas por tarefa estimam melhor sua variabilidade, mas não substituem automaticamente mais tarefas distintas.

Probes lineares podem falhar mesmo quando existe informação acessível a modelos não lineares. Portanto, um resultado negativo delimita a classe de leitura avaliada. Expansões para classificadores mais complexos precisam de orçamento e validação próprios; não são necessárias para produzir um resultado conclusivo sobre o desenho delimitado.

### 7.9 Trabalhos futuros

Extensões naturais incluem avaliação com benchmarks menos sujeitos a contaminação, verificadores incompletos separados dos testes finais, reinvestimento da economia em tentativas adicionais e repetição em outros modelos. Uma comparação com representações textuais mais fortes poderia aprofundar a interpretação de ganho sobre observáveis simples.

Activation Steering constitui uma pergunta posterior: se uma direção preditiva também permite modificar a distribuição de sucesso. Essa pergunta exigiria intervenções, controles e desenho causal próprios. Não se infere a resposta a partir da existência de um probe preciso.

## 8 CONSIDERAÇÕES FINAIS

A avaliação principal foi executada com 2.640 tentativas em 132 tarefas HumanEval+, precedida por piloto separado de 960 trajetórias. A validação aninhada agrupa tarefas e compara representações internas com observáveis disponíveis no mesmo prefixo. Em 32 tokens, ΔWT--AUC(H+B − B) foi −0,047, IC 95% [−0,099; 0,006] e Δlog loss foi 0,038, IC 95% [0,007; 0,071]. O resultado não satisfaz o critério de ganho incremental.

Os critérios conjuntos para afirmar benefício operacional não foram satisfeitos. A comparação com verificador e observáveis, o replay pareado e a validação real impedem atribuir ao probe economias disponíveis apenas pela parada após sucesso. A transferência para MBPP+ utiliza modelos congelados. As conclusões estão limitadas ao modelo, aos benchmarks e à população ativa avaliados. Exposição histórica, incerteza condicional e ausência de inferência robusta sobre latência são explicitadas. Replicações com novos modelos, benchmarks e tarefas externas independentes são extensões naturais.

Os diagnósticos exploratórios posteriores examinam a estabilidade entre tarefas, a composição temporal e a calibração sem alterar as decisões principais. A retenção de candidatos corretos ativos de H+B em MBPP+ foi 0,7541 (IC 95% [0,619; 0,877]), frente ao alvo empírico de 0,97 no desenvolvimento. Esses resultados delimitam a transportabilidade do sistema avaliado; extensões devem ser tratadas como novos estudos.

O aprofundamento exploratório mostra que a leitura e sua parametrização afetam o resultado: PCA e uma correção residual estritamente cross-fitted reduzem a desvantagem original sem estabelecer ganho sobre B. A anatomia dos descartes distingue perda de candidatos e de tarefas. O oracle retrospectivo quantifica oportunidade de economia e a derivação econômica explicita como retenção, overhead, orçamento e heterogeneidade limitam essa oportunidade. Essas contribuições delimitam o resultado negativo e fornecem hipóteses testáveis, sem convertê-lo em superioridade ou mecanismo causal. A avaliação independente aprovada foi concluída em 120 novas tarefas MBPP+. Em t=8, a diferença de retenção H+B−B é −0,1636, IC95% [−0,240; −0,094] e satisfaz o critério direcional definido antes das novas trajetórias. Esse endpoint é distinto dos critérios originais; suas limitações permanecem explícitas.

# REFERÊNCIAS


AZARIA, Amos; MITCHELL, Tom. **The Internal State of an LLM Knows When It's Lying**. 2023. Disponível em: <https://arxiv.org/abs/2304.13734>. Acesso em: 17 out. 2026.

BROWN, Bradley *et al*. **Large Language Monkeys: Scaling Inference Compute with Repeated Sampling**. 2024. Disponível em: <https://arxiv.org/abs/2407.21787>. Acesso em: 17 out. 2026.

CAWLEY, Gavin C.; TALBOT, Nicola L. C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. **Journal of Machine Learning Research**, v. 11, p. 2079–2107, 2010.

CHEN, Mark *et al*. **Evaluating Large Language Models Trained on Code**. 2021. Disponível em: <https://arxiv.org/abs/2107.03374>. Acesso em: 17 out. 2026.

DI CICCO, Carlo. **Code Correctness Is Linearly Decodable from LLM Hidden States Before Generation**. 2026. Disponível em: <https://arxiv.org/abs/2606.14530v3>. Acesso em: 17 out. 2026.

GREENLAND, Sander *et al*. Statistical tests, P values, confidence intervals, and power: a guide to misinterpretations. **European Journal of Epidemiology**, v. 31, p. 337–350, 2016.

GUO, Chuan *et al*. On Calibration of Modern Neural Networks. *In:* PMLR, 2017. Disponível em: <https://proceedings.mlr.press/v70/guo17a.html>. Acesso em: 17 out. 2026

HEWITT, John; LIANG, Percy. Designing and Interpreting Probes with Control Tasks. *In:* 2019. Disponível em: <https://aclanthology.org/D19-1275/>. Acesso em: 17 out. 2026

HUI, Binyuan *et al*. **Qwen2.5-Coder Technical Report**. 2024. Disponível em: <https://arxiv.org/abs/2409.12186>. Acesso em: 17 out. 2026.

KADAVATH, Saurav *et al*. **Language Models (Mostly) Know What They Know**. 2022. Disponível em: <https://arxiv.org/abs/2207.05221>. Acesso em: 17 out. 2026.

KLASSERT, Thomas. **Introspective Uncertainty Estimation for LLM-Based Code Generation**. 2026. Disponível em: <https://arxiv.org/abs/2609.13975v1>. Acesso em: 17 out. 2026.

LIU, Jiawei *et al*. **Is Your Code Generated by ChatGPT Really Correct? Rigorous Evaluation of Large Language Models for Code Generation**. 2023. Disponível em: <https://arxiv.org/abs/2305.01210>. Acesso em: 17 out. 2026.

OJALA, Markus; GARRIGA, Gemma C. Permutation Tests for Studying Classifier Performance. **Journal of Machine Learning Research**, v. 11, p. 1833–1863, 2010.

OVADIA, Yaniv *et al*. Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift. *In:* 2019. Disponível em: <https://papers.neurips.cc/paper_files/paper/2019/hash/8558cb408c1d76621371888657d2eb1d-Abstract.html>. Acesso em: 17 out. 2026

RATHNASURIYA, Ravishka; YANG, Wei. **Characterizing Overconfident Failure in LLM-Based Code Generation**. 2026. Disponível em: <https://arxiv.org/abs/2610.11300v1>. Acesso em: 17 out. 2026.

RUAN, Kai *et al*. **Doomed from the Start: Early Abort of LLM Agent Episodes via a Recall-Controlled Probe Cascade**. 2026. Disponível em: <https://arxiv.org/abs/2607.06503v2>. Acesso em: 17 out. 2026.

VASWANI, Ashish *et al*. **Attention Is All You Need**. 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 17 out. 2026.

WANG, Yiming *et al*. **Sampling-Efficient Test-Time Scaling: Self-Estimating the Best-of--N Sampling in Early Decoding**. 2025. Disponível em: <https://arxiv.org/abs/2503.01422v3>. Acesso em: 17 out. 2026.

ZHU, Yubo *et al*. **The LLM Already Knows: Estimating LLM-Perceived Question Difficulty via Hidden Representations**. 2025. Disponível em: <https://arxiv.org/abs/2509.12886v1>. Acesso em: 17 out. 2026.

ZOU, Andy *et al*. **Representation Engineering: A Top-Down Approach to AI Transparency**. 2023. Disponível em: <https://arxiv.org/abs/2310.01405>. Acesso em: 17 out. 2026.

# 9 REPRODUTIBILIDADE E HISTÓRICO METODOLÓGICO

## 9.1 Artefatos e comandos

O protocolo vigente está em `RESEARCH_PROTOCOL.md`; o anterior foi preservado em `docs/protocols/RESEARCH_PROTOCOL_v0.1.md`. O texto originalmente enviado foi preservado em `tcc/archive/`. O notebook executado é `notebooks/final_research_summary.ipynb`; sua exportação HTML permite leitura sem iniciar um kernel. O manifesto `reports/final_review/evidence.json` contém os hashes dos arquivos de entrada e o escopo de cada resultado.

```
$env:SLM_STEERING_TEST_TORCH = "1"
.venv/Scripts/python.exe -c `
 "import torch,pytest; raise SystemExit(pytest.main(['-q']))"
.venv/Scripts/python.exe scripts/build_research_delivery.py
.venv/Scripts/python.exe scripts/build_final_notebook.py --execute
.venv/Scripts/python.exe scripts/build_manuscript.py --compile
```

A geração de evidência precisa dos arquivos históricos em `runs/`; o notebook apresenta os resultados já exportados. Os capítulos de fundamentação e método são editáveis. As seções empíricas são geradas a partir de um único manifesto, reduzindo divergência entre números no texto, tabelas e notebook.

## 9.2 Correções da versão 0.2

Quadro 6: Correções metodológicas registradas na versão 0.2.

| Dimensão | Implementação revisada |
|---|---|
| Desfecho | Aprovação funcional; truncamento registrado separadamente |
| Temporalidade | Término antes do gate; conjunto ativo estrito |
| Margem de logits | Após temperatura e antes do top-p |
| Seleção e calibração | Cross-fitting da seleção; avaliação externa por tarefa |
| Inferência | Associação por fold; incremento por deltas externos pareados |
| Política | Busca por custo em todos os limiares admissíveis, incluindo ausência de aborto |
| Transferência | Bundle treinado na origem, congelado antes da coleta alvo |

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Nenhuma alteração é apresentada como anterior a resultados já conhecidos. Há arquivos históricos de 30 tarefas HumanEval, incluindo 26 do conjunto hoje reservado para a avaliação principal. Essa exposição é diferente de vazamento entre os folds de treinamento, mas limita alegações de um teste totalmente intocado pelo pesquisador. A aprovação científica e o congelamento continuam sendo decisões reais do aluno e do orientador.

Em 14 de outubro de 2026, o estudante autorizou a execução integral. A emenda administrativa e o snapshot verificável dos fontes registram essa autorização antes do banco principal. O registro histórico mantém pendente a aprovação do orientador; não se infere aprovação a partir da execução e não se reivindica pré-registro independente. O arquivo normativo original

foi preservado para manter a proveniência do piloto, então em andamento. A validação online usa as primeiras 12 tarefas por ID lexicográfico, sem escolha por economia observada.

A extensão EXCELLENCE_EXTENSION_v1 tem aprovação posterior própria: o estudante aprovou a proposta e informou revisão do orientador antes do snapshot de 46 arquivos e das novas trajetórias. Esse relato não foi convertido em assinatura nem aprovação retroativa do experimento original. Os helpers de parsing e dataset, omitidos como entradas separadas do snapshot, coincidem com os bytes recuperados do HEAD e patch preservados antes da aprovação; o recibo explicita essa limitação. Comandos de análise estatística, publicação e coleta longa estão separados em `docs/FINAL_REPRODUCIBILITY.md`. Análise e compilação não iniciam nova geração.

### 9.3 Integridade e assistência computacional

Em 15 de outubro de 2026, uma sessão de coleta foi interrompida por bloqueio temporário do Windows durante a substituição atômica do manifesto JSON. A auditoria confirmou 2.433 registros completos, que foram preservados na retomada. O launcher `scripts/run_research_safely.py` acrescenta tentativas limitadas a dez segundos para essa operação de filesystem. Os fontes científicos congelados, os bytes publicados, as sementes e os procedimentos numéricos permanecem preservados. O registro administrativo, os hashes da camada de compatibilidade e o teste com bloqueio real estão documentados em `docs/windows_execution_recovery.md` e nos artefatos de recuperação em `reports/research/`. O manifesto preservado da sessão interrompida registra pico reservado de 5.582 MiB, superior ao pico de aproximadamente 4,49 GiB do piloto. O valor da última sessão concluída, isoladamente, não resume o pico de toda a coleta.

Os testes verificam rótulos, sementes, posições, término exatamente no checkpoint, contabilidade do replay, isolamento de tarefas e ausência de ajuste com rótulos do benchmark de transferência. Nenhum teste demonstra, por si só, ausência de adaptação humana ao conjunto de dados. O histórico de decisões complementa as verificações automatizadas.

Esta versão foi preparada com assistência de um agente de programação para implementação, auditoria, organização dos artefatos e revisão textual. A autoria científica requer que o pesquisador confira a argumentação, as referências e as decisões experimentais e assuma responsabilidade pela versão submetida.

### 9.4 Diagnósticos posteriores à análise principal

Após a conclusão das 19 etapas e a inspeção de seus resultados, a solicitação de análises mais completas motivou uma extensão exploratória de publicação. `scripts/analyze_research_robustness.py` reproduz as análises sem ajuste de modelos, calibradores ou limiares. Os fontes científicos congelados e todos os bancos permanecem idênticos por hash. A publicação anterior e os hashes protegidos estão em `reports/research/publication_before_supplement_20261016/`.

Os diagnósticos incluem contrastes pareados por tarefa, folds externos, influência da exclusão de uma tarefa, coorte comum $T > 64$, sensibilidade à exclusão das tarefas presentes no histórico, calibração da probabilidade positiva em dez bins fixos e transporte da retenção dos corretos. Cada tarefa tem peso total igual nas perdas e na calibração; a retenção usa razão das contagens de candidatos, reamostrando tarefas como clusters. São 2.000 reamostragens com seed 20260921, sem refazer treinamento.

O gerador exige reprodução das estimativas e intervalos principais. As extensões não introduzem margens de equivalência nem substituem os critérios originais. Os intervalos são pontuais e condicionais aos escores; comparações exploratórias múltiplas não recebem interpretação confirmatória. A coorte de trajetórias longas condiciona no comprimento final; a exclusão histórica não refaz modelos nem apaga decisões anteriores. O relatório complementar exporta tabelas por tarefa e bin, figuras vetoriais, definições e proveniência.