FUNDAÇÃO GETULIO VARGAS

ESCOLA DE MATEMÁTICA APLICADA

João Felipe Vilas Boas

SINAIS LATENTES PRECOCES DE CORRETUDE EM GERAÇÃO DE CÓDIGO

Avaliação intratarefa, custo de inferência e robustez entre modelos e decodificadores

Rio de Janeiro
2026

João Felipe Vilas Boas

SINAIS LATENTES PRECOCES DE CORRETUDE EM GERAÇÃO DE CÓDIGO

Avaliação intratarefa, custo de inferência e robustez entre modelos e decodificadores

Trabalho de Conclusão de Curso apresentado à Escola de Matemática Aplicada da Fundação Getulio Vargas como requisito para obtenção do grau de bacharel em Matemática Aplicada.

Orientador: Prof. Dário Oliveira.

Rio de Janeiro
2026

RESUMO

Este trabalho investiga se estados internos precoces de modelos de linguagem especializados em código distinguem tentativas corretas e incorretas da mesma tarefa, acrescentando valor preditivo a estatísticas observáveis do prefixo. A análise separa previsibilidade agregada, discriminação intratarefa, qualidade probabilística e utilidade operacional. A primeira etapa avalia Qwen2.5-Coder-1.5B-Instruct em 2.640 tentativas de 132 tarefas HumanEval+, com probes lineares e validação aninhada por tarefa. Em 32 tokens, a diferença de WT-AUC de H+B em relação a B é −0,047, IC95% [−0,099; 0,006], sem satisfazer o critério incremental original. Ablações exploratórias com PCA e correção residual reduzem a desvantagem, sem demonstrar superioridade. Uma validação independente em 120 tarefas MBPP+ encontra retenção de corretos ativos de 82,72% para H+B e 99,08% para B nos gates anteriores de oito tokens, evidenciando uma limitação de transporte. A segunda etapa acrescenta DeepSeek-Coder-1.3B--Instruct e compara regressão logística e MLP pequeno nos dois geradores. Os procedimentos são ajustados em HumanEval+ e congelados antes de quatro mil gerações externas nas mesmas cem tarefas MBPP+ por modelo. No contraste primário DeepSeek/MLP, a diferença é −0,0042, IC95% [−0,0648; 0,0548], em 58 tarefas mistas: resultado inconclusivo, sem ganho ou equivalência demonstrados. Métricas probabilísticas secundárias e replay de políticas de interrupção mostram comportamentos distintos entre modelos e probes; economia de tokens não demonstra redução de latência. A formulação de decisão sequencial relaciona probabilidade de sucesso, custo restante, orçamento e penalidade por não resolver. Nas condições avaliadas, capacidade preditiva dos estados não implica incremento aproveitável nem benefício econômico confiável. A quantidade de tarefas mistas e a incerteza de treinamento limitam a precisão; os intervalos são condicionais aos probes ajustados.

Palavras-chave: geração de código; sinais latentes; avaliação intratarefa; probes não lineares; decisão sequencial.

ABSTRACT

This work investigates whether early hidden states of code language models, assessed through hidden-state probing, distinguish correct and incorrect attempts for the same task and provide incremental predictive value beyond observable prefix statistics. The analysis separates aggregate predictability, within-task discrimination, probabilistic accuracy, and operational utility. The first stage evaluates Qwen2.5-Coder-1.5B-Instruct on 2,640 attempts across 132 HumanEval+ tasks using linear probes and task-grouped nested validation. At 32 tokens, the H+B versus B within-task AUC difference is −0.047, with a 95% interval [−0.099, 0.006], failing the original incremental-value criterion. Exploratory PCA and residual-correction ablations reduce the disadvantage without demonstrating superiority. An independent evaluation on 120 MBPP+ tasks finds active-correct-candidate retention of 82.72% for H+B and 99.08% for B under the earlier eight-token gates, exposing a transfer limitation. The second stage adds DeepSeek--Coder-1.3B-Instruct and compares logistic regression and a small MLP in both generators. Procedures are developed on HumanEval+ and frozen before an external evaluation comprising 4,000 generations on the same 100 MBPP+ tasks per generator. The primary DeepSeek/MLP contrast is −0.0042, with a 95% interval [−0.0648, 0.0548], across 58 mixed tasks: inconclusive evidence establishing neither improvement nor equivalence. Secondary probabilistic metrics and early-abort policy replay show different behavior across generators and probes; token savings do not establish latency gains. The sequential decision formulation relates success probability, remaining cost, budget, and failure penalties. Under the tested conditions, hidden--state predictability does not imply accessible incremental value or reliable economic benefit. Mixed-task counts and training variability limit precision; confidence intervals quantify statistical uncertainty conditional on the fitted probes.

Keywords: code generation; hidden states; within-task evaluation; nonlinear probes; sequential decision making.

SUMÁRIO

1 Introdução 6
1.1 Gerar uma solução e decidir quando continuar 6
1.2 O que significa um sinal de corretude 6
1.3 Objetivos e sequência de evidências 7
1.4 Contribuições e delimitação 8
2 Trabalhos relacionados e posicionamento 9
2.1 Amostragem repetida e verificação funcional 9
2.2 Representações internas e estimação de corretude 9
2.3 Duas famílias de geradores de código 10
2.4 Dificuldade e interrupção adaptativa 10
2.5 Complexidade do probe e transporte de probabilidades 10
2.6 Interrupção como decisão sequencial 11
2.7 Contribuição delimitada e limites da reivindicação 11
2.8 Matriz de posicionamento 12
3 Fundamentação matemática e computacional 13
3.1 Formulação probabilística e notação 13
3.2 Transformers, espaço latente e extração causal 14
3.3 Dificuldade da tarefa e sinal específico da trajetória 17
3.4 Capacidade do decodificador de corretude 19
3.5 Amostragem repetida, seleção e custo 20
3.6 Decisão sequencial sob orçamento finito 24
4 Metodologia 27
4.1 Desenho geral e estatuto das análises 27
4.2 Geração, corretude e informação disponível 27
4.3 Primeira etapa: avaliação Qwen e desenvolvimento exploratório . . . 29
4.4 Segunda etapa: comparação entre modelos e classes de probes 30
4.5 Métricas, denominadores e inferência 33
4.6 Replay e contabilidade do custo 33
4.7 Condições computacionais e integridade 34
5 Primeira etapa: Qwen, transferência e diagnósticos 35
5.1 Composição do banco e comparação intratarefa 35
5.2 O resultado de classificação e a política original 36
5.3 Transporte para MBPP+ e validação independente dos gates 38
5.4 O que as ablações exploratórias acrescentam 38
5.5 O espaço econômico disponível 39
6 Comparação entre modelos e decodificadores 40
6.1 Desenvolvimento, precisão e população externa 40
6.2 Hipótese primária: incremento no DeepSeek com MLP 41

6.3 Capacidade do probe e diferenças entre geradores 42
6.4 Probabilidades, ranking e calibração 43
6.5 Replay secundário e consequência das decisões 44
6.6 Recursos medidos e síntese da etapa 46
7 Discussão 47
7.1 Uma resposta articulada às perguntas do estudo 47
7.2 O que o resultado inconclusivo permite afirmar 47
7.3 Capacidade do probe e acesso ao sinal 48
7.4 Modelo, tokenizer e população sob risco 48
7.5 Probabilidades, limiares e transporte 49
7.6 O que a economia observada representa 49
7.7 A contribuição da formulação sequencial 50
7.8 Limitações de precisão e de validade 50
7.9 Continuidade científica 51
8 Considerações finais 52
Referências 53
APÊNDICE A — Reprodutibilidade e proveniência 55
A.1 Separação entre análise e redação 55
A.2 Artefatos científicos de referência 55
A.3 Cronologia e exposição anterior 56
A.4 Integridade temporal, funcional e operacional 56
A.5 Assistência computacional e responsabilidade 57

1 INTRODUÇÃO

1.1 Gerar uma solução e decidir quando continuar

Um modelo de linguagem pode produzir programas diferentes para a mesma especificação. Alguns passam nos testes; outros falham por erros de sintaxe, de execução ou de lógica. Essa variabilidade permite melhorar a cobertura por amostragem repetida: mesmo quando a primeira tentativa falha, outra pode fornecer uma solução válida. HumanEval consolidou a avaliação por corretude funcional e a medida pass@k (Chen et al., 2021). Estudos de amostragem repetida também mostram que o orçamento de inferência pode aumentar a cobertura de tarefas, desde que exista um meio adequado de verificar ou selecionar as respostas (Brown et al., 2024).

O aumento de cobertura exige mais computação. Para cada candidato, o sistema processa o enunciado, gera tokens e verifica o programa extraído. Parte desse esforço é aplicada a respostas que não serão utilizadas. Surge então a possibilidade de reconhecer uma tentativa pouco promissora enquanto ela ainda está sendo gerada e interrompê-la antes do término.

A dificuldade está no compromisso entre economia e perda de soluções. Um prefixo aparentemente ruim pode admitir uma continuação correta. Ao interromper a primeira solução que resolveria o problema, o controlador talvez precise iniciar outras tentativas ou encerre a busca sem sucesso. Portanto, uma previsão de corretude não basta para demonstrar uma política econômica: é necessário avaliar o momento da decisão, os sucessos descartados, as tarefas resolvidas e o custo efetivo.

Este trabalho investiga esse problema em Qwen2.5-Coder-1.5B-Instruct e DeepSeek--Coder-1.3B-Instruct, dois modelos pequenos especializados em código. O termo **Small Language Model** (SLM) designa aqui seu porte aproximado, sem pressupor uma fronteira universal entre modelos pequenos e grandes. Os experimentos foram executados em uma GPU pessoal de 6 GB. Essa restrição motiva um desenho compacto, mas não substitui os controles necessários à interpretação científica.

1.2 O que significa um sinal de corretude

Há quatro perguntas distintas por trás da expressão “prever corretude”. A primeira é reconhecer tarefas em que o gerador costuma acertar. A segunda é distinguir tentativas corretas e incorretas **da mesma tarefa**. A terceira é verificar se o estado interno acrescenta poder preditivo a estatísticas observáveis do prefixo. A quarta é estabelecer se esse acréscimo melhora uma decisão de interrupção. Uma resposta favorável em um nível não implica uma resposta favorável no seguinte.

Considere um classificador que atribui a mesma probabilidade elevada a todas as respostas de um problema fácil e uma probabilidade baixa a todas as respostas de um problema difícil. Ele pode ordenar bem as respostas quando os dois problemas são misturados, mas não indica qual tentativa merece continuar dentro de nenhum deles. A avaliação intratarefa é necessária para separar essas situações.

As representações internas são vetores calculados pelo Transformer a partir do enunciado e dos tokens já processados. Um **probe**, ou decodificador estatístico de corretude, relaciona essas representações ao resultado funcional futuro, sem alterar os pesos do gerador. Ele é diferente do mecanismo que amostra o próximo token. Neste texto, H representa o estado latente selecionado e B reúne observáveis como logprobabilidades, entropia e margem de logits. O contraste central compara um probe que usa apenas B com outro que usa $H + B$.

Esse contraste depende também da capacidade do classificador. Se apenas $H + B$ recebesse uma rede neural, uma eventual melhora poderia decorrer da classe de funções mais expressiva, e não do uso de H. Por isso, a segunda etapa cruza os dois conjuntos de features com regressão logística e um MLP pequeno de uma camada oculta, aplicando o mesmo desenho aos dois geradores. A comparação entre modelos e entre classes de probes integra, assim, a pergunta sobre o alcance dos resultados.

> **Pergunta central**
> Em modelos pequenos de geração de código, estados internos disponíveis após um prefixo curto melhoram a discriminação de corretude entre tentativas da mesma tarefa, além dos observáveis escolhidos, e esse ganho depende da classe do probe ou se traduz em uma política de interrupção útil?

"Além dos observáveis" significa além do vetor B especificado. Não significa informação adicional em relação ao prompt, ao prefixo completo e ao conhecimento integral do gerador, pois o estado interno é uma função desses elementos. Tampouco se interpreta um probe como consciência ou conhecimento infalível do futuro.

1.3 Objetivos e sequência de evidências

O objetivo geral é avaliar o valor incremental e operacional dos estados internos precoces, distinguindo o que cada procedimento consegue acessar e o que permanece incerto. Cinco perguntas articulam a obra:

Quadro 1: Perguntas que organizam as duas etapas do estudo.

Pergunta	Evidência necessária
Q1 — Previsibilidade	Estimar corretude separando diferenças entre tarefas e entre tentativas.
Q2 — Incremento	Comparar $H + B$ e B com a mesma informação temporal e a mesma classe de probe.
Q3 — Capacidade e modelo	Investigar a contribuição de H com logística e MLP, em Qwen e DeepSeek.
Q4 — Transporte	Avaliar probabilidades e decisões congeladas em tarefas externas, sem reajuste no alvo.
Q5 — Decisão e custo	Medir resolução, custo e distância a um oracle contrafactual que conhece os resultados.

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Essas perguntas organizam a redação final; não substituem retrospectivamente os identificadores ou os critérios dos protocolos executados. A investigação teve duas etapas, conectadas por diagnósticos exploratórios. A primeira avaliou Qwen em HumanEval+, com probes lineares, validação aninhada por tarefa e checkpoint principal de 32 tokens. A transferência para MBPP+ e uma validação independente de gates congelados examinaram o transporte das decisões. Após a inspeção desses resultados, ablações com PCA e correção residual investigaram a sensibilidade à parametrização.

A segunda etapa transformou essa limitação em uma pergunta prospectiva: no DeepSeek, $H + B$ com MLP melhora a WT-AUC em relação a B com MLP aos 32 tokens? Os procedimentos foram desenvolvidos em HumanEval+, e ambos os geradores foram avaliados nas mesmas cem tarefas MBPP+ sem resultados locais anteriores. Cada um produziu vinte respostas por tarefa: quatro mil novas gerações externas. DeepSeek/MLP é o contraste confirmatório primário dessa etapa; as demais comparações e o replay são secundários.

Essa cronologia é parte da interpretação científica. Os diagnósticos motivaram a segunda etapa, mas não se tornam confirmatórios porque agora aparecem em uma obra integrada. Da mesma forma, a extensão não altera os números ou as decisões originais. O encadeamento permite investigar o alcance de um resultado inicial sem apresentar escolhas posteriores como se tivessem sido antecipadas.

1.4 Contribuições e delimitação

A contribuição empírica combina controle por tarefa, comparação com observáveis, duas classes de probes e avaliação externa em duas famílias de SLMs. A contribuição metodológica é tornar explícito por que AUC agregada, ordenação intratarefa, qualidade probabilística e utilidade de interrupção exigem estimandos distintos. A formulação sequencial relaciona probabilidade de sucesso, custo restante, orçamento e penalidade por insucesso; trata-se de uma aplicação delimitada de programação dinâmica, sem reivindicação de teorema inédito.

Nenhuma das duas etapas demonstrou ganho incremental de WT-AUC em seu contraste primário. Esse resultado não autoriza uma afirmação universal de ausência de sinal latente. Há diferenças entre as métricas probabilísticas e de ranking, e entre as consequências operacionais dos modelos. A análise dessas diferenças, com seus intervalos e denominadores, constitui o centro da discussão.

O alcance permanece restrito a dois modelos, dois benchmarks de funções Python relativamente curtas e às classes de probes examinadas. Ambos os benchmarks são públicos; a auditoria de exposição local não elimina contaminação no pré-treinamento. Não foram avaliadas intervenções causais nas ativações, projetos com múltiplos arquivos ou políticas que reinvistam a economia em novas tentativas.

A fundamentação e a metodologia antecedem os resultados das duas etapas, apresentados no capítulo 5 e no capítulo 6. A discussão e a conclusão reúnem as respostas à pergunta central.

2 TRABALHOS RELACIONADOS E POSICIONAMENTO

2.1 Amostragem repetida e verificação funcional

Chen et al. (2021) formulam a avaliação de programas gerados por meio de testes e apresentam um estimador de pass@k baseado em múltiplos candidatos. Brown et al. (2024) estudam o aumento de cobertura obtido com mais amostras e destacam a relevância da seleção e verificação. Esses trabalhos motivam a separação entre a capacidade de gerar ao menos uma solução correta e a capacidade de identificá-la.

A qualidade do verificador também importa. Liu et al. (2023) apresentam EvalPlus e a ampliação dos testes de HumanEval para HumanEval+, mostrando que testes mais completos revelam falhas que os testes originais não identificam. Neste projeto, a variável resposta é passar em uma versão fixada dessa suíte. Isso fornece um critério reproduzível, mas não uma prova de correção para todas as entradas possíveis.

2.2 Representações internas e estimação de corretude

Kadavath et al. (2022) diferenciam a avaliação de uma resposta específica da estimativa de que o modelo saberá responder uma pergunta. Essa distinção é próxima da separação entre nível da tarefa e nível da trajetória adotada aqui. Azaria; Mitchell (2023) estudam classificadores sobre ativações internas para identificar veracidade de afirmações, comparando-os também a medidas baseadas na probabilidade da sequência. A abordagem de Representation Engineering organiza a investigação de fenômenos de alto nível em padrões distribuídos das ativações (Zou et al., 2023).

Em geração de código, Di Cicco (2026) reporta decodificação linear de corretude a partir do estado do último token do prompt em Qwen3-4B-Instruct-2507 sobre tarefas de LiveCode-Bench. O resultado demonstra a relevância de estados anteriores à geração para discriminação entre tarefas. Por construção, porém, um estado determinístico do mesmo prompt é compartilhado pelas suas diferentes tentativas. Essa observação motiva uma avaliação adicional entre trajetórias do mesmo problema.

Klassert (2026) investiga estimação de incerteza introspectiva em geração de código, com características estáticas e dinâmicas e avaliações no nível da resposta e da linha. O resumo do trabalho reporta sinal de corretude no nível da resposta, sem ganhos consistentes das estratégias dinâmicas mais elaboradas. Isso reforça a opção por um probe simples como experimento principal; não justifica assumir que uma dinâmica temporal mais complexa será superior.

Rathnasuriya; Yang (2026) examinam sobreconfiança em quatro modelos de código e três benchmarks de execução. Confiança e entropia oferecem discriminação parcial e dependente do modelo; seleção por incerteza não melhora consistentemente a acurácia do conjunto aceito. A análise latente é exploratória. Esse antecedente recente aproxima a literatura da comparação entre observáveis e estados internos, mas não estabelece o estimando intratarefa nem o custo sequencial dos gates específicos avaliados neste TCC. Resultados de modelos de 7–

8 bilhões de parâmetros não são transferidos numericamente aos dois SLMs de 1,3 e 1,5 bilhão avaliados aqui.

2.3 Duas famílias de geradores de código

Qwen2.5-Coder (Hui et al., 2024) e DeepSeek-Coder (Guo et al., 2024) são famílias de modelos especializados em programação. Seus relatórios fundamentam a escolha de geradores de pesos públicos e portes próximos, mas não respondem à pergunta deste estudo: obter bom desempenho funcional em um benchmark é diferente de oferecer um estado precoce que permita ordenar as próprias tentativas corretas e incorretas. Aqui se utilizam as variantes de aproximadamente 1,5 e 1,3 bilhão de parâmetros especificadas na metodologia.

Arquitetura, tokenizer e template fazem parte do regime de geração. Não se procura alinhar coordenadas latentes ou comparar entropias como se os vocabulários fossem os mesmos. Cada gerador tem seu próprio contraste entre $H + B$ e B. As tarefas externas comuns tornam a comparação mais informativa, mas não igualam automaticamente as populações que permanecem ativas em 32 tokens.

2.4 Dificuldade e interrupção adaptativa

Zhu et al. (2025) estimam dificuldade percebida pelo modelo a partir de representações iniciais e aplicam essa informação a estratégias de inferência adaptativa. Ruan et al. (2026) estudam interrupção de episódios de agentes a partir de probes em estados internos, com controle de retenção e certificação em dados independentes. Seu cenário, unidade temporal e procedimento de garantia diferem de uma regra empírica ajustada em prefixos de código.

O método ST-BoN (Wang et al., 2025) utiliza estados internos em uma estratégia de truncamento e seleção de candidatos. Esse antecedente impede apresentar o uso de hidden states para reduzir o custo de Best-of-N como novidade isolada. A comparação do presente estudo concentra-se na corretude funcional supervisionada, na discriminação dentro da tarefa e na comparação controlada com observáveis.

2.5 Complexidade do probe e transporte de probabilidades

Hewitt; Liang (2019) mostram que o desempenho de um probe pode refletir sua capacidade de aprender a tarefa, motivando controles e restrições de complexidade. Seus controles linguísticos diferem da permutação de rótulos intratarefa utilizada aqui. As ablações com PCA, penalização e offset residual avaliam a sensibilidade à parametrização; não identificam, sozinhas, um mecanismo semântico ou a ausência de informação acessível a outros decodificadores.

Ovadia et al. (2019) avaliam incerteza sob mudanças de distribuição e documentam limitações do transporte da calibração. Isso motiva avaliar o gate congelado por suas decisões, além do ranking. O presente estudo distingue escores OOF da origem, escores de desenvolvimento usados na seleção do gate e aplicação de um modelo ajustado em toda a origem ao novo benchmark. Essa distinção impede atribuir toda diferença a um único efeito de domínio.

Na comparação entre classes de probes, uma rede não linear pode expressar interações que a logística não representa diretamente, mas também acrescenta parâmetros e variabilidade de ajuste. Esse aumento de capacidade precisa ser oferecido ao baseline B. Por isso, a segunda etapa cruza logística e MLP com B e $H + B$, mantendo a redução de dimensão latente e as regras de validação correspondentes. O desenho examina acessibilidade a classes restritas, sem presumir superioridade do MLP ou identificar, por si só, um mecanismo semântico.

2.6 Interrupção como decisão sequencial

A escolha de continuar uma computação tem antecedentes em metarraciocínio. Russell; Wefald (1991) formulam a avaliação de ações computacionais por sua utilidade esperada; Callaway et al. (2018) estudam como aprender a selecionar computações considerando custo e valor esperado. No contexto de modelos de linguagem, Wan et al. (2025) formulam uma regra de parada para a busca por respostas completas. Esses antecedentes impedem apresentar o controle de inferência por programação dinâmica como novidade isolada.

O objeto específico deste estudo é a decisão sobre uma tentativa parcialmente gerada, com possibilidade de abandoná-la, iniciar outra ou encerrar a busca. A recursão de Bellman apresentada adiante organiza essas escolhas e explicita as hipóteses sob as quais um limiar de probabilidade poderia ser ótimo. Ela não transforma os gates empíricos em políticas ótimas ou certificadas.

2.7 Contribuição delimitada e limites da reivindicação

O trabalho não reivindica ter sido o primeiro a prever corretude com hidden states, o primeiro a estimar dificuldade nem o primeiro a interromper inferência com sinais internos. A contribuição é uma avaliação integrada e reproduzível, em um regime delimitado de geração de código, de três aspectos: separação entre tarefa e trajetória; poder incremental sobre baselines observáveis especificados; e utilidade em uma política sequencial de interrupção. A extensão exploratória aprofunda o resultado negativo com controles de parametrização, diagnóstico dos sucessos descartados e um limite econômico contrafactual. A derivação do custo por série geométrica e os métodos de PCA e validação não são apresentados como novidades teóricas.

As referências são identificadas por fontes primárias, com versão explícita quando fixada na bibliografia. Resultados resumidos não substituem a leitura integral dos métodos antes da comparação final. Em especial, alegações de ausência de trabalhos idênticos exigem revisão bibliográfica mais ampla; não são inferidas de uma busca limitada.

2.8 Matriz de posicionamento

Quadro 2: Posicionamento sintético em relação aos antecedentes discutidos na revisão bibliográfica.

Antecedente	Objeto principal	Relação com este estudo
Di Cicco	Corretude da primeira tentativa a partir do prompt	Motiva separar dificuldade e trajetória
Klassert	Incerteza introspectiva em respostas e linhas de código	Motiva o probe simples e limites da generalização
Rathnasuriya e Yang	Sobreconfiança, seleção e sinais latentes exploratórios	Exige separar ranking, calibração, retenção e custo sequencial
Zhu et al.	Dificuldade percebida e alocação de inferência	Comparação no nível da tarefa
Ruan et al.	Abortos em episódios de agentes	Retenção certificada difere de meta empírica
Wang et al. / ST-BoN	Consistência interna entre amostras e truncamento	Uso de estados internos para economia já possui antecedentes
Este estudo	Duas famílias de SLMs, logística/ MLP e replay pareado	Incremento sobre observáveis, transporte das decisões e limites da utilidade econômica

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

3 FUNDAMENTAÇÃO MATEMÁTICA E COMPUTACIONAL

O capítulo desenvolve o argumento em três níveis. Primeiro define a informação disponível durante a geração e a corretude de uma resposta. Depois separa dificuldade da tarefa, discriminação intratarefa e capacidade do probe. Por fim, formula o custo de interromper e de iniciar novas tentativas. As mesmas definições serão usadas nas duas etapas experimentais; os procedimentos de ajuste e os estimandos primários de cada protocolo serão distinguidos na metodologia.

3.1 Formulação probabilística e notação

3.1.1 Tarefas, candidatos e configuração

Seja $\mathcal{X}$ o espaço de tarefas e seja $x_i \in \mathcal{X}$ o prompt da tarefa i, incluindo especificação, assinatura e template fixado. O modelo tem parâmetros θ congelados. Uma configuração c reúne temperatura, top-p, limite de tokens, regras de parada, precisão e versão do tokenizer. A tentativa j produz a sequência aleatória $Y_{ij} = \left(Y_{ij1}, ..., Y_{ijT_{ij}}\right)$, de comprimento T_{ij}.

Distinguem-se a distribuição original do modelo, p_θ, e a distribuição efetivamente usada pelo decodificador, $q_{\theta,c}$. A lei da sequência amostrada é

$$q_{\theta,c}(y \mid x_i) = \prod_{u=1}^{T} q_{\theta,c}(y_u \mid x_i, y_{<u}). \tag{1}$$

O comprimento é determinado por término natural ou limite computacional. A distribuição da sequência incorpora as regras de parada. Tratar todos os candidatos como tendo comprimento fixo esconderia uma dimensão essencial do custo e da elegibilidade para interrupção.

A notação omite um índice de modelo para simplificar as expressões. Na comparação entre Qwen e DeepSeek, as distribuições de geração, os vocabulários e as dimensões dos estados são próprios de cada gerador. O índice de tarefa pode ser compartilhado; tokens e coordenadas latentes não são tratados como intercambiáveis.

Quadro 3: Notação do modelo de geração, corretude e custo sequencial.

Símbolo	Significado
i, j	Tarefa e tentativa.
x_i, c, θ	Prompt, configuração de inferência e parâmetros do modelo.
T_{ij}	Número de tokens gerados, incluindo os tokens de término conforme convenção registrada.
S_{ij}	Indicador de aprovação na suíte funcional.
ℓ, t	Camada do Transformer e posição relativa à completion.
$h_{ij\ell t}$	Estado interno após processar o token de completion t.
B_{ijt}, z_{ijt}	Vetor de observáveis e score do probe.
π_i	Probabilidade de sucesso de uma tentativa da tarefa i no regime fixado.
N, q	Número máximo de tentativas e limiar de interrupção.
A_i, C_i	Resolução da tarefa e custo acumulado de uma política.

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

3.1.2 Corretude operacional

Um verificador V recebe a tarefa e o programa extraído da completion. Sua saída define

$$S_{ij} = V\big(x_i, Y_{ij}\big) \in \{0,1\}, \quad \pi_i = P\big(S_{ij} = 1 \mid x_i, c\big). \tag{2}$$

O verificador é mantido fixo em versão, testes, ambiente e limites de execução. Falhas de sintaxe, execução, asserção e extração são classificadas como insucesso. Um timeout do programa é uma falha sob o orçamento especificado. Uma interrupção da infraestrutura de avaliação é um erro de medição e deve ser reexecutada ou marcada como dado indisponível, sem virar automaticamente um rótulo negativo.

Truncamento no limite de geração é registrado como atributo do candidato. O programa extraído é avaliado pela mesma regra funcional: um candidato que terminou por limite pode, excepcionalmente, já conter uma solução válida. Caso o protocolo deseje definir sucesso como "passa e não truncou", deve nomear essa variável separadamente e não confundi-la com corretude funcional. Esta versão adota a aprovação no verificador como rótulo principal.

3.1.3 Informação disponível durante a geração

Seja $\mathcal{F}_{ijt}$ a informação observável até o prefixo de comprimento t: prompt, tokens amostrados, distribuições de decodificação calculadas e estados acessíveis até esse instante. O resultado final é observado apenas depois de completar e testar o programa. O alvo ideal de um preditor precoce é

$$p^{*}_{ijt} = P\big(S_{ij} = 1 \mid \mathcal{F}_{ijt}\big). \tag{3}$$

Antes do término, o mesmo prefixo pode admitir continuações corretas e incorretas. Portanto, "trajetória com baixa chance de sucesso" não significa "trajetória inevitavelmente errada". Dois candidatos que compartilham exatamente o mesmo prefixo podem receber a mesma previsão e posteriormente obter rótulos diferentes.

Pela propriedade da esperança condicional, a sequência ideal p^{*}_{ijt} satisfaz, antes ou após absorção no término,

$$E\big[p^{*}_{ij,t+1} \mid \mathcal{F}_{ijt}\big] = p^{*}_{ijt}. \tag{4}$$

Essa identidade é uma propriedade do preditor probabilístico ideal. Não implica que o probe ajustado seja uma martingala, que a confiança cresça monotonamente em cada trajetória ou que a AUC estimada aumente a cada checkpoint.

3.2 Transformers, espaço latente e extração causal

3.2.1 Representações e atenção causal

Um Transformer representa tokens por vetores e aplica sucessivos blocos de atenção e transformações não lineares (Vaswani et al., 2017). Em notação esquemática, para uma matriz de estados H, uma cabeça de atenção calcula

$$Q = HW_Q, \quad K = HW_K, \quad U = HW_U, \tag{5}$$

$$\mathrm{Attn}(H) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)U. \tag{6}$$

A máscara causal M impede que uma posição consulte tokens posteriores. Conexões residuais, normalizações e transformações feed-forward produzem estados contextualizados. O espaço latente é o espaço vetorial dessas representações, com dimensão determinada pela arquitetura. Não é um espaço de significados com coordenadas semanticamente nomeadas por definição.

O estado $h_{ij\ell t} \in \mathbb{R}^d$ é uma função do prompt e do prefixo processado. Para um modelo determinístico em modo de avaliação,

$$h_{ij\ell t} = f_{\theta,\ell}\big(x_i, Y_{ij,1:t}\big). \tag{7}$$

A aleatoriedade da representação decorre principalmente da amostragem de tokens; pesos e procedimento de extração permanecem constantes. A investigação testa a acessibilidade do sinal à classe de decodificadores escolhida. Na segunda etapa, logística e MLP recebem a mesma representação latente; muda a função estatística que procura ler o sinal, e não o gerador de código.

3.2.2 Convenção temporal e alinhamento

O checkpoint $t = 0$ corresponde ao último token do prompt. Para $t > 0$, o estado é extraído após processar o token t da completion, e não o estado que foi usado para amostrar esse token. Em um decodificador autoregressivo, os logits usados para amostrar Y_t dependem do prefixo que termina em Y_{t-1}; o estado de Y_t participa da predição seguinte. Confundir essas posições produz um deslocamento de um token e invalida a interpretação temporal.

Um pipeline que para imediatamente depois de amostrar Y_t pode ainda não ter calculado o seu estado. É necessário processá-lo, sem amostrar Y_{t+1}, para decidir a interrupção. Esse forward adicional ou antecipado deve ser incluído na latência e no custo de operação. Contar t tokens gerados continua correto, mas não contabiliza sozinho todo o trabalho do Transformer.

3.2.3 Propriedade do estado anterior à amostragem

> **Proposição 1 — Ausência de discriminação antes da divergência**
> Com prompt, template, pesos e execução determinística fixados, o estado do último token do prompt é igual entre tentativas da mesma tarefa. Qualquer score determinístico calculado apenas desse estado também é constante dentro da tarefa.

Demonstração. Para todo j, $h_{ij\ell 0} = f_{\theta,\ell}(x_i)$. Logo, $z_{ij0} = g\big(f_{\theta,\ell}(x_i)\big)$ independe de j. Cada comparação entre uma tentativa correta e uma incorreta da tarefa resulta em empate. Uma AUC que atribui peso $\frac{1}{2}$ aos empates vale $\frac{1}{2}$ dentro dessa tarefa.

Esse resultado não impede que `prompt_last` apresente boa AUC entre tarefas. Ele o torna um baseline de dificuldade e um controle de integridade: diferenças relevantes entre repetições do mesmo prompt precisam ser explicadas por mudanças de entrada, dropout, extração

incorreta ou não determinismo numérico. Não devem ser interpretadas como previsão da seed futura.

3.2.4 Teste de ausência de informação futura

Para cada camada e posição selecionadas, compare a extração usando apenas o prefixo e a extração na mesma posição de uma passagem sobre a sequência completa:

$$h_{\ell,t}(x, y_{1:t}) \approx h_{\ell,t}(x, y_{1:T}). \tag{8}$$

A igualdade é esperada matematicamente sob atenção causal. Diferenças numéricas podem decorrer de precisão e kernels. O teste deve fixar tolerância absoluta e relativa, modo de avaliação, backend e convenção de normalização. Uma falha exige diagnóstico antes de usar as ativações. Este é um teste de integridade da causalidade temporal da arquitetura, não uma demonstração de que uma direção latente causa corretude.

3.2.5 Estatísticas observáveis do prefixo

Se q_u é a distribuição efetivamente amostrada na posição u, a NLL média até t é

$$\mathrm{NLL}_t = -\frac{1}{t}\sum_{u=1}^{t} \log q_u(Y_u). \tag{9}$$

Ela aumenta quando os tokens escolhidos recebem menor probabilidade do próprio gerador. A entropia de uma distribuição é

$$\mathrm{Ent}(q_u) = -\sum_{v \in \mathcal{V}} q_u(v) \log q_u(v), \tag{10}$$

em que $\mathcal{V}$ é o vocabulário. Ela descreve dispersão entre as alternativas, e não a corretude da resposta que será completada. A margem entre os dois maiores logits descreve outra forma de concentração. O vetor B utiliza resumos dessas grandezas até o checkpoint, sem acesso à continuação.

Uma resposta frequente e incorreta pode ter NLL baixa, assim como um programa correto pouco usual pode ter NLL maior. Esses resumos precisam ser avaliados empiricamente como preditores de corretude. Também não são medidas de confiança diretamente comparáveis entre vocabulários diferentes: a segunda etapa ajusta B separadamente em cada gerador.

3.2.6 Alcance informacional do estado interno

Se $H = f_\theta(X, P)$, em que P é o prefixo completo e o modelo é fixado, então H não acrescenta informação aleatória quando (X, P) já é integralmente conhecido. Em notação de informação mútua,

$$I(S; H \mid X, P) = 0. \tag{11}$$

A utilidade do estado está em representar o prefixo de modo que certas propriedades se tornem acessíveis a um preditor limitado. Assim, um ganho sobre NLL e entropia sustenta a afirmação de ganho sobre essas estatísticas, e não sobre todo método possível baseado no texto.

Essa restrição impede transformar um resultado de probing em uma alegação excessiva sobre introspecção.

3.3 Dificuldade da tarefa e sinal específico da trajetória

3.3.1 Heterogeneidade entre problemas

A probabilidade π_i varia com a tarefa e a configuração. Em um banco com n_i tentativas, a proporção $\hat{\pi}_i = \sum_j \frac{S_{ij}}{n_i}$ é uma estimativa descritiva dessa probabilidade. Uma tarefa sem sucessos observados não possui necessariamente probabilidade verdadeira zero; a amostra pode simplesmente não ter encontrado sua região de soluções corretas.

Para descrição do banco, definem-se três categorias mutuamente exclusivas: todas as tentativas corretas, resultados mistos e todas as tentativas incorretas. Esses nomes se referem aos resultados observados. Não autorizam afirmar que o modelo sempre acertará ou nunca resolverá o problema.

O número de tentativas influencia a classificação. Sob amostragem independente e n tentativas, a probabilidade de observar resultados mistos é

$$P(\text{mista} \mid \pi_i, n) = 1 - \pi_i^n - (1 - \pi_i)^n. \tag{12}$$

Assim, a análise entre tarefas mistas representa principalmente problemas com variabilidade detectável nesse orçamento. Não é uma amostra aleatória de todos os problemas de programação.

3.3.2 Decomposição da associação

Para um score Z e o indicador S, a lei da covariância total fornece

$$\mathrm{Cov}(Z, S) = \mathrm{Cov}(E[Z|X], E[S|X]) + E[\mathrm{Cov}(Z, S|X)]. \tag{13}$$

O primeiro termo captura a associação entre tarefas; o segundo, a associação dentro da tarefa. A decomposição é conceitual e não uma decomposição da AUC. Ela mostra por que uma associação agregada pode ser explicada inteiramente pela dificuldade do prompt.

Como exemplo estritamente ilustrativo, considere duas tarefas: uma com 90% de acertos e outra com 10%. Um score constante igual a 0,9 para a primeira e 0,1 para a segunda pode ordenar bem exemplos agregados. Entretanto, não distingue qual tentativa acertará dentro de nenhuma das tarefas. Nenhum desempenho numérico desse exemplo é um resultado do modelo estudado.

3.3.3 Discriminação dentro da tarefa

Sejam $\mathcal{P}_i$ e $\mathcal{N}_i$ os conjuntos de tentativas corretas e incorretas elegíveis da tarefa i. Define-se a AUC intratarefa por

$$\mathrm{AUC}_i = \frac{1}{|\mathcal{P}_i| \ |\mathcal{N}_i|} \sum_{j \in \mathcal{P}_i} \sum_{k \in \mathcal{N}_i} \psi\big(z_{ij} - z_{ik}\big), \tag{14}$$

em que $\psi(a)$ vale 1 se $a > 0$, $\frac{1}{2}$ se $a = 0$ e 0 se $a < 0$. A média por tarefas mistas é

$$\text{WT-AUC} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \text{AUC}_i. \tag{15}$$

Cada tarefa informativa recebe o mesmo peso. Uma média por todos os pares de candidatos daria maior peso a tarefas com mais pares positivo-negativo; seria outro estimando. A unidade principal de inferência é a tarefa, mesmo que milhares de pares sejam construídos a partir dela.

Tarefas com apenas uma classe não têm AUC intratarefa definida. Elas continuam nas métricas probabilísticas e operacionais. A exclusão da WT-AUC deve ser acompanhada dos respectivos denominadores, para que um resultado elevado em poucas tarefas não pareça representar todo o benchmark.

3.3.4 Informação incremental e hipótese operacional

Seja B_{ijt} um vetor fixado de características observáveis do prefixo. Compare um modelo que usa apenas B com outro que combina B e a ativação. Os estimandos centrais são

$$\Delta_W = \text{WT-AUC}_{H+B} - \text{WT-AUC}_B, \tag{16}$$

$$\Delta_L = \text{LogLoss}_{H+B} - \text{LogLoss}_B. \tag{17}$$

Valores positivos de Δ_W e negativos de Δ_L indicam ganho, mas os dois critérios avaliam propriedades diferentes: ordenação dentro da tarefa e qualidade de previsão probabilística. Um ganho robusto sustenta a utilidade incremental da representação para a classe de modelos comparada. Não demonstra independência condicional universal nem que todos os fatores semânticos ou estilísticos foram controlados.

A hipótese nula de ausência de qualquer sinal dentro da tarefa, S independente de Z dado X, difere da hipótese de ausência de informação adicional sobre B, isto é, S independente de Z dado (X, B). Essa distinção orienta a interpretação dos testes estatísticos posteriores.

3.3.5 Perdas probabilísticas e calibração

Para um resultado $S \in \{0, 1\}$ e uma previsão p entre zero e um, as duas perdas utilizadas são

$$\ell_{\log}(S, p) = -S \log p - (1 - S) \log(1 - p), \quad \ell_{\text{Brier}}(S, p) = (S - p)^2. \tag{18}$$

A log loss penaliza fortemente um erro ao qual se atribuiu probabilidade extrema. O Brier mede a distância quadrática entre probabilidade e resultado. Ao calcular a média, o estudo dá o mesmo peso total a cada tarefa contribuinte e divide esse peso entre suas tentativas ativas. Tarefas com somente acertos ou somente erros podem entrar nessas perdas, embora não identifiquem AUC intratarefa.

Calibração pergunta se respostas às quais se atribui probabilidade p acertam com frequência aproximadamente p na população considerada. A calibração Platt ajusta uma transformação logística do score bruto, $\sigma(az + b)$, usando dados de desenvolvimento adequados. Com inclinação positiva, essa transformação preserva a ordenação, mas muda as probabilidades

e as decisões em limiares numéricos fixos. Isso explica como uma métrica probabilística pode mudar sem melhora de AUC.

3.4 Capacidade do decodificador de corretude

3.4.1 Da representação à probabilidade

Seja v o vetor fornecido ao probe: apenas B ou a concatenação de B com a representação de H. A regressão logística constrói um score afim e o transforma em probabilidade pela função sigmoide:

$$z_{\text{lin}}(v) = w^\top v + b, \quad \sigma(z) = \frac{1}{1+\exp(-z)}. \tag{19}$$

A fronteira entre scores altos e baixos é um hiperplano nesse espaço de features. Uma relação pode estar presente nos estados internos e ainda assim não ser bem aproximada por essa fronteira, sobretudo com regularização e amostra finita. Esse é um limite do procedimento de leitura, não uma demonstração de que o estado não contém informação relevante.

Um MLP de uma camada oculta usa uma transformação intermediária:

$$z_{\text{MLP}}(v) = w_2^\top \varphi(W_1 v + b_1) + b_2, \quad \varphi(a) = \max(0, a). \tag{20}$$

A ReLU é aplicada por coordenada. Ao combinar essas unidades, o classificador pode representar regiões e interações que uma função afim das features originais não representa diretamente. Essa flexibilidade também aumenta a possibilidade de ajustar ruído. Por isso, largura, regularização, parada do treinamento e seeds precisam ser definidos e selecionados sem acesso aos rótulos do teste externo.

Na segunda etapa, cada classe é comparada consigo mesma:

$$\Delta_{\text{linear}} = \text{WT-AUC}(H + B, \text{linear}) - \text{WT-AUC}(B, \text{linear}), \tag{21}$$

$$\Delta_{\text{MLP}} = \text{WT-AUC}(H + B, \text{MLP}) - \text{WT-AUC}(B, \text{MLP}), \tag{22}$$

$$\Gamma = \Delta_{\text{MLP}} - \Delta_{\text{linear}}. \tag{23}$$

Γ pergunta se a mudança de classe altera o incremento atribuído a H. Um Γ positivo pode significar apenas que uma desvantagem ficou menor: se $\Delta_{\text{linear}} = -0.06$ e $\Delta_{\text{MLP}} = -0.01$, então $\Gamma = 0.05$, embora nenhum dos incrementos seja positivo. Os números desse exemplo são ilustrativos. O contraste absoluto precisa ser examinado junto à interação.

A correspondência entre os probes significa mesma profundidade, larguras candidatas e regras de seleção dentro da classe. Não significa igualdade exata do número de parâmetros: acrescentar features a $H + B$ aumenta a primeira matriz de pesos. Assim, os resultados comparam procedimentos controlados e não fornecem uma decomposição causal perfeita entre quantidade de parâmetros e conteúdo da representação.

3.4.2 Redução de dimensão e risco de vazamento

Os estados têm centenas ou milhares de coordenadas. No PCA, uma base de componentes é estimada a partir da covariância das features de treinamento. A projeção em 64 componentes reduz a dimensão antes do ajuste do probe; o whitening reescala as coordenadas projetadas segundo suas variâncias estimadas. Essas operações não usam diretamente o rótulo, mas aprendem características da distribuição dos exemplos. Logo, também precisam ser ajustadas somente no treino de cada partição.

A mesma restrição vale para imputação e padronização. Ajustar o PCA uma única vez com todas as trajetórias e depois separar folds permitiria que a transformação visse as tarefas pontuadas. O protocolo evita esse vazamento repetindo o pré-processamento dentro dos treinos. Na aplicação externa, utiliza a transformação já congelada da origem, sem recalcular componentes com dados MBPP+.

A hipótese experimental continua sendo uma comparação de predição, e não uma estimativa direta de informação mútua. Em particular, a ausência de melhora de um probe regularizado não implica $I(S; H|B) = 0$. Também não elimina a possibilidade de um baseline textual mais forte capturar o mesmo padrão que o probe encontra no estado.

3.5 Amostragem repetida, seleção e custo

3.5.1 Cobertura e pass@k

Para N candidatos, a cobertura da tarefa é

$$A_i(N) = \mathbf{1}\{\exists j \leq N : S_{ij} = 1\}. \tag{24}$$

Sob tentativas independentes e identicamente distribuídas condicionalmente à tarefa,

$$P(A_i(N) = 1|x_i) = 1 - (1 - \pi_i)^N. \tag{25}$$

O ganho de passar de $N - 1$ para N tentativas é $\pi_i(1 - \pi_i)^{N-1}$, que decresce quando $0 < \pi_i < 1$. Essa expressão não deve ser aplicada após substituir π_i por uma taxa global sem considerar heterogeneidade: em geral, a média das coberturas por tarefa difere da cobertura calculada com a média das probabilidades.

Com n candidatos e c_i aprovados, o estimador usual de pass@k é (Chen et al., 2021)

$$\widehat{\text{pass@k}}_i = 1 - \frac{\binom{n-c_i}{k}}{\binom{n}{k}}, \quad k \leq n. \tag{26}$$

Esse estimador descreve a probabilidade de incluir um sucesso em um subconjunto de tamanho k. Já a resolução observada dos primeiros k candidatos é $\mathbf{1}\left\{\sum_{j=1}^{k} S_{ij} > 0\right\}$. Ambos são úteis, mas não são números intercambiáveis. O replay operacional preserva uma ordem de tentativas e utiliza o segundo objeto.

3.5.2 Terminologia: Best-of-N e verificador

"Best-of-N" frequentemente descreve gerar candidatos e escolher o melhor segundo um score. Neste documento, o baseline operacional é mais precisamente **amostragem repetida com verificador e parada no primeiro sucesso**. Ele é denominado BoN com verificador por continuidade com o projeto, com essa definição explícita.

A suíte completa de testes é acessada pela política apenas quando um candidato termina. Esse acesso representa um cenário de verificação forte: o programa não recebe os testes ocultos no prompt, mas o controlador pode utilizá-los para decidir a parada. Isso difere da seleção em produção, na qual os testes disponíveis podem ser incompletos. As conclusões operacionais devem ser limitadas a esse cenário, ou acompanhadas futuramente de uma separação entre testes de seleção e de avaliação final.

3.5.3 Custo até sucesso ou esgotamento

Defina $K_i = \min\{j : S_{ij} = 1\}$, adotando $K_i = \infty$ quando não há sucesso no banco. O custo do baseline até o primeiro sucesso ou limite N é

$$C_i^V(N) = \sum_{j=1}^{N} T_{ij} \mathbf{1}\{K_i \geq j\}. \tag{27}$$

Tarefas não resolvidas contribuem com o custo de todas as tentativas iniciadas. Excluir essas tarefas do custo médio favoreceria políticas que simplesmente desistem de problemas difíceis.

A métrica primária de custo é tokens de completion por tarefa, $\overline{C} = \sum_i \frac{C_i}{m}$. Uma métrica secundária é o custo agregado por tarefa resolvida,

$$C_{\text{por solução}} = \frac{\sum_i C_i}{\sum_i A_i}, \tag{28}$$

que fica indefinido se nenhuma tarefa for resolvida. Ela inclui no numerador o custo das tarefas sem sucesso. Não é a média do custo apenas entre tarefas que tiveram sucesso.

3.5.4 Retenção de candidatos e efeito sobre resolução

Considere uma política que mantém um candidato com indicador R_{ij}, com $R = 1$ para candidatos que terminaram naturalmente antes da decisão. O sucesso útil é $S_{ij}R_{ij}$. Para $\pi_i > 0$, defina $r_i = P(R = 1|S = 1, x_i)$, e defina $a_i = P(R = 1|x_i)$. Se $\pi_i = 0$, a retenção condicionada ao sucesso não é identificável, mas a probabilidade de sucesso útil é zero sem precisar defini-la.

Sob tentativas independentes e a mesma regra por tentativa,

$$P(SR = 1|x_i) = \pi_i r_i, \tag{29}$$

$$P(A_i^{\pi}(N) = 1|x_i) = 1 - (1 - \pi_i r_i)^N. \tag{30}$$

A precisão entre candidatos mantidos é $P(S = 1|R = 1, x_i) = \pi_i \frac{r_i}{a_i}$, quando $a_i > 0$. Essa precisão pode crescer mesmo quando a cobertura com orçamento fixo diminui. Portanto, "maior fração de acertos entre os mantidos" não basta como evidência de melhoria do sistema.

> **Proposição 2 — Limite da interrupção no mesmo banco**
> Quando a política usa exatamente os mesmos N candidatos potenciais e só pode descartá-los, seu conjunto de sucessos é subconjunto do conjunto de sucessos do baseline. Logo, $A_i^{\pi}(N) \leq A_i^{V}(N)$ para cada tarefa.

Demonstração. Se um sucesso é encontrado pela política, o candidato correspondente está no banco original e também passa no verificador do baseline. A política não cria novos candidatos além do limite e não altera o conteúdo dos mantidos. Assim, não pode resolver uma tarefa que nenhum dos N candidatos originais resolvia.

O ganho esperado nesse regime é reduzir custo com perda pequena ou nula de resolução. Para superar cobertura em um mesmo orçamento de tokens, seria necessário reinvestir a economia em novas tentativas, com um banco maior e uma comparação própria. Essa extensão não integra o experimento principal.

3.5.5 Condição econômica para interromper

Uma política pode economizar tokens em um candidato e aumentar o custo total da tarefa ao eliminar um sucesso precoce, forçando outras tentativas. Por isso, o custo do replay não é necessariamente monotônico no limiar de interrupção.

Sob tentativas iid por tarefa, seja D o custo de uma tentativa sob a política e $s = \pi_i r_i$ sua probabilidade de sucesso útil. Como iniciar uma tentativa depende dos resultados anteriores, independentes da tentativa atual,

$$E[C_i^{\pi}(N)|x_i] = E[D|x_i] \sum_{j=0}^{N-1} (1-s)^j. \tag{31}$$

Para $s > 0$, a soma vale $\frac{1-(1-s)^N}{s}$; para $s = 0$, vale N. Essa expressão mostra que a redução do custo por tentativa deve compensar a possível redução na probabilidade de sucesso por tentativa. A análise empírica usa os caminhos efetivos do banco e não depende de estimar π_i para substituir nessa fórmula.

3.5.6 Derivação, limite ilimitado e retenção ativa

Para explicitar as hipóteses, condicione em x_i e suponha que os pares $\big(D_j, S_j R_j\big)$ sejam identicamente distribuídos e independentes entre tentativas. Permite-se dependência entre custo e sucesso da **mesma** tentativa. Se I_j indica que as tentativas anteriores não produziram sucesso mantido, então I_j é independente de D_j, e

$$E\big[D_j I_j \mid x_i\big] = E[D|x_i] P\big(I_j = 1 | x_i\big) = d_i (1 - \pi_i r_i)^{j-1}. \tag{32}$$

Somar essas identidades demonstra a expressão anterior sem impor que candidatos corretos e incorretos tenham o mesmo comprimento. A hipótese falha se o controlador adapta prompts, seeds, amostragem ou sua regra com base nas tentativas anteriores. O replay preserva ordem e configuração, mas o banco finito não prova que as tentativas de uma aplicação futura sejam iid.

Se $\pi_i > 0$, $r_i > 0$ e os custos médios são finitos, o limite com tentativas ilimitadas é

$$E[C_i^{\pi}(\infty)|x_i] = \frac{d_i}{\pi_i r_i}, \quad E\left[C_i^{V}(\infty)|x_i\right] = \frac{\tau_i}{\pi_i}, \quad \tau_i = E[T|x_i]. \tag{33}$$

Logo, a interrupção reduz o custo esperado nesse limite precisamente quando

$$\frac{d_i}{\tau_i} < r_i. \tag{34}$$

Trata-se de uma consequência algébrica conhecida de uma soma geométrica, não de um teorema inédito. Se $\pi_i r_i = 0$, o tempo até sucesso não é finito e não se aplica essa comparação de razões. Nenhum sucesso em vinte tentativas tampouco demonstra que a probabilidade verdadeira seja zero.

Para orçamento finito, escreva $G_N(s) = \sum_{j=0}^{N-1} (1-s)^j$. A condição de menor custo é $\frac{d_i}{\tau_i} < G_N \frac{\pi_i}{G_N}(\pi_i r_i)$, enquanto a cobertura é $1 - (1 - \pi_i r_i)^N$. Quando $N = 1$, economizar em candidatos é suficiente para reduzir custo; ao aumentar N, os sucessos perdidos pesam mais. Menor custo finito pode refletir abandono de soluções e precisa ser examinado junto à resolução, sem interpretação automática de eficiência.

A retenção r_i dessas equações é **global**, incluindo sucessos terminados antes do gate. Se $a_i^+ = P(T > t|S = 1, x_i)$ e r_i^{ativo} é a retenção entre corretos ativos, então

$$r_i = 1 - a_i^+(1 - r_i^{\text{ativo}}). \tag{35}$$

Portanto, substituir indiscriminadamente recall ativo por r_i altera o modelo econômico. A análise empírica explicita os dois denominadores. Se $a_i^+ = 0$, o recall ativo não é identificável e os corretos terminam antes do gate, de modo que $r_i = 1$; a identidade anterior se aplica diretamente quando $a_i^+ > 0$.

Finalmente, sob heterogeneidade entre tarefas, o custo populacional é $E_X[d_X G_N(\pi_X r_X)]$. Em geral ele não coincide com $E_X[d_X]G_N(E_X[\pi_X]E_X[r_X])$. A média agregada de acertos não pode substituir as probabilidades condicionais nessa expressão não linear. Overheads de prefill, gate e verificação devem ser acrescidos ao custo por tentativa na mesma unidade, preservando sua dependência com o caminho. Um tempo de probe não é uma quantidade de tokens sem hipótese de conversão explicitada e validada; as medições deste estudo mantêm essas unidades separadas.

3.5.7 Oracle retrospectivo e alcance do limite econômico

O oracle idealizado conhece S_{ij}, interrompe todos os incorretos ativos em um checkpoint fixo t e mantém todos os corretos. Usa a mesma ordem e para no primeiro sucesso. Em cada tarefa, seu custo é no máximo o do verificador e sua resolução é idêntica. Entre políticas no mesmo checkpoint que preservam **todos** os candidatos corretos, ele minimiza o custo nesse caminho: nenhuma delas pode cobrar menos que t por um incorreto ainda ativo ou menos que o comprimento completo do primeiro sucesso mantido.

Esse limite é condicional às restrições descritas. Uma política que descarta sucessos pode, em certos caminhos, custar menos que esse oracle e perder cobertura, ou alcançar depois um sucesso mais curto. O oracle não é limite inferior universal para toda política de inferência nem é implementável online. Sua utilidade é separar o espaço econômico disponível da capacidade real de identificar candidatos descartáveis sem conhecer seus rótulos finais.

3.5.8 Tokens, latência e fronteira custo–resolução

Tokens gerados são uma medida auditável de trabalho de decodificação, mas não equivalem a FLOPs, energia ou tempo. Prefill, comprimento do contexto, cache, extração de estados, cálculo de entropia, transferência GPU–CPU, inferência do probe e verificação têm custos próprios. Os resultados devem distinguir economia de tokens e aceleração medida em execução.

Uma política domina outra no plano descritivo se tem resolução ao menos igual e custo não maior, com uma desigualdade estrita. Na presença de incerteza amostral, a comparação deve reportar diferenças pareadas e intervalos. A fronteira apresentada corresponde às políticas e limiares previamente definidos; não representa a fronteira ótima global de todos os algoritmos possíveis.

3.6 Decisão sequencial sob orçamento finito

3.6.1 Objetivo e estado

O replay anterior avalia regras fixadas. Para entender quais grandezas uma regra ideal precisaria considerar, pode-se formular um problema de decisão sequencial. Seja λ a penalidade por encerrar sem uma solução verificada. O objetivo é minimizar o custo esperado de geração, aquisição dos sinais e verificação, acrescido dessa penalidade, sob um orçamento finito b_0.

Custos e penalidade devem estar na mesma unidade, por exemplo milissegundos ou uma unidade monetária definida. Se forem usados tokens, o overhead do gate e do verificador exige uma conversão explícita, ou precisa ser mantido fora desse objetivo de tokens. Somar milissegundos e tokens sem conversão não define uma função de custo. Custos já pagos são afundados: importam para o total da política, mas não são cobrados novamente na comparação entre ações futuras.

O estado de uma tentativa ativa é (k, b, h, z): k novas tentativas ainda disponíveis **além da atual**, orçamento restante b, prefixo observado h e crença z sobre a tarefa. A crença resume o que resultados anteriores informam sobre sua dificuldade. O score de um probe só poderia substituir esse estado completo se fosse uma estatística suficiente para as distribuições de sucesso e custo futuro; essa suficiência não é assumida nos experimentos.

As ações são continuar a tentativa, abortá-la para considerar outra, ou encerrar sem solução. Há ainda a decisão de iniciar uma tentativa quando nenhuma está ativa. Um sucesso verificado encerra o processo com custo futuro zero. Sem novas tentativas, ainda pode ser ótimo completar a atual.

3.6.2 Recursão de Bellman

Denote por $J_k(b, z)$ o menor custo esperado sem tentativa ativa e por $F_k(b, h, z)$ o custo no checkpoint após obter seu score. Suponha inicialmente custos determinísticos por transição e aquisição obrigatória dos sinais nos checkpoints previstos. Se iniciar uma tentativa custa a até o primeiro checkpoint, incluindo o primeiro gate, então

$$J_0(b, z) = \lambda, \quad J_k(b, z) = \min(\lambda, a + E[F_{k-1}(b - a, H_0, z)]). \tag{36}$$

O segundo ramo só é admissível para $k \geq 1$ e $b \geq a$. A esperança considera o prefixo inicial aleatório H_0. No checkpoint, se $d(h)$ é o custo de gerar até o próximo evento,

$$F_k(b, h, z) = \min(\lambda, J_k(b, z), d(h) + E[\Phi_k(b - d(h), H', Z')]). \tag{37}$$

O custo do gate atual já foi pago e não aparece apenas no ramo de continuar. Se o próximo evento for outro checkpoint, Φ inclui o custo do próximo gate e retorna a F. Se for o término, inclui o custo v do verificador e retorna zero em caso de sucesso ou J_k com orçamento e crença atualizados em caso de falha. Ações que excedem o recurso disponível são removidas. Se não houver recurso para uma verificação ou aquisição obrigatória, o modelo deve prever o encerramento sem solução. Quando adquirir o próprio sinal for opcional, é necessário acrescentar uma ação anterior à observação que pague esse custo.

Explicitamente, escrevendo $u = b - d(h)$, o ramo de outro checkpoint custa $g' + F_k(u - g', H', Z')$, admissível se $u \geq g'$, em que g' é o custo do próximo sinal. No término, o ramo custa $v + (1 - S')J_k(u - v, Z')$, admissível se $u \geq v$; S' é o resultado da verificação. Assim, geração, aquisição e verificação reduzem o orçamento no ponto em que são pagas. O ramo de sucesso tem custo futuro zero depois de pagar v.

Os limites de tentativas e tokens asseguram horizonte finito. A recursão escolhe o ramo admissível de menor custo. Sua interpretação exige transições conhecidas ou crenças suficientes, custos aditivos e uma regra de verificação bem especificada. Independência entre tentativas condicionalmente à tarefa não implica independência marginal: fracassos anteriores podem atualizar z. O caso sintético testado simplifica esse ponto ao usar probabilidade de sucesso conhecida e tentativas iid.

3.6.3 Quando a regra se reduz a um limiar

Considere uma decisão única, sem novos checkpoints dentro da tentativa. Sejam p_t sua probabilidade condicional de sucesso, c_t o custo restante e V_k o custo ótimo de fallback, incluindo a penalidade por não resolver. Mantém-se a convenção de k novas tentativas além da atual. Suponha que falhar após continuar e abortar agora conduzam **ao mesmo estado futuro**. Então

$$Q_{\text{continuar}} = c_t + (1 - p_t)V_k, \quad Q_{\text{abortar}} = V_k. \tag{38}$$

Subtraindo os custos, continuar é preferível ou empatado precisamente quando

$$c_t - p_t V_k \leq 0 \iff p_t V_k \geq c_t. \tag{39}$$

p_t é adimensional; c_t e V_k são custos na mesma unidade. V_k não é a probabilidade de sucesso de outra tentativa. Se $V_k > 0$, o limiar simplificado é $\frac{c_t}{V_k}$; se $c_t > V_k$, nenhuma probabilidade admissível torna continuar vantajoso. Sem novas tentativas, $V_0 = \lambda$. Se $V_k = 0$, apenas $c_t = 0$ permite empate.

A hipótese de fallback idêntico é forte. Com orçamento estrito, completar a tentativa consome recurso e altera o estado após fracasso. Nesse caso, a comparação envolve $J_k(b - c_t, z_{\text{falha}})$ e $J_k(b, z_{\text{aborto}})$, que não são geralmente iguais. Custos aleatórios correlacionados ao sucesso também exigem uma esperança conjunta; substituir tudo por médias não preserva automaticamente uma restrição estrita de orçamento.

3.6.4 Conexão com a política empírica

Os gates estudados usam limiares escolhidos para uma meta de retenção na origem. Não estimam as funções J e F, nem implementam a solução ótima dessa recursão. A formulação explica por que um limiar ótimo poderia depender da tarefa, do comprimento restante, do orçamento e do número de tentativas. Também mostra por que boa ordenação por AUC não garante decisões econômicas perto do limiar.

O problema pertence à tradição de seleção de computações por custo e valor esperado (Callaway et al., 2018; Russell; Wefald, 1991) e se relaciona à parada na amostragem de respostas completas (Wan et al., 2025). A contribuição aqui é explicitar essas condições para a interrupção de prefixos. O solver sintético foi confrontado com enumeração exata de políticas iid pequenas; essa validação é interna ao modelo e não demonstra ganho econômico dos probes nos benchmarks.

4 METODOLOGIA

4.1 Desenho geral e estatuto das análises

O estudo foi executado em etapas, e não como um único experimento concebido antes de todos os resultados. Esta distinção determina o que cada comparação permite concluir. A primeira etapa corresponde ao protocolo v0.2 com Qwen, probes lineares e avaliação por tarefa em HumanEval+. A segunda compara classes de probes em dois geradores e utiliza um novo conjunto externo comum. Entre elas ocorreram diagnósticos exploratórios e uma validação independente de gates, com hipótese de retenção própria.

Quadro 4: Papel de cada conjunto na sequência da investigação.

Conjunto	Uso científico
Piloto original	32 tarefas HumanEval+, 960 trajetórias; desenvolvimento da configuração de geração Qwen.
Origem da primeira etapa	132 tarefas HumanEval+, 2.640 trajetórias Qwen; avaliação OOF por tarefa e seleção restrita ao desenvolvimento.
Transferência inicial	32 tarefas MBPP+, 640 trajetórias; aplicação do sistema Qwen congelado, sem reajuste no alvo.
Validação independente dos gates	120 novas tarefas MBPP+, 2.400 trajetórias Qwen; comparação prospectiva de retenção no checkpoint comum de oito tokens.
Origem da segunda etapa	As mesmas 132 tarefas HumanEval+; reutilização do banco Qwen e coleta de 2.640 trajetórias DeepSeek para desenvolvimento dos oito probes.
Teste externo da segunda etapa	100 novas tarefas MBPP+ comuns aos geradores; vinte tentativas por tarefa e modelo, totalizando 4.000 gerações.

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

OOF, de out-of-fold, designa previsões em tarefas excluídas do ajuste do respectivo fold. Não é sinônimo de um novo benchmark. Na segunda etapa, “externo” designa o conjunto MBPP+ reservado para testar procedimentos já congelados na origem. Essa diferença evita misturar o teste agrupado em HumanEval+ com a transferência prospectiva entre benchmarks.

As cinco perguntas da introdução constituem uma síntese editorial. Nos arquivos normativos, Q1, Q2 e Q3 do protocolo original têm seus significados e critérios próprios. A nova hipótese DeepSeek/MLP não substitui o critério original nem transforma as ablações posteriores em testes antecipados. Os registros de autorização e de exposição são preservados no apêndice.

4.2 Geração, corretude e informação disponível

4.2.1 Dois modelos e uma especificação funcional comum

Foram utilizados Qwen/Qwen2.5-Coder-1.5B-Instruct e deepseek-ai/deepseek-coder-1.3b-instruct. O primeiro tem 28 blocos e estados de dimensão 1.536; o segundo usa arquitetura Llama com 24 blocos e dimensão 2.048. Pesos e tokenizers foram fixados por revisões imutáveis, reproduzidas no apêndice. Não houve fine-tuning dos geradores nem quantização.

O prompt transmite a mesma especificação de função, com mensagens renderizadas pelo template oficial de cada tokenizer. O renderer histórico mantém uma referência textual a HumanEval também em MBPP; essa imperfeição foi preservada para não alterar somente a

condição de teste. No DeepSeek, o template já emite BOS e termina com a marca de resposta; a tokenização evita adicionar um segundo BOS. O token EOT de ID 32021 define seu término. Qwen utiliza suas próprias regras de término congeladas.

A comparação não presume equivalência entre tokens. Trinta e dois tokens podem representar quantidades diferentes de código nos dois geradores, sobretudo quando há comentários ou formatação. Em vez de igualar estados ou entropias de vocabulários distintos, compara-se o incremento de H sobre os observáveis do próprio modelo.

4.2.2 Amostragem e independência dos candidatos

O piloto original testou temperaturas 0,6, 0,8 e 1,0 em 32 tarefas separadas das 132 de origem. Uma regra fixada privilegiou a composição mista, sujeita a restrições de validade e truncamento, sem usar AUC de probes. Foram dez tentativas por tarefa e temperatura, somando 960. A configuração selecionada foi temperatura 1,0, top-p 0,95, top-k zero e máximo de 512 novos tokens.

A mesma configuração de amostragem foi mantida na segunda etapa. Cada banco principal contém vinte tentativas por tarefa, inclusive após um sucesso. Isso fornece uma população comum para todos os probes e para o replay; gerar um banco diferente para cada política confundiria diferenças de decisão e de candidatos.

As seeds são derivadas por hash de protocolo, versão do benchmark, tarefa e índice da tentativa, com namespace de modelo próprio na segunda etapa. A reinicialização antes de cada tentativa impede que abortar uma anterior consuma o estado aleatório destinado à seguinte. Não há feedback dos testes para modificar o próximo prompt. Essas condições sustentam o pareamento, mas não certificam independência estatística absoluta ou ausência de variações numéricas entre hardwares.

4.2.3 Desfecho funcional e segurança

O desfecho é aprovação nas suítes base e plus do EvalPlus 0.3.1, com HumanEval+ v0.1.10 e MBPP+ v0.2.0. O programa é extraído pela regra de parsing fixada antes dos testes correspondentes. Truncamento é um atributo: um programa terminado pelo limite ainda pode passar. Falha do candidato sob o limite do verificador é um insucesso funcional; falha de comunicação, corrupção ou indisponibilidade da infraestrutura não recebe um rótulo negativo fabricado.

Na execução histórica, EvalPlus utilizou subprocessos WSL, timeouts e reliability_guard. Esses mecanismos não equivalem a isolamento de rede e arquivos. Na segunda etapa, a avaliação foi executada em namespaces WSL/bubblewrap, sem rede, sem home ou disco Windows montados e com runtime e dataset somente para leitura. O limite de memória por processo foi fixado em 3 GiB, em vez do padrão histórico de 4 GiB. A reavaliação dos 2.640 programas Qwen de origem nesse ambiente encontrou zero divergências de label; os rótulos antigos não foram substituídos.

Os limites de tempo e memória fazem parte da definição operacional de corretude. Passar nos testes não constitui prova para todas as entradas, e diferenças de parser ou de ambiente precisam ser consideradas na interpretação externa.

4.2.4 Checkpoint, conjunto ativo e causalidade

O checkpoint principal das duas etapas é $t = 32$. Nos demais pontos da primeira etapa, $t \in \{0, 8, 16, 64, \text{final}\}$, as análises são secundárias ou diagnósticas. Uma tentativa entra na decisão precoce somente quando $T_{ij} > t$. Se termina exatamente no checkpoint ou antes dele, segue ao verificador; não recebe uma representação futura fictícia nem é contada como aborto do gate.

O estado é capturado após alimentar o token t ao modelo. Os logits anteriores predizem esse token e não são sua ativação. A instrumentação foi confrontada com processamento do prefixo isolado, sequência completa e geração com cache, dentro das tolerâncias fixadas. Também foram comparados os tokens com e sem captura seletiva e as estatísticas com teacher forcing. Esses testes verificam temporalidade e integridade numérica, sem atribuir causalidade semântica à representação.

O vetor B contém dez features: cinco atributos do prompt — comprimento tokenizado, comprimento da assinatura, presença de import, de exemplos com >>> e de bloco de código — e cinco estatísticas do prefixo: NLL média e última, entropia média e máxima e margem média entre os dois maiores logits. NLL e entropia usam a distribuição amostrada após temperatura e top-p; a margem é calculada antes do top-p, após temperatura. Somente os tokens observados até o checkpoint entram nessas estatísticas. Comprimento final, tempo futuro e resultado do verificador não são preditores.

4.3 Primeira etapa: avaliação Qwen e desenvolvimento exploratório

4.3.1 Separação de tarefas e ajuste linear

Das 164 tarefas HumanEval+, 32 foram destinadas ao piloto e 132 ao banco principal. Agrupar por task_id impede que respostas da mesma tarefa apareçam simultaneamente no treino e no teste de um fold. Não remove a exposição humana anterior a tarefas: 26 tarefas principais já apareciam em artefatos históricos, limitação documentada que não foi apagada pela mudança de seeds.

A avaliação utilizou cinco folds externos e três internos agrupados. B, H e H+B receberam regressão logística L2. Para H e H+B, a camada foi selecionada entre profundidades relativas de 25%, 50%, 75% e 100%. O grid de C foi 0,001; 0,01; 0,1; 1 e 10. A seleção minimizou log loss balanceada por tarefa; entre opções dentro de um erro-padrão estimado da melhor, preferiu regularização mais forte e depois camada mais rasa. Essa regra de um erro-padrão é uma heurística de seleção, não um intervalo de confiança.

Imputação, padronização e ajuste foram feitos somente no treino correto. A calibração Platt utilizou scores obtidos por cross-fitting de todo o procedimento de seleção dentro do treino externo. Assim, os labels da tarefa pontuada não participam do modelo, da seleção ou

do calibrador que a avalia. As escolhas de desenvolvimento e a comparação final precisam permanecer separadas para controlar o otimismo de seleção (Cawley; Talbot, 2010).

Os observáveis recebem o mesmo peso total por tarefa: uma tentativa de uma tarefa com menos respostas ativas tem peso maior do que uma tentativa de tarefa com mais respostas ativas. Isso define uma população de tarefas com contribuições iguais, em vez de uma população dominada pelas trajetórias mais longas.

4.3.2 Critério original e diagnósticos posteriores

O critério incremental original em 32 tokens exigia diferença positiva de WT-AUC, IC95% pareado inteiramente acima de zero e diferença negativa de log loss. O intervalo da perda também era reportado. Controles de associação por permutação dentro da tarefa eram uma análise distinta, com combinação por folds; não constituíam um teste isolado de informação condicional adicional sobre B.

Após conhecer o resultado, foram examinados maior regularização, PCA e um corretor residual sobre a previsão de B. Seus ajustes respeitaram as partições, mas a escolha de investigá-los foi posterior. Portanto, seus intervalos são exploratórios e pontuais. Eles motivam a investigação seguinte, sem confirmar a superioridade de uma representação.

4.3.3 Transferência e validação dos gates

O transporte inicial aplicou modelos, calibradores e limiares ajustados em HumanEval+ a 32 tarefas MBPP+, com vinte gerações em cada. Não houve retreino nem recalibração com labels alvo. Os gates originalmente escolhidos podiam usar checkpoints distintos; essa avaliação examinava os procedimentos transportados completos.

Uma validação independente posterior reservou vinte tarefas técnicas e 120 tarefas principais sem resultados locais anteriores. Sua hipótese própria comparou a retenção de corretos ativos dos gates Qwen B e H+B, ambos em oito tokens, com limiares congelados na origem. A retenção é uma razão de contagens de candidatos, e não uma média de AUCs ou a proporção de tarefas resolvidas. Os intervalos dessa hipótese utilizaram 10.000 reamostragens de tarefas inteiras, recalculando a razão em cada réplica. Seus resultados não alteram o contraste original em 32 tokens.

4.4 Segunda etapa: comparação entre modelos e classes de probes

4.4.1 Piloto DeepSeek e inventário externo

Doze tarefas HumanEval+ do desenvolvimento original foram fixadas por hash, separadas das 132 de origem, para um piloto DeepSeek de vinte tentativas por tarefa. Os critérios para prosseguir incluíram pelo menos quatro tarefas mistas, taxa agregada de acertos de pelo menos 5%, truncamento de no máximo 25%, erro de parsing de no máximo 15% e aprovação dos controles numéricos e funcionais. Qwen foi medido em uma tentativa nas mesmas doze tarefas para dimensionamento técnico; esse conjunto não compõe o teste externo.

A auditoria MBPP+ considerou 378 tarefas, 173 IDs já expostos em trajetórias ou tabelas locais e uma triagem lexical de variantes. Depois das exclusões, 189 tarefas permaneceram elegíveis. Similaridade lexical não é garantia de independência semântica completa. A ordenação foi determinada por hash antes das novas gerações; não se substituíram tarefas por seus resultados.

A hierarquia de tamanho prevista foi 150, 140, 120, 100 ou 80 tarefas por modelo, com vinte tentativas. A projeção baseada no piloto, com contingência de 50%, selecionou cem tarefas para respeitar aproximadamente 60 horas de sessão ativa. A redução foi uma aplicação da regra de recursos, não uma reação à significância. Os mesmos cem IDs foram usados pelos dois modelos.

A análise de planejamento simulou efeitos conhecidos de +0,02, +0,03, +0,05 e +0,075, usando a dispersão histórica por tarefa e cenários de frequência mista. Seus intervalos normais são aproximações de planejamento, distintos do bootstrap final. As curvas e a possibilidade de baixo poder para efeitos pequenos foram registradas antes do teste; poder calculado a partir do efeito externo observado não foi usado como validação.

4.4.2 Features e comparação fatorial

Na segunda etapa, H foi fixado na saída do bloco de profundidade relativa de 75%: índice 20 no Qwen e 17 no DeepSeek, em base zero. A escolha é comum em profundidade relativa, mas não alinha semanticamente as coordenadas. O estado passou por padronização e PCA64 com whitening estimados somente no treino. O vetor B manteve a definição anterior, computado pelo tokenizer do respectivo gerador.

Quadro 5: Quatro famílias centrais aplicadas separadamente a cada gerador.

Conjunto de features	Classe do probe
B	Regressão logística L2.
$H + B$	Regressão logística L2 com o mesmo grid de regularização.
B	MLP de uma camada oculta ReLU, largura 16 ou 32.
$H + B$	O mesmo desenho de MLP, acrescentando os 64 componentes de H.

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Cada contraste H+B−B é calculado dentro da mesma classe. Na comparação entre logística e MLP, a arquitetura do gerador, o checkpoint e a representação latente permanecem fixos. O grid e a validação do baseline são próprios e correspondentes; B não é mantido deliberadamente subajustado para favorecer H+B.

4.4.3 Desenvolvimento na origem, calibração e congelamento

Os probes foram desenvolvidos nas mesmas 132 tarefas HumanEval+ por modelo. O banco Qwen válido foi reutilizado; para DeepSeek, coletaram-se vinte tentativas por tarefa. Por ordenação hash, 26 tarefas foram reservadas para calibração e limiar. As outras 106 alimentaram validação agrupada de três folds para selecionar hiperparâmetros pela média da log loss balanceada por tarefa. As 26 tarefas não participaram dessa seleção.

A logística utilizou C em 0,001; 0,01; 0,1 e 1. O MLP utilizou uma camada ReLU de 16 ou 32 unidades, dropout 0,1, AdamW com taxa de aprendizado 0,001 e weight decay 0,001. O treinamento foi em CPU, full batch, com BCE ponderada por tarefa e limite de duzentas épocas.

Dentro de cada treino interno, uma reserva agrupada de 20% forneceu early stopping, com paciência de vinte épocas e melhora mínima de 0,00001. Ela não incluiu o fold pontuado. Após escolher o número de épocas, o modelo foi reajustado no treino interno completo. O ajuste final nas 106 tarefas utilizou a mediana das épocas escolhidas nos folds. As seeds 20261104, 20261105 e 20261106 foram todas mantidas: o ensemble é a média de probabilidades, sem seleção do membro mais favorável.

A calibração Platt e o limiar foram ajustados somente nas 26 tarefas reservadas. O limiar busca preservar pelo menos 97% dos corretos ativos de calibração. Esse número é uma meta de desenvolvimento, não uma garantia de retenção externa. Os modelos, transformações, calibradores, limiares, código e IDs foram congelados em 5 de novembro de 2026, às 19h29 UTC, antes de qualquer resultado externo novo. Nenhuma decisão de ajuste utilizou os labels dessas cem tarefas.

4.4.4 Hipótese primária e comparações secundárias

A hipótese primária foi o incremento de WT-AUC de H+B/MLP sobre B/MLP no DeepSeek aos 32 tokens. O IC95% pareado por tarefa tem interpretação bilateral: inteiramente acima de zero sustenta ganho; inteiramente abaixo sustenta deterioração; incluindo zero não demonstra diferença. Não foi fixada uma margem de equivalência que permitisse concluir igualdade prática por ausência de significância.

DeepSeek linear, ambos os contrastes Qwen, a interação Γ, as diferenças probabilísticas, a calibração e o replay foram secundários. Seus intervalos são pontuais, sem controle conjunto de multiplicidade. A interpretação não promove um resultado secundário ao lugar do contraste primário quando este é inconclusivo.

4.4.5 Estabilidade do treinamento

Além dos três membros fixos do MLP, oito análises de sensibilidade na origem Qwen repetiram seleção, pré-processamento, ajuste e calibração completos. Um conjunto fixo de 26 tarefas foi reservado exclusivamente para auditar estabilidade; cada repetição utilizou 84 das 106 tarefas restantes, sem reposição. Não se utilizaram labels MBPP novos.

Essa subamostragem evita que cópias de uma mesma tarefa atravessem folds, mas não é um bootstrap de treinamento. Oito conjuntos sobrepostos, um conjunto de auditoria pequeno e um treino menor não fornecem uma estimativa sem viés da variância do procedimento final. A análise quantifica sensibilidade empírica e não converte os IC finais condicionais em intervalos de toda a seleção.

4.5 Métricas, denominadores e inferência

A WT-AUC é a média sem ponderação das AUCs das tarefas mistas no conjunto ativo. Cada tarefa informativa contribui uma vez; todos os pares positivo-negativo de uma mesma tarefa continuam dependentes. As tarefas homogêneas não recebem AUC artificial de 0,5. Elas permanecem nas perdas probabilísticas quando possuem candidatos ativos e nas métricas operacionais de toda a população.

AUC agregada, average precision, log loss e Brier foram calculados com pesos iguais por tarefa contribuinte. Log loss mede a penalização probabilística de acertos e erros, dando peso elevado a erros confiantes; Brier mede erro quadrático das probabilidades. Calibração foi examinada em dez bins fixos. Essas medidas não substituem a ordenação intratarefa.

O bootstrap reamostra tarefas inteiras, com o mesmo índice para todos os métodos comparados. A primeira etapa utilizou 2.000 réplicas e seed 20260921; a validação independente de gates utilizou 10.000 e seed 20261017; a segunda etapa utilizou 10.000 e seed 20261104. Na WT-AUC, contribuem as tarefas mistas; nas perdas, as tarefas com candidatos ativos; no custo e na resolução, todas as tarefas selecionadas. Comparações entre geradores mantêm o cluster da tarefa. O contraste de incrementos entre modelos é reportado separadamente nas tarefas mistas comuns, pois muda a população em relação aos contrastes primários.

Os intervalos condicionam nos probes ajustados e no conjunto observado. Não incorporam integralmente a variabilidade de refazer seleção, calibração e treinamento. Também não certificam ausência de perdas raras quando nenhuma foi observada: se todas as diferenças de resolução forem zero, o bootstrap empírico pode devolver um intervalo degenerado. Essa limitação será considerada na discussão operacional.

4.6 Replay e contabilidade do custo

As políticas são avaliadas nos mesmos candidatos, na ordem original de tentativa, para $N \in \{1, 5, 10, 20\}$. O baseline fixo gera todos os candidatos; o verificador encerra ao primeiro sucesso. Os gates interrompem candidatos ativos cujo score é inferior ao limiar e continuam a busca até um sucesso mantido ou o esgotamento. O oracle contrafactual conhece os labels e aborta apenas incorretos ativos. Ele não é implementável em uma aplicação real.

Uma tentativa abortada custa t tokens de completion; uma mantida custa seu comprimento integral. O replay soma somente tentativas efetivamente iniciadas. Tarefas não resolvidas contribuem com seus custos. Tokens agregados por tarefa resolvida dividem o custo de todas as tarefas pela quantidade resolvida, e não apenas pelo custo das que tiveram sucesso.

A retenção entre todos os corretos ativos do banco responde a uma pergunta diferente da taxa de aborto entre corretos ativos iniciados. Um sucesso potencial descartado depois de uma solução anterior não teria sido iniciado pelo replay; o primeiro denominador o inclui, e o segundo não. Ambos são identificados nas tabelas.

O protocolo original condicionou uma afirmação conjunta de utilidade ao suporte incremental, à não inferioridade de resolução com margem de três pontos percentuais, à economia contra verificador e B e à validação online de replay. A segunda etapa não herdou uma nova hipótese confirmatória operacional: seus resultados de custo são secundários, com limiares da origem e sem concluir redução de latência a partir de tokens.

4.7 Condições computacionais e integridade

A GPU efetivamente utilizada foi uma RTX 3050 Laptop de 6 GB. Os pesos permaneceram em BF16, as projeções densas foram calculadas em FP32, as ativações armazenadas em float16, com atenção eager, batch um e TF32 desligado. Precisão de armazenamento, computação e pesos são condições distintas e foram mantidas durante cada comparação.

Os candidatos foram gravados de forma atômica e a retomada verificou identidades, seeds e hashes. Uma suspensão do Windows por bateria atravessou uma sessão da segunda etapa. O intervalo de 9h40 foi comprovado pelo log do sistema e excluído somente da contabilidade de sessão ativa, preservando tempos brutos e todos os candidatos. O total ativo inclui carga e verificação; não é perfil de kernels CUDA. Essa emenda técnica ocorreu antes da avaliação externa e não alterou amostra ou critério estatístico.

Extração, score do probe, geração e verificação têm custos próprios. Medições em lote de score na CPU não estimam automaticamente overhead online por tentativa. A análise mantém separados tokens de completion, tempo de execução, custo de preparação da pesquisa e desempenho de uma política já treinada. Os artefatos que permitem reconstruir essas condições são descritos no apêndice.

5 PRIMEIRA ETAPA: QWEN, TRANSFERÊNCIA E DIAGNÓSTICOS

5.1 Composição do banco e comparação intratarefa

A primeira etapa estabelece a referência empírica do estudo. O piloto separado produziu 960 trajetórias e selecionou a configuração de geração. O banco principal contém 2.640 tentativas em 132 tarefas HumanEval+. Como os probes precoces só podem atuar enquanto uma resposta continua sendo gerada, o tamanho de sua população diminui com o checkpoint.

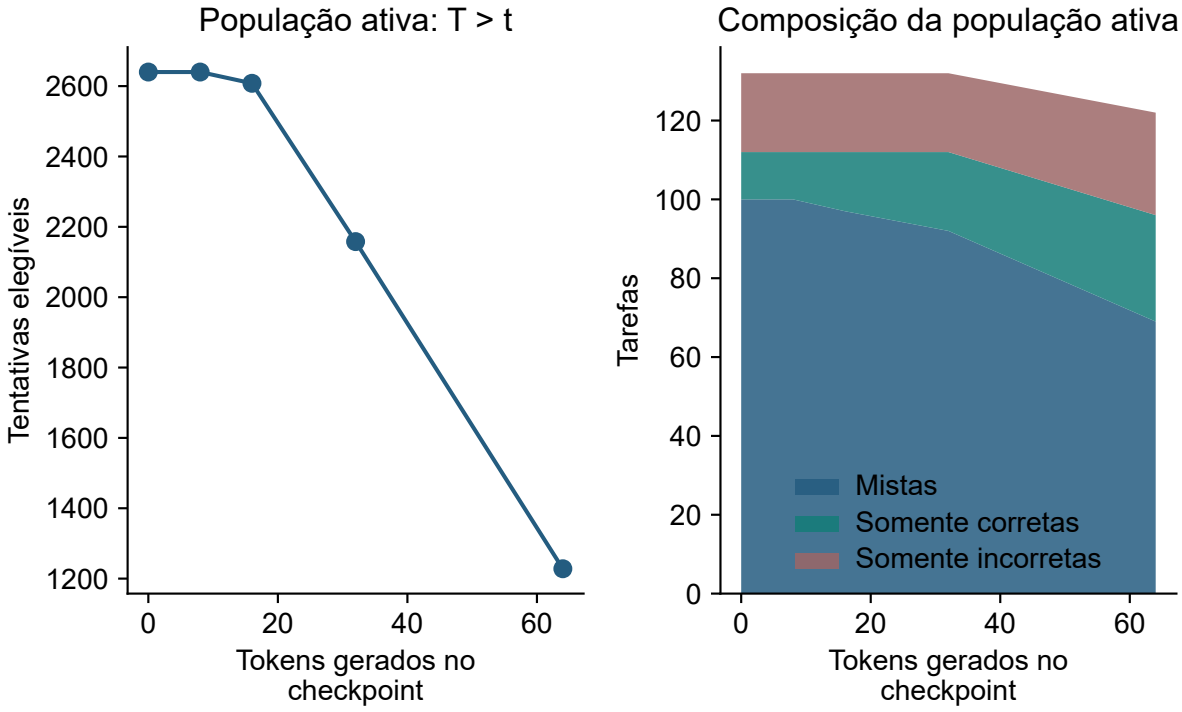
Tabela 1: Qwen em HumanEval+: população ativa e tarefas que identificam WT-AUC.

Tokens	Ativas	Tarefas ativas	Mistas
8	2640	132	100
16	2608	132	97
32	2158	132	92
64	1228	122	69

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Em 32 tokens, 2.158 tentativas permanecem ativas e 92 tarefas apresentam ambos os resultados. Essa é a população do contraste principal de WT-AUC. Tarefas homogêneas continuam contribuindo para perdas e replay, mas não recebem uma AUC intratarefa fictícia. O conjunto de trajetórias longas em 64 tokens é diferente; a curva temporal não deve ser interpretada como evolução de desempenho sobre uma amostra invariável.

Figura 1: Composição do banco Qwen por checkpoint. A condição T > t muda a população e o número de tarefas mistas.



Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Tabela 2: Probes lineares da primeira etapa, fora da amostra por tarefa em HumanEval+, t=32.

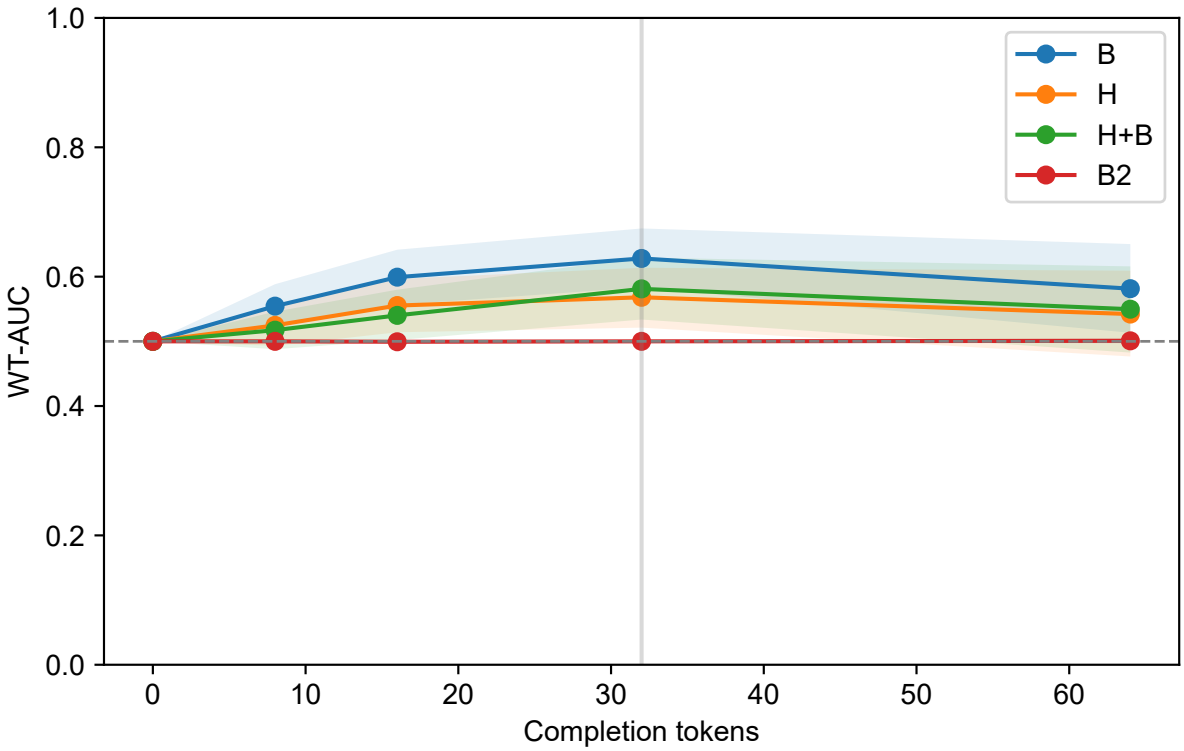
Probe	AUC agregada	WT-AUC e IC95%	Log loss	Brier
B	0,701	0,628 [0,583; 0,675]	0,630	0,220
H	0,592	0,568 [0,521; 0,614]	0,687	0,246
H+B	0,646	0,581 [0,534; 0,629]	0,668	0,236

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

O baseline observável B alcança WT-AUC de 0,628, enquanto H+B alcança 0,581. A diferença é −0,047, IC95% [−0,099; 0,006]. Na perda probabilística, H+B−B é 0,038, IC95% [0,007; 0,071]. O critério incremental original não foi satisfeito: a ordenação não apresenta ganho demonstrado, e o intervalo da diferença de log loss indica maior perda de H+B.

Esse resultado não equivale a provar ausência de qualquer associação entre estados e corretude. O probe H pode apresentar variação preditiva sem superar B. Além disso, o teste de permutação por fold examina associação intratarefa, e não a hipótese mais forte de ausência de informação condicional adicional. O contraste pareado e seus intervalos respondem à pergunta operacional sobre o procedimento ajustado.

Figura 2: WT-AUC Qwen por checkpoint. Intervalos por tarefa condicionais aos scorers OOF; 32 tokens é o endpoint primário, e os demais pontos são secundários.



Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

5.2 O resultado de classificação e a política original

Uma diferença de AUC não determina o custo de uma política. Por isso, a avaliação original também reproduziu a ordem dos candidatos e a parada ao primeiro sucesso mantido. Em N=20, os resultados são:

Tabela 3: Primeira etapa: replay com N=20 e toda a população de tarefas.

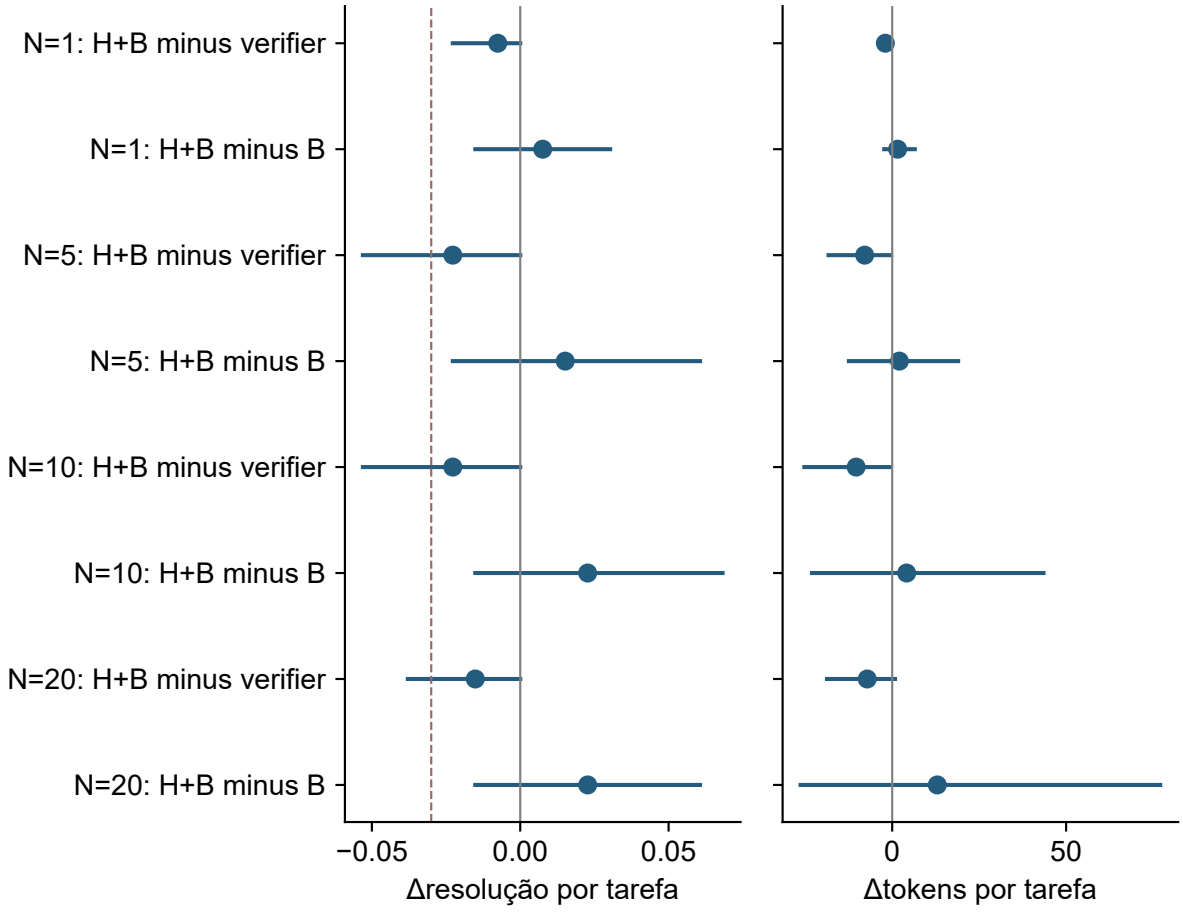
Política	**Resolvidas / 132**	**Tokens / tarefa**
Vinte completas	112	1534,0
Verificador	112	467,3
B	107	447,2
H+B	110	460,2

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Contra o verificador, H+B apresenta diferença de resolução de −0,015, IC95% [−0,038; 0,000] e diferença média de tokens de −7,18, IC95% [−18,73; 0,80]. Contra B, os respectivos contrastes são 0,023, IC95% [−0,015; 0,061] e 12,96, IC95% [−26,34; 77,05]. Os critérios conjuntos de resolução, economia e incremento preditivo não foram satisfeitos. Economias obtidas apenas por parar após um sucesso pertencem ao baseline com verificador e não podem ser creditadas ao probe.

A validação online em doze tarefas conferiu a reprodução de tokens, identidades, decisões e contagem de custo, incluindo aborto efetivo. Seu escopo foi técnico: não forneceu repetição suficiente para afirmar redução de latência. O replay dos demais orçamentos e seus intervalos permanece nos artefatos e é distinguido da execução online.

Figura 3: Diferenças pareadas de custo e resolução do procedimento Qwen original. A margem de três pontos percentuais pertence ao critério operacional desse protocolo.



Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

5.3 Transporte para MBPP+ e validação independente dos gates

Na primeira transferência, os modelos, calibradores e limiares ajustados em HumanEval+ foram aplicados a 32 tarefas MBPP+, sem reajuste no alvo. Em 32 tokens, a WT-AUC pontual de H+B ficou próxima de B, mas o comportamento de uma política depende do limiar transportado e do momento da decisão. A retenção pode se deteriorar mesmo quando uma métrica de ordenação permanece semelhante.

A comparação posterior em um checkpoint comum de oito tokens torna essa diferença mais clara. Nas 32 tarefas inicialmente examinadas, H+B manteve 276 dos 366 corretos ativos, enquanto B manteve 364. A observação motivou uma hipótese prospectiva delimitada: os dois gates congelados perderiam diferentes proporções de corretos em tarefas locais ainda não examinadas?

A validação independente foi concluída em outras 120 tarefas MBPP+, com vinte tentativas cada. Seu denominador comum contém 1.192 candidatos corretos ativos. Os resultados são:

Tabela 4: Validação independente anterior, 120 tarefas Qwen/MBPP+. Intervalos por tarefas, em percentuais.

Gate em t=8	Corretos mantidos	Corretos ativos	Retenção e IC95%
H+B	986	1192	82,72% [75,00; 89,72]
B	1181	1192	99,08% [98,30; 99,71]

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

A diferença de retenção H+B−B é −16,36 pontos percentuais, IC95% [−24,02; −9,43]. O intervalo inteiramente negativo satisfaz o critério direcional daquela avaliação. Essa evidência confirma uma limitação dos gates transportados em oito tokens; não é uma nova avaliação do contraste original em 32 tokens e não prova impossibilidade universal de informação latente.

Retenção de candidatos também não é resolução. Perder o único sucesso potencial de uma tarefa pode impedir sua solução; perder um entre vários sucessos pode não modificar a cobertura. Os denominadores dos candidatos iniciados e de todos os corretos potenciais são, por isso, mantidos separados.

5.4 O que as ablações exploratórias acrescentam

Os resultados motivaram diagnósticos de leitura: regularização mais forte, PCA e um corretor residual que parte da previsão de B. Como foram escolhidos após a inspeção do resultado principal, são exploratórios, ainda que seus ajustes internos respeitem o isolamento de tarefas.

Tabela 5: Diagnósticos posteriores no mesmo banco Qwen de origem; intervalos exploratórios condicionais.

Leitura	WT-AUC	ΔWT-AUC contra B e IC95%
H+B original	0,581	−0,047, IC95% [−0,099; 0,006]
H+B com PCA64	0,630	0,002, IC95% [−0,030; 0,034]
Correção residual de B	0,635	0,006, IC95% [−0,009; 0,024]

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

PCA64 e correção residual aproximam o desempenho do baseline e reduzem a desvantagem da combinação original. Seus intervalos não demonstram superioridade sobre B. Essa observação altera a interpretação do resultado: uma leitura latente de alta dimensão pode ser sensível à parametrização. Ela justifica fixar uma representação reduzida e testar outra classe de decodificador em uma nova avaliação, sem escolher retrospectivamente o vencedor desta tabela como evidência confirmatória.

Diagnósticos de prefixos idênticos fornecem um controle complementar. Com o mesmo prompt e os mesmos tokens já processados, um scorer determinístico deve empatar as tentativas, mesmo que suas continuações tenham resultados diferentes. A consistência dessas previsões verifica a instrumentação; não revela, por si só, por que uma determinada família perde informação ou calibração.

5.5 O espaço econômico disponível

O oracle contrafactual mantém todos os corretos e interrompe incorretos ativos, conhecendo seus labels finais. A comparação mostra que há trabalho dispensável no banco, mas não que um probe saiba identificá-lo. O espaço idealizado de economia e a capacidade empírica de aproveitá-lo são objetos distintos.

Tabela 6: Limite contrafactual na primeira etapa, N=20 e checkpoint de 32 tokens.

Política	Resolução	Tokens / tarefa
oracle	0,848	212,75
verifier	0,848	467,34

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Esses diagnósticos conectam a primeira à segunda etapa: há oportunidade econômica sob informação perfeita, sensibilidade à parametrização do leitor e problemas de transporte de decisões. A avaliação seguinte pergunta se uma comparação correspondente entre classes de probes, em outra família de gerador e em tarefas externas novas, modifica o incremento acessível de H.

6 COMPARAÇÃO ENTRE MODELOS E DECODIFICADORES

6.1 Desenvolvimento, precisão e população externa

A segunda etapa examina a limitação deixada pela primeira: o resultado incremental poderia depender da família do gerador e da capacidade do probe? O piloto DeepSeek foi concluído nas doze tarefas de desenvolvimento, com 240 tentativas, oito tarefas mistas, 41,67% de acertos, 0,42% de truncamento e 0,83% de erro de parsing. Os critérios de viabilidade foram satisfeitos. Esses números descrevem desenvolvimento e não são resultados do teste externo.

O planejamento adotou cem tarefas por gerador, a partir da hierarquia técnica prevista, preservando vinte tentativas em cada.

Antes de utilizar o conjunto externo, as escolhas de hiperparâmetros produziram os procedimentos abaixo. Ambos os conjuntos de features selecionaram largura 32 para o MLP, mas os números de épocas e os limiares foram próprios de cada ajuste.

Tabela 7: Configurações escolhidas exclusivamente em HumanEval+. Cada procedimento usa 106 tarefas para ajuste/seleção e 26 para calibração e limiar.

Gerador	Procedimento	Seleção	Épocas	Limiar
DeepSeek	B / logística	C=0,01	—	0,4964
DeepSeek	H+B / logística	C=0,01	—	0,5368
DeepSeek	B / MLP	Largura 32	167	0,4783
DeepSeek	H+B / MLP	Largura 32	65	0,5598
Qwen	B / logística	C=0,01	—	0,3764
Qwen	H+B / logística	C=0,01	—	0,3913
Qwen	B / MLP	Largura 32	99	0,3725
Qwen	H+B / MLP	Largura 32	76	0,3962

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Com a dispersão histórica e a frequência mista usadas como aproximação, a análise prospectiva de precisão forneceu os seguintes cenários:

Tabela 8: Planejamento para cem tarefas, condicional aos scores e à heterogeneidade histórica usada como aproximação.

Ganho verdadeiro simulado	Detecção positiva	Largura esperada do IC95%
0,020	10,3%	0,124
0,030	15,6%	0,124
0,050	36,1%	0,124
0,075	64,9%	0,124

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Os valores mostram que a amostra não prometia detecção confiável de ganhos pequenos. Não são poder pós-hoc calculado a partir do efeito externo. Também não garantem que DeepSeek/MBPP reproduza a heterogeneidade de Qwen/HumanEval. As oito repetições de seleção e ajuste completos na origem Qwen apresentaram desvios das diferenças de WT-AUC de 0,036 para

logística e 0,045 para MLP. Essa sensibilidade reforça o limite dos IC condicionais, sem estimar sem viés a variância do procedimento final.

As quatro mil gerações externas foram concluídas nos mesmos cem IDs. Apesar disso, o conjunto ativo aos 32 tokens é bastante diferente entre os modelos:

Tabela 9: Teste externo completo: cem tarefas e vinte tentativas por modelo, com elegibilidade T>32.

Gerador	Geradas	Ativas	Tarefas ativas	Tarefas mistas
DeepSeek	2000	1943	100	58
Qwen	2000	863	81	35

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

No Qwen, 1.137 respostas terminam até esse checkpoint; dezenove tarefas não possuem nenhuma tentativa ativa. No DeepSeek, somente 57 respostas terminam até ele. A comparação intratarefa se apoia em 35 tarefas mistas no Qwen e 58 no DeepSeek. Portanto, diferenças de AUC entre geradores não podem ser atribuídas apenas à arquitetura: a população condicionada ao comprimento também muda.

6.2 Hipótese primária: incremento no DeepSeek com MLP

O contraste primário compara H+B/MLP e B/MLP em 32 tokens, com os procedimentos ajustados em HumanEval+ e congelados antes do teste. B/MLP alcança WT-AUC de 0,5225; H+B/MLP, 0,5183. A diferença é −0,0042, IC95% [−0,0648; 0,0548], nas 58 tarefas mistas.

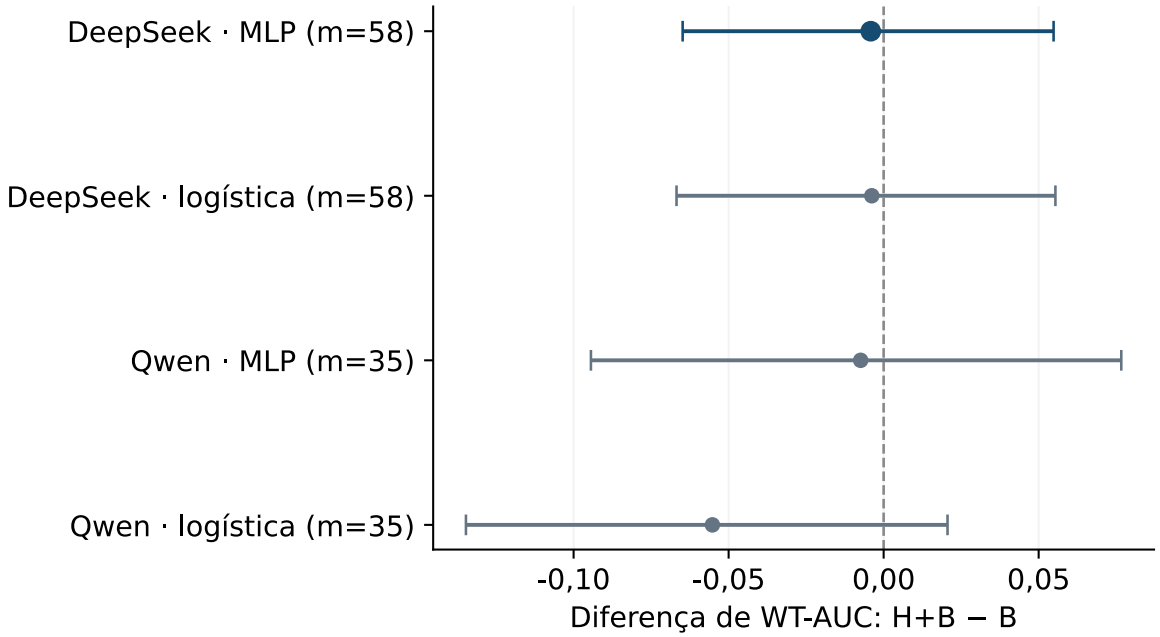
O resultado é inconclusivo. O intervalo inclui zero, ganhos próximos de 0,05 e perdas próximas de 0,06. Não se demonstrou ganho incremental, deterioração ou equivalência prática para esse procedimento. Essa é uma limitação de precisão e da evidência observada, e não uma prova de que nenhum decodificador possa acessar sinal latente.

Tabela 10: H+B menos B dentro da mesma classe. Bootstrap pareado de 10.000 réplicas.

Gerador / classe	ΔWT-AUC e IC95%	Mistas	Estatuto
DeepSeek / MLP	−0,0042, IC95% [−0,0648; 0,0548]	58	Primário
DeepSeek / logística	−0,0038, IC95% [−0,0668; 0,0554]	58	Secundário
Qwen / MLP	−0,0074, IC95% [−0,0944; 0,0766]	35	Secundário
Qwen / logística	−0,0552, IC95% [−0,1347; 0,0206]	35	Secundário

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Figura 4: ΔWT-AUC H+B−B no teste MBPP+ aos 32 tokens: 58 tarefas mistas DeepSeek e 35 Qwen. O ponto destacado é primário; os demais são secundários. IC95% pareados por tarefa, condicionais aos procedimentos congelados.



Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

6.3 Capacidade do probe e diferenças entre geradores

Nenhum dos outros três contrastes de WT-AUC possui IC95% inteiramente positivo. No DeepSeek, as diferenças de logística e MLP são próximas de zero. No Qwen, a desvantagem pontual de H+B é maior na logística e menor no MLP. Para avaliar essa mudança sem confundir incremento absoluto e interação, reporta-se Γ:

Tabela 11: Mudança secundária do incremento de H ao passar da logística para MLP.

Gerador	Γ e IC95%	Tarefas mistas
DeepSeek	−0,0003, IC95% [−0,0313; 0,0323]	58
Qwen	0,0478, IC95% [0,0178; 0,0810]	35

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

No Qwen, o intervalo secundário de Γ fica acima de zero. Isso significa que o contraste H+B−B se torna mais favorável ao trocar a classe do probe; não significa que H+B/MLP supere B/MLP. Seu incremento absoluto permanece −0,0074, IC95% [−0,0944; 0,0766]. A distinção é necessária para não transformar a redução de uma desvantagem em uma demonstração de superioridade.

O contraste entre os incrementos MLP de DeepSeek e Qwen, restrito às 28 tarefas mistas comuns, foi −0,0130, IC95% [−0,1355; 0,1125]. Essa análise mantém a tarefa como cluster compartilhado, mas muda a população em relação aos contrastes de cada modelo. É secundária e não estabelece uma diferença geral entre famílias de SLMs.

6.4 Probabilidades, ranking e calibração

As métricas pontuais dos oito procedimentos evidenciam por que a ordenação intratarefa não esgota a avaliação:

Tabela 12: Métricas pontuais do teste externo aos 32 tokens. Populações ativas próprias de cada modelo.

Gerador	Features / probe	AUC agregada	WT-AUC	Log loss	Brier
DeepSeek	B / logística	0,532	0,516	0,728	0,267
DeepSeek	H+B / logística	0,542	0,512	0,723	0,265
DeepSeek	B / MLP	0,568	0,522	0,726	0,266
DeepSeek	H+B / MLP	0,574	0,518	0,718	0,262
Qwen	B / logística	0,735	0,660	0,638	0,223
Qwen	H+B / logística	0,721	0,604	0,641	0,225
Qwen	B / MLP	0,746	0,640	0,624	0,217
Qwen	H+B / MLP	0,711	0,632	0,652	0,230

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Os contrastes de perdas usam todas as tarefas com candidatos ativos, inclusive homogêneas: cem no DeepSeek e 81 no Qwen. Eles não utilizam o mesmo denominador das AUCs intratarefa.

Tabela 13: Contrastes secundários H+B−B. Valores negativos indicam menor perda; IC pontuais sem ajuste de multiplicidade.

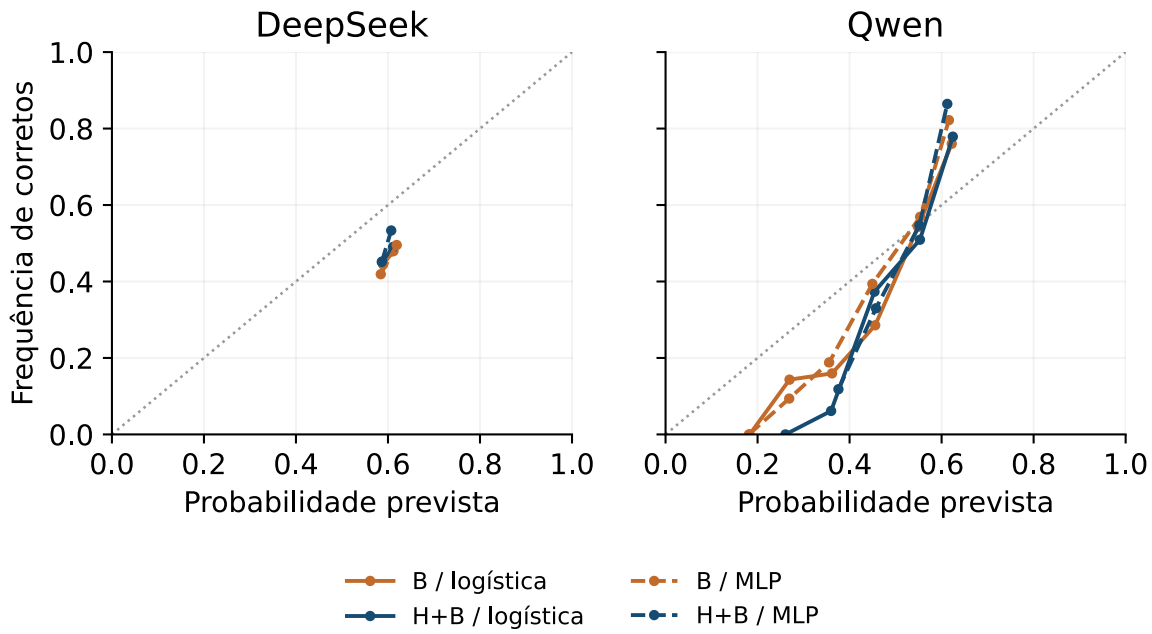
Gerador / classe	Δlog loss e IC95%	ΔBrier e IC95%
DeepSeek / logística	−0,0047, IC95% [−0,0080; −0,0016]	−0,0023, IC95% [−0,0038; −0,0008]
DeepSeek / MLP	−0,0075, IC95% [−0,0138; −0,0014]	−0,0036, IC95% [−0,0066; −0,0007]
Qwen / logística	0,0037, IC95% [−0,0084; 0,0156]	0,0019, IC95% [−0,0041; 0,0077]
Qwen / MLP	0,0278, IC95% [0,0085; 0,0468]	0,0132, IC95% [0,0038; 0,0225]

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

No DeepSeek, as diferenças secundárias de log loss e Brier favorecem H+B nas duas classes. É possível melhorar probabilidades sem melhorar de forma demonstrada a ordenação entre tentativas. No Qwen, H+B/MLP apresenta maior perda probabilística que B/MLP. A inclusão de H, portanto, não produz um comportamento uniforme entre modelos ou métricas. Esses intervalos são pontuais, sem controle de multiplicidade, e não confirmam uma hipótese primária que teve resultado inconclusivo.

A calibração é examinada com os bins fixados antes do teste. Cada ponto resume um bin não vazio; a linha diagonal indica correspondência perfeita entre probabilidade e frequência. Os tamanhos dos bins diferem, e pontos ligados não constituem uma curva populacional estimada com precisão uniforme. Os valores por bin estão preservados nos artefatos. Probabilidade alta não constitui uma garantia certificada de retenção.

Figura 5: Calibração descritiva no MBPP+, T>32: 1.943 candidatos em cem tarefas DeepSeek e 863 em 81 Qwen. Dez bins fixos, com ponderação por tarefa; eixos em proporções e pontos sem IC. Calibradores ajustados exclusivamente na origem.



Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

6.5 Replay secundário e consequência das decisões

O replay utiliza as mesmas tentativas, na ordem original, com limiares da origem. Em N=20, os resultados por política foram:

Tabela 14: DeepSeek: replay N=20 nas cem tarefas externas. Retenção entre corretos ativos potenciais.

Política	**Resolvidas**	**Tokens / tarefa**	**Retenção**	**Ab. corretos**	**Perdidas**
Vinte completas	71	2709,31	100,00%	0	0
Verificador	71	1260,38	100,00%	0	0
B / logística	71	1260,38	100,00%	0	0
H+B / logística	71	1256,94	100,00%	0	0
B / MLP	71	1260,38	100,00%	0	0
H+B / MLP	71	1243,65	99,45%	1	0
Oracle	71	304,37	100,00%	0	0

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Tabela 15: Qwen: replay N=20 nas cem tarefas externas. Retenção entre corretos ativos potenciais.

Política	Resolvidas	Tokens / tarefa	Retenção	Ab. corretos	Perdidas
Vinte completas	75	791,88	100,00%	0	0
Verificador	75	318,71	100,00%	0	0
B / logística	75	282,80	97,80%	0	0
H+B / logística	75	282,09	97,48%	0	0
B / MLP	75	271,76	96,23%	0	0
H+B / MLP	75	300,05	99,06%	0	0
Oracle	75	200,37	100,00%	0	0

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

"Retenção" é a fração mantida de todos os corretos ativos do banco no orçamento. "Ab. corretos" conta os corretos efetivamente interrompidos entre as tentativas iniciadas. As duas colunas não são complementares porque a parada após sucesso impede que parte do banco seja iniciada. Nenhuma política perdeu tarefas em relação ao verificador neste conjunto, mas essa ausência observada não certifica ausência de perdas futuras.

Tabela 16: Diferenças pareadas contra parada por verificador. Resultados operacionais secundários.

Gerador / gate	Δtokens e IC95%	Δresolução e IC95%
DeepSeek / B / MLP	0,00, IC95% [0,00; 0,00]	0,000, IC95% [0,000; 0,000]
DeepSeek / H+B / MLP	−16,73, IC95% [−35,47; −3,34]	0,000, IC95% [0,000; 0,000]
Qwen / B / MLP	−46,95, IC95% [−93,10; −16,33]	0,000, IC95% [0,000; 0,000]
Qwen / H+B / MLP	−18,66, IC95% [−40,58; −4,53]	0,000, IC95% [0,000; 0,000]

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

No DeepSeek, H+B/MLP reduz o custo médio de 1.260,38 para 1.243,65 tokens por tarefa, mantendo 71 resolvidas no banco. A economia pontual é aproximadamente 1,33%: são 7 abortos entre 754 tentativas iniciadas, um deles correto. B/MLP não interrompe nenhuma das 752 tentativas iniciadas e reproduz a parada por verificador. A pequena economia secundária de H+B precisa ser comparada aos custos de adquirir e executar o sinal.

No Qwen, B/MLP e H+B/MLP preservam as 75 tarefas resolvidas, mas têm custos médios de 271,76 e 300,05 tokens. H+B/MLP mantém maior fração dos corretos ativos potenciais, enquanto B/MLP gera menos tokens. Esse compromisso não é resumido por AUC, e as metas de retenção da origem não escolhem automaticamente a preferência econômica no alvo.

Incluindo os gastos das tarefas não resolvidas, o custo agregado por tarefa resolvida no DeepSeek é 1775,18 tokens com verificador e 1751,62 com H+B/MLP. No Qwen, os valores são 424,95 com verificador, 362,35 com B/MLP e 400,07 com H+B/MLP. Trata-se de uma razão agregada, e não do custo médio apenas das tarefas que tiveram sucesso.

O oracle resolve as mesmas tarefas que o verificador com 304,37 tokens médios no DeepSeek e 200,37 no Qwen. A distância aos gates é um limite contrafactual sob conhecimento

dos labels, não uma promessa de ganho alcançável. O replay completo de N=1, 5, 10 e 20 está preservado nos artefatos; nenhuma leitura secundária modifica a hipótese primária.

6.6 Recursos medidos e síntese da etapa

Tabela 17: Sessões da extensão final na RTX 3050 Laptop. Valores de parede ativa e memória do PyTorch; treino dos probes em CPU.

Coleta	Tentativas	Horas ativas	Pico reservado / GiB
Piloto DeepSeek	240	1,46	3,63
Técnico Qwen	12	0,05	4,63
Origem DeepSeek	2640	18,83	3,63
Externo DeepSeek	2000	9,54	3,38
Externo Qwen	2000	3,61	4,64

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

A etapa consumiu 33,49 horas de sessão ativa, dentro do orçamento de sessenta. O tempo de parede bruto foi 43,17 horas, incluindo 9,68 horas de suspensão do sistema, excluídas por evidência do Windows e preservadas nos registros originais. Sessão ativa inclui carregamento e verificação; não é tempo de kernels CUDA. Medições de score em lote na CPU também não estimam, por si só, o overhead de uma política online.

A síntese é delimitada: a mudança de família e o MLP não produziram ganho de WT--AUC demonstrado nos contrastes testados; a parametrização e a métrica escolhida modificam outros aspectos do desempenho. O estudo não estabelece impossibilidade de sinal interno, equivalência entre features ou superioridade econômica geral. Esses limites orientam a discussão conjunta das duas etapas.

7 DISCUSSÃO

7.1 Uma resposta articulada às perguntas do estudo

O resultado original em Qwen foi ΔWT-AUC(H+B−B) = −0,047, IC95% [−0,099; 0,006], com maior log loss de H+B. Na avaliação prospectiva da segunda etapa, o contraste primário DeepSeek/MLP foi −0,0042, IC95% [−0,0648; 0,0548]. Nenhum demonstra incremento intratarefa positivo, mas os intervalos não excluem toda melhora relevante. A validação independente de gates, por sua vez, confirmou uma perda específica de retenção, de −16,36 pontos percentuais, no transporte do procedimento anterior em oito tokens. São conclusões sobre estimandos distintos, não repetições de um mesmo teste.

O conjunto responde às perguntas da introdução em níveis diferentes. Há previsibilidade que pode decorrer de diferenças entre tarefas, mas isso não basta para selecionar tentativas (Q1). O incremento das ativações não foi demonstrado nos contrastes primários (Q2). A capacidade do probe altera parte do comportamento, sem estabelecer superioridade de H+B/MLP, e não há efeito uniforme entre os dois modelos (Q3). A retenção do sistema congelado anterior não se transportou satisfatoriamente, e os procedimentos novos também precisam ser julgados em suas próprias populações ativas (Q4). O replay observa economias secundárias e compromissos de retenção, sem comprovar benefício econômico geral ou aceleração online (Q5).

7.2 O que o resultado inconclusivo permite afirmar

A interpretação deve preservar a diferença entre uma afirmação sobre o procedimento avaliado e uma afirmação sobre toda a informação disponível. Os probes receberam representações específicas, tiveram capacidade e regularização limitadas e foram ajustados em amostras finitas. Não demonstrar incremento nesse desenho significa que a evidência não estabeleceu a superioridade desse procedimento sobre seu baseline. Não significa que todas as funções dos estados internos sejam incapazes de prever corretude.

Também não se conclui equivalência porque o intervalo inclui zero. No contraste primário DeepSeek/MLP, o intervalo ainda comporta ganhos de aproximadamente 0,05 de WT--AUC. A análise de planejamento já indicava poder limitado para diferenças pequenas; o teste externo encontrou menos tarefas mistas do que o cenário histórico de referência. A contribuição não é eliminar essa incerteza por linguagem mais forte, mas explicitar os efeitos que a avaliação ainda não distingue.

A evidência original é mais específica em outro aspecto: a diferença de log loss positiva indica pior qualidade probabilística de H+B naquele ajuste. A extensão acrescenta que esse comportamento não é uniforme. No DeepSeek, as perdas secundárias favorecem H+B; no Qwen com MLP, o contrário ocorre. Essas observações ampliam a interpretação do fenômeno, sem substituir o contraste primário por uma métrica escolhida após conhecer seu sinal.

7.3 Capacidade do probe e acesso ao sinal

A comparação entre logística e MLP enfrenta uma limitação real da primeira etapa. Um probe linear não representa todas as relações entre prefixo e resultado; por outro lado, acrescentar flexibilidade aumenta a necessidade de regularização e de dados. Os resultados não sustentam que a simples troca por um MLP resolva a questão incremental.

A interação positiva secundária no Qwen exige uma leitura particularmente cuidadosa. Γ compara dois incrementos: ele pode crescer porque H+B melhora, porque B piora ao mudar de classe, ou pelos dois motivos. As métricas pontuais mostram que esses movimentos podem coexistir. Portanto, maior interação não isola uma melhoria absoluta do uso das ativações. O teste de H+B/MLP contra B/MLP continua sendo necessário.

A igualdade de largura e orçamento de seleção controla uma parte importante da comparação, mas não iguala o número de parâmetros: H+B possui mais entradas. O PCA64 reduz essa diferença e mantém o mesmo número de componentes latentes nos dois geradores, sem garantir que tais componentes expressem o mesmo conteúdo. O whitening e a seleção pela perda também podem influenciar a estabilidade. Os resultados dizem respeito a esse procedimento completo, não a uma medida direta da quantidade de informação semanticamente representada.

As ablações exploratórias da primeira etapa já mostravam que o resultado era sensível à leitura. A nova avaliação aproveita essa motivação sem apagar sua origem posterior. Não é uma repetição exata do H+B original: além do benchmark e dos candidatos, mudaram a representação reduzida e o esquema de desenvolvimento. A comparação controlada relevante ocorre entre as quatro famílias dentro da segunda etapa.

7.4 Modelo, tokenizer e população sob risco

Avaliar duas famílias amplia o escopo em relação ao Qwen isolado, mas não torna a comparação uma experiência causal sobre arquitetura. Os modelos diferem em pré-treinamento, ajuste instrucional, vocabulário, formatação e comprimento das respostas. Essas diferenças afetam tanto os observáveis quanto a composição dos candidatos que chegam a 32 tokens.

O contraste de comprimentos é expressivo: mais da metade das respostas Qwen do teste termina até o checkpoint, enquanto quase todas as respostas DeepSeek continuam ativas. O mesmo número de tokens, portanto, não implica a mesma fração de programa observada ou a mesma oportunidade de economia. No Qwen, parte importante dos sucessos e fracassos já foi encaminhada ao verificador antes que o gate possa atuar.

Essa seleção também limita comparações diretas de WT-AUC entre modelos. As 58 tarefas mistas do DeepSeek e as 35 do Qwen não são dois grupos independentes nem a mesma população. A análise nas 28 tarefas mistas comuns conserva o pareamento, mas responde a uma pergunta mais restrita. Ela não permite declarar que uma família contém universalmente mais sinal precoce que a outra.

Um checkpoint semanticamente alinhado, por instrução de código ou por proporção do comprimento, seria outra condição experimental. Seu desenvolvimento deveria ocorrer sem escolher o ponto que produz o melhor resultado nas tarefas externas já examinadas. A constatação atual é uma limitação do uso de posições tokenizadas fixas, e não autorização para alterar retrospectivamente o endpoint.

7.5 Probabilidades, limiares e transporte

Ordenação e qualidade probabilística podem variar separadamente. Uma transformação monotônica das previsões preserva a AUC, mas altera perdas e decisões em limiares numéricos. Mesmo entre modelos que não são simples transformações um do outro, melhorar o nível das probabilidades não implica produzir uma ordenação intratarefa mais informativa. Por isso, as melhorias secundárias de log loss e Brier no DeepSeek são compatíveis com uma WT-AUC incremental inconclusiva.

A política utiliza um limiar escolhido em tarefas de calibração da origem. Sua retenção de desenvolvimento é um resultado no conjunto de ajuste e não uma certificação para MBPP+. A validação independente dos gates anteriores demonstra essa limitação de forma direta: um alvo de retenção alto no desenvolvimento não impediu uma perda substancial de corretos no transporte. O novo teste, com outros probes, não revoga essa constatação.

Também não se identifica a causa exclusiva da mudança como domain shift. Prevalência, dificuldade, comprimento, formatação e o ajuste final sobre a origem podem contribuir. A comparação entre OOF, desenvolvimento e aplicação congelada precisa permanecer explícita. Recalibrar sobre o conjunto externo e então avaliar nesse mesmo conjunto eliminaria justamente o teste de transporte que se pretende realizar.

7.6 O que a economia observada representa

O replay distingue a economia disponível por parar após verificar um sucesso daquela que depende de interromper um candidato. A primeira já está presente no baseline com verificador. A contribuição do gate deve ser medida contra esse baseline, com a mesma ordem, população e limite de tentativas.

Na segunda etapa, algumas políticas reduzem tokens sem perda observada de tarefas, mas os tamanhos e os compromissos são diferentes. No DeepSeek, a economia de H+B/MLP é pequena em relação ao custo do verificador. No Qwen, B/MLP gera menos tokens que H+B/MLP, enquanto H+B/MLP preserva mais corretos ativos potenciais. Essa diferença ilustra por que uma preferência econômica depende da penalidade atribuída aos sucessos descartados e da disponibilidade de outros sucessos na tarefa.

Nenhuma perda observada não é garantia de nenhuma perda futura. Em um conjunto em que todas as diferenças de resolução são zero, reamostrar as mesmas tarefas também produz diferenças zero. Um intervalo empírico degenerado não representa evidência de que um evento

raro seja impossível em outras tarefas. A avaliação operacional desta etapa é secundária e não fornece uma nova certificação de não inferioridade.

Além disso, o custo de tokens não incorpora toda a política. O estado após o token do checkpoint exige processamento, a captura transfere dados, e o probe precisa ser executado. Uma economia pequena pode ser anulada por esses custos em tempo, mesmo quando o score em lote parece barato. A pesquisa mede condições técnicas, mas não estabelece aceleração online ou retorno financeiro.

O oracle utiliza informação indisponível no momento da decisão. Sua economia mostra que existe trabalho dispensável sob conhecimento perfeito, sem indicar que esse trabalho possa ser identificado com alta retenção a partir do prefixo. A distância observada não é uma meta garantida para outro classificador.

7.7 A contribuição da formulação sequencial

A recursão de Bellman reúne elementos que AUC e retenção isoladas não representam: tentativas restantes, orçamento, custo de completar e valor de abandonar para reiniciar. No caso simplificado, continuar quando p vezes o custo de fallback excede o custo restante decorre da comparação dos dois custos esperados. A interpretação depende de ambos os caminhos conduzirem ao mesmo fallback após fracasso.

No sistema real, completar uma tentativa consome recurso e pode atualizar a informação sobre a tarefa. A condição simplificada deixa de ser geral. Essa distinção evita apresentar um limiar fixo ajustado por recall como uma política ótima. As probabilidades estimadas, seus erros de calibração e o custo de adquirir o sinal são parte da decisão, não detalhes externos a ela.

A contribuição matemática é explicativa e delimitada. As identidades de probabilidade, o custo por soma geométrica e a programação dinâmica têm antecedentes. Sua utilidade aqui é mostrar que um bom decodificador de corretude e um bom controlador de inferência não são o mesmo objeto.

7.8 Limitações de precisão e de validade

A unidade independente relevante para generalização é a tarefa. Milhares de trajetórias e de pares positivo-negativo não substituem centenas de tarefas distintas. A restrição às mistas e ao conjunto ativo reduz ainda mais o tamanho efetivo para certos estimandos. As perdas, a AUC e o replay possuem denominadores diferentes, que precisam acompanhar cada conclusão.

Os intervalos condicionam nos probes treinados. Oito repetições de seleção e ajuste na origem mostram sensibilidade à perturbação das tarefas, mas não constituem uma estimativa completa da incerteza de treinamento. Não se deve somar essa dispersão mecanicamente ao IC externo ou apresentá-la como uma cobertura frequentista certificada de todo o procedimento.

As garantias de isolamento também têm escopo. Separar folds por tarefa evita um tipo de vazamento, mas não elimina decisões humanas informadas por exposições anteriores. A primeira etapa declara 26 tarefas principais presentes no histórico. A nova reserva excluiu resul-

tados locais anteriores e variantes lexicais identificadas; não certifica independência semântica total ou ausência de contaminação no pré-treinamento.

Por fim, passar em testes finitos não é uma prova de correção para todas as entradas. Parser, limites de execução e cobertura das suítes integram a medida. A reavaliação dos labels Qwen no sandbox novo sustenta a compatibilidade dos desfechos reutilizados, sem tornar o verificador perfeito. As conclusões permanecem condicionais a um cenário com acesso a verificação funcional forte.

7.9 Continuidade científica

As próximas perguntas devem preservar a separação entre desenvolvimento e teste. Prioridades são ampliar o número de tarefas realmente novas, avaliar funções e projetos mais longos, comparar baselines textuais mais fortes e medir a política online com overhead completo. Um checkpoint definido por evento de código exigiria um novo protocolo.

Aumentar a capacidade dos probes também continua sendo uma possibilidade, mas já não pode ser descrita como uma direção inteiramente ausente deste estudo: um MLP pequeno foi efetivamente avaliado. Outras arquiteturas precisariam de amostra, regularização e controles próprios, sem usar o conjunto externo atual como fonte reiterada de seleção.

Intervenções nas ativações respondem a uma pergunta causal diferente. Uma direção que prediz corretude não necessariamente permite aumentar sua probabilidade quando modificada. Avaliar steering, ou reinvestir a economia em novas tentativas, requer experiências adicionais. A conclusão desta obra é o que as duas etapas permitem afirmar sobre leitura e decisão, mantendo essas extensões como hipóteses futuras.

8 CONSIDERAÇÕES FINAIS

Este trabalho avaliou sinais latentes precoces de corretude em geração de código, com cinco perguntas articuladas. Sobre **previsibilidade (Q1)**, o probe H isolado alcançou WT-AUC pontual de 0,568 no experimento original. Capacidade preditiva dos estados não implica automaticamente incremento sobre observáveis ou benefício de interrupção; a avaliação separou esses níveis, preservando a tarefa como unidade de generalização.

Quanto ao **incremento (Q2)**, a primeira etapa avaliou Qwen2.5-Coder-1.5B-Instruct em 2.640 tentativas de 132 tarefas HumanEval+, com validação aninhada e probes lineares. Em 32 tokens, ΔWT-AUC(H+B−B) foi −0,047, IC95% [−0,099; 0,006]; Δlog loss foi 0,038, IC95% [0,007; 0,071]. O critério incremental original não foi satisfeito, sem benefício operacional conjunto demonstrado.

Sobre **capacidade e modelo (Q3)**, os diagnósticos exploratórios motivaram a comparação prospectiva com DeepSeek-Coder-1.3B-Instruct e logística/MLP nos dois geradores. Oito procedimentos foram desenvolvidos em HumanEval+ e congelados antes de quatro mil gerações externas nas mesmas cem tarefas MBPP+ por modelo. No contraste primário DeepSeek/MLP, ΔWT-AUC foi −0,0042, IC95% [−0,0648; 0,0548], em 58 tarefas mistas: resultado inconclusivo, sem ganho, deterioração ou equivalência demonstrados.

A interação secundária no Qwen reduz uma desvantagem linear, sem demonstrar incremento positivo. Melhorias secundárias de probabilidade no DeepSeek também não substituem o teste de ordenação. Não se estabeleceu efeito uniforme das ativações ou da maior expressividade.

Quanto ao **transporte (Q4)**, a validação independente em 120 tarefas MBPP+ confirmou uma limitação dos gates anteriores de oito tokens: retenção de 82,72% para H+B e 99,08% para B, diferença de −16,36 pontos percentuais. Essa confirmação específica não estende o resultado a todo procedimento de leitura latente.

Sobre **decisão e custo (Q5)**, alguns replays economizam tokens sem perda observada de tarefas. O achado secundário não certifica retenção populacional, aceleração ou superioridade econômica geral de H+B. O oracle delimita oportunidade sob informação perfeita; Bellman explica o papel de custo restante, orçamento e reinício, sem tornar os gates empíricos ótimos.

Os intervalos são condicionais aos probes ajustados; poucas tarefas mistas e variabilidade de treinamento limitam a precisão. Dois geradores e funções curtas públicas não representam toda a geração de software nem eliminam contaminação no pré-treinamento. Os resultados não demonstram ausência universal de informação latente.

A contribuição é uma avaliação controlada que separa previsibilidade, incremento e economia. Avançar requer novas tarefas e distribuições, baselines textuais mais fortes e medições online de custo, preservando a separação entre desenvolvimento e teste.

REFERÊNCIAS

AZARIA, Amos; MITCHELL, Tom. **The Internal State of an LLM Knows When It's Lying**. 2023. Disponível em: <https://arxiv.org/abs/2304.13734>. Acesso em: 17 out. 2026.

BROWN, Bradley *et al*. **Large Language Monkeys: Scaling Inference Compute with Repeated Sampling**. 2024. Disponível em: <https://arxiv.org/abs/2407.21787>. Acesso em: 17 out. 2026.

CALLAWAY, Frederick *et al*. Learning to Select Computations. *In:* 34TH CONFERENCE ON UNCERTAINTY IN ARTIFICIAL INTELLIGENCE. **Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence.** 2018. Disponível em: <https://arxiv.org/abs/1711.06892v3>. Acesso em: 7 nov. 2026

CAWLEY, Gavin C.; TALBOT, Nicola L. C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. **Journal of Machine Learning Research**, v. 11, p. 2079–2107, 2010.

CHEN, Mark *et al*. **Evaluating Large Language Models Trained on Code**. 2021. Disponível em: <https://arxiv.org/abs/2107.03374>. Acesso em: 17 out. 2026.

DI CICCO, Carlo. **Code Correctness Is Linearly Decodable from LLM Hidden States Before Generation**. 2026. Disponível em: <https://arxiv.org/abs/2606.14530v3>. Acesso em: 17 out. 2026.

GUO, Daya *et al*. **DeepSeek-Coder: When the Large Language Model Meets Programming – The Rise of Code Intelligence**. 2024. Disponível em: <https://arxiv.org/abs/2401.14196v2>. Acesso em: 7 nov. 2026.

HEWITT, John; LIANG, Percy. Designing and Interpreting Probes with Control Tasks. *In:* EMNLP-IJCNLP. **Proceedings of EMNLP-IJCNLP.** 2019. Disponível em: <https://aclanthology.org/D19-1275/>. Acesso em: 17 out. 2026

HUI, Binyuan *et al*. **Qwen2.5-Coder Technical Report**. 2024. Disponível em: <https://arxiv.org/abs/2409.12186>. Acesso em: 17 out. 2026.

KADAVATH, Saurav *et al*. **Language Models (Mostly) Know What They Know**. 2022. Disponível em: <https://arxiv.org/abs/2207.05221>. Acesso em: 17 out. 2026.

KLASSERT, Thomas. **Introspective Uncertainty Estimation for LLM-Based Code Generation**. 2026. Disponível em: <https://arxiv.org/abs/2609.13975v1>. Acesso em: 17 out. 2026.

LIU, Jiawei *et al*. **Is Your Code Generated by ChatGPT Really Correct? Rigorous Evaluation of Large Language Models for Code Generation**. 2023. Disponível em: <https://arxiv.org/abs/2305.01210>. Acesso em: 17 out. 2026.

OVADIA, Yaniv *et al*. Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift. *In:* CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS. **Advances in Neural Information Processing Systems.** 2019. Disponível em: <https://papers.neurips.cc/paper_files/paper/2019/hash/8558cb408c1d76621371888657d2eb1d-Abstract.html>. Acesso em: 17 out. 2026

RATHNASURIYA, Ravishka; YANG, Wei. **Characterizing Overconfident Failure in LLM--Based Code Generation**. 2026. Disponível em: <https://arxiv.org/abs/2610.11300v1>. Acesso em: 17 out. 2026.

RUAN, Kai *et al*. **Doomed from the Start: Early Abort of LLM Agent Episodes via a Recall-Controlled Probe Cascade**. 2026. Disponível em: <https://arxiv.org/abs/2607.06503v2>. Acesso em: 17 out. 2026.

RUSSELL, Stuart; WEFALD, Eric. Principles of Metareasoning. **Artificial Intelligence**, v. 49, n. 1–3, p. 361–395, 1991.

VASWANI, Ashish *et al*. **Attention Is All You Need**. 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 17 out. 2026.

WAN, Guangya *et al*. **BEACON: Bayesian Optimal Stopping for Efficient LLM Sampling**. 2025. Disponível em: <https://arxiv.org/abs/2510.15945v1>. Acesso em: 7 nov. 2026.

WANG, Yiming *et al*. **Sampling-Efficient Test-Time Scaling: Self-Estimating the Best-of--N Sampling in Early Decoding**. 2025. Disponível em: <https://arxiv.org/abs/2503.01422v3>. Acesso em: 17 out. 2026.

ZHU, Yubo *et al*. **The LLM Already Knows: Estimating LLM-Perceived Question Difficulty via Hidden Representations**. 2025. Disponível em: <https://arxiv.org/abs/2509.12886v1>. Acesso em: 17 out. 2026.

ZOU, Andy *et al*. **Representation Engineering: A Top-Down Approach to AI Transparency**. 2023. Disponível em: <https://arxiv.org/abs/2310.01405>. Acesso em: 17 out. 2026.

APÊNDICE A — REPRODUTIBILIDADE E PROVENIÊNCIA

A.1 Separação entre análise e redação

Os resultados empíricos foram concluídos antes da revisão integrada deste manuscrito. A edição reorganiza a argumentação e renderiza tabelas dos artefatos; não gera candidatos, não reajusta probes e não substitui resultados antigos. A versão anterior de 75 páginas, seus fontes e hashes foram arquivados antes da revisão de 7 de novembro de 2026.

O documento atual combina fontes autorais em chapters, templates editoriais em templates e seções numéricas em generated. A renderização integrada lê tanto os resultados históricos quanto os da extensão final. Não depende de carregar um gerador de código ou executar código produzido por modelos.

```
.venv/Scripts/python.exe scripts/build_manuscript.py --compile
```

O manifesto editorial identifica hashes das entradas, dos fontes ativos e do PDF. A geração falha se faltar um artefato necessário, se o resultado externo estiver incompleto ou se permanecerem marcadores não resolvidos. O notebook e os relatórios anteriores mantêm sua finalidade e não são apresentados como se já contivessem toda a análise da segunda etapa.

A.2 Artefatos científicos de referência

Quadro 6: Entradas que permitem localizar os resultados e suas condições.

Objeto	Arquivo ou diretório
Primeira etapa e protocolo	RESEARCH_PROTOCOL.md; reports/protocol_v0.2/results.json.
Transferência inicial	reports/transfer_v0.2/results.json.
Ablações exploratórias	reports/excellence/models/results.json.
Validação independente dos gates	reports/excellence/independent_v1/results.json e relatórios correspondentes.
Protocolo entre modelos	docs/protocols/FINAL_CROSS_MODEL_EXTENSION_v1.md e sua emenda de recursos.
Reserva e congelamento	reports/final_extension/task_inventory.json, final_design.json e freeze.json.
Resultados e replay finais	reports/final_extension/results.json, external_predictions.csv e replay_per_task.csv.
Treinamento e poder	Manifests dos probes, power_results.json e qwen_training_sensitivity.json.
Contabilidade e integridade	status.json, historical_hashes.json, model_weight_integrity.json e registros de suspensão.

Fonte: elaboração própria a partir dos artefatos e procedimentos identificados na legenda.

Os IDs completos, as seeds e os hashes são preservados nos artefatos, evitando listas extensas no corpo do texto. As revisões dos modelos são Qwen 2e1fd397ee46e1388853d2af2c993145b0f1098a e DeepSeek e063262dac8366fc1f28a4da0ff3c50ea66259ca, aplicadas também aos tokenizers. As revisões fixam a condição avaliada; “versão mais recente” não é uma descrição reprodutível.

O ambiente principal utiliza Python 3.12.8, PyTorch 2.12.0+cu126 e Transformers 4.46.3. EvalPlus 0.3.1 roda em Ubuntu/WSL para seus mecanismos POSIX. As versões completas, CUDA, driver, precisão e picos de memória são registrados nos manifestos. A RTX 4060 mencionada na motivação de execução não estava acessível: os números publicados correspondem à RTX 3050 Laptop de 6 GB.

A.3 Cronologia e exposição anterior

O v0.2 foi executado sob autorização do estudante, com snapshot anterior ao banco principal. Seu registro histórico não apresenta aprovação do orientador como concluída, e a execução não é convertida em pré-registro independente. Vinte e seis tarefas principais já apareciam em registros exploratórios anteriores. Essa exposição humana é distinta de vazamento entre folds e permanece uma limitação declarada.

As ablações de parametrização foram posteriores à inspeção dos resultados. A validação de gates em 120 novas tarefas teve autorização e congelamento próprios; o estudante informou revisão do orientador para aquela extensão. Esse relato não é tratado como assinatura ou aprovação retroativa do v0.2.

A segunda etapa foi autorizada em 4 de novembro de 2026. O piloto e os critérios de viabilidade precederam a definição da amostra final; os procedimentos e cem IDs externos foram congelados em 5 de novembro, antes da geração correspondente. O arquivo de trava registra zero resultados externos novos anteriores ao congelamento. Não se reivindica pré-registro independente ou aprovação adicional do orientador para essa etapa.

O inventário considerou as 32 tarefas da transferência, as vinte técnicas da extensão anterior, as 120 da validação independente e controles já utilizados. Exposição local significa presença de resultados anteriores nos artefatos auditados. A disponibilidade pública do benchmark e o histórico de pré-treinamento dos geradores são questões diferentes, que esse inventário não resolve.

A.4 Integridade temporal, funcional e operacional

Os controles incluem alinhamento do estado após o token observado, equivalência prefixo/sequência completa, teacher forcing para probabilidades, reprodução das seeds, ausência de acesso a sufixos nas features, isolamento por tarefa e ajuste de PCA somente no treino. Testes sintéticos conferem empates, tarefas homogêneas, término exatamente no checkpoint, custos de replay e o solver sequencial finito.

A comparação do EvalPlus histórico com o sandbox novo reavaliou 2.640 programas Qwen de origem sem divergência de label. O novo isolamento restringe rede, arquivos e recursos; não altera retrospectivamente a descrição de segurança do worker anterior. Falhas técnicas de preflight foram registradas antes do primeiro candidato válido, sem gerar labels substitutos.

Uma suspensão do Windows por bateria ocorreu de 22h19 de 4 de novembro a 7h59 de 5 de novembro, horário de São Paulo. A interseção comprovada desse intervalo com as sessões

foi excluída da contabilidade ativa. O tempo bruto da tentativa afetada permaneceu inalterado; sua correção temporal está em tabela separada. Nenhuma trajetória foi removida ou regenerada por esse motivo.

Tabelas e intervalos publicados são provenientes dos artefatos identificados. A reescrita não muda bootstrap, limiares, multiplicidade ou interpretação dos protocolos. A auditoria científica registra o alcance dos testes: consistência técnica não comprova ausência de toda adaptação humana, de similaridade semântica ou de contaminação no pré-treinamento.

A.5 Assistência computacional e responsabilidade

A preparação utilizou assistência de um agente de programação para implementação, auditoria, organização dos artefatos, renderização e revisão textual. A autoria científica permanece com o pesquisador, que deve conferir a argumentação, as referências, os resultados e a adequação da versão submetida. O registro dessa assistência não substitui a revisão do orientador nem constitui aprovação institucional.